



INE 5404

Probabilidade e Estatística: Conceitos Iniciais

Simone Silmara Werner

simone.werner@ufsc.br





O Poder da Estatística

A **estatística** é a base da análise de dados.

Com ela, podemos **interpretar** dados, realizar **previsões** e entender a **variabilidade** dos fenômenos. Através de métodos estatísticos, somos capazes de extrair informações significativas que guiam nossas escolhas e estratégias.



Origens da Estatística

As raízes da **estatística** remontam à **Antiguidade**, quando dados eram coletados para fins administrativos e fiscais. Com o tempo, a coleta de dados se expandiu, permitindo uma análise mais profunda da **sociedade** e do **comportamento humano**.

A Revolução Industrial trouxe um aumento na coleta de dados, especialmente nas áreas de **demografia** e **economia**. A necessidade de entender fenômenos sociais e econômicos impulsionou o desenvolvimento de novas técnicas estatísticas.



O estudo da **Estatística**, envolve técnicas para sistematicamente:

1. Planejar a coleta de dados oriundos de estudos ou experimentos, realizados em qualquer área do conhecimento;
2. Descrever, analisar e interpretar dados;
3. Extrair informações para subsidiar decisões;
4. Avaliar evidências empíricas sob hipóteses de interesse

Estatística no Século XX

O século XX viu a **estatística** se consolidar como uma disciplina essencial nas **ciências sociais**, **econômicas** e **naturais**.

O advento da **computação** revolucionou a análise de dados, permitindo a manipulação de grandes conjuntos de informações.



**“Estatística é a Ciência que permite
obter conclusões a partir de
dados”**

Paul Velleman



Métodos Estatísticos

Hoje, os **métodos estatísticos** são amplamente utilizados em diversas áreas, desde a **medicina** até a **economia**. Técnicas como a **análise de regressão**, **agrupamento** e **classificação** são fundamentais para interpretar dados complexos.




Impactos na Pesquisa Científica

A **estatística** desempenha um papel crucial na **pesquisa científica**, permitindo que os pesquisadores testem hipóteses e validem resultados. Sua aplicação rigorosa é essencial para garantir a **credibilidade** e a **reprodutibilidade** dos estudos.



Pesquisas científicas





Definindo População

A população é o conjunto total de elementos que possui uma característica em comum. É fundamental entender que a população pode **ser finita ou infinita**, e a **escolha da amostra** deve refletir as características da população para **garantir a representatividade**.



O que é Amostra?

Uma **amostra** é um **subconjunto da população** que é selecionado para análise. A amostragem correta é vital para obter resultados precisos e confiáveis.

Existem diferentes maneiras de selecionarmos amostras e a **escolha do procedimento de amostragem adequado** é fundamental para que a **inferência estatística seja válida**.

O que é Censo?

Um **censo** é a coleta de dados de toda a população.

Embora forneça informações completas, é frequentemente caro e demorado. Em muitas situações, a amostragem é uma alternativa mais prática, permitindo que as empresas tomem decisões baseadas em dados sem o ônus de um censo.


Variável de interesse

É a característica que será observada em cada indivíduo da amostra ou população, no caso do censo.

Em um mesmo estudo podem ser coletadas/avaliadas diferentes variáveis de interesse.



Tipos de variáveis:



As **variáveis qualitativas** referem-se a características que não podem ser medidas numericamente. Exemplos incluem **gênero, cor e satisfação do cliente**. A análise dessas variáveis ajuda a entender melhor o comportamento e as preferências dos consumidores.



Exemplos de Qualitativas



Um exemplo prático de **variáveis qualitativas** é a **classificação de produtos em categorias** como luxo e básico. Essa categorização permite que as empresas ajustem suas estratégias de marketing e atendam melhor o público-alvo.

As **variáveis quantitativas** são aquelas que podem ser medidas numericamente, como **vendas, lucros e número de funcionários**. Elas são essenciais para a realização de análises estatísticas e para a tomada de decisões baseadas em dados.



Exemplos de variáveis quantitativas

Um exemplo prático de **variáveis quantitativas** é a análise de **vendas mensais** de um produto. Esses dados permitem que as empresas identifiquem padrões e façam previsões para o futuro, otimizando suas operações.



Dados e variáveis

As **variáveis** são as características que podem ser observadas (ou medidas) em cada elemento da população, sob as mesmas condições.

Dado é a informação coletada e registrada, referente a uma variável.

Conceitos importantes

População: Conjunto de todos os elementos sob investigação.

Amostra: Subconjunto da população.

Variável de interesse: característica a ser observada em cada indivíduo da amostra.



O que é Amostragem?

A **amostragem** é o processo de selecionar um subconjunto de indivíduos de uma população.

Através dela, podemos fazer inferências sobre o todo, economizando tempo e recursos. É uma técnica fundamental para a **coleta de dados** na pesquisa e análise.

A amostragem pode ser **probabilística** e **não probabilística**.





Amostragem Não Probabilística

Na amostragem não probabilística, os membros da população não têm chances iguais de serem selecionados. Isso pode levar a **viés** nos resultados, mas é útil em situações onde a rapidez e a facilidade são mais importantes que a precisão estatística.



Tipos de Amostragem Não Probabilística

Os principais tipos de amostragem não probabilística incluem a amostragem por **conveniência**, **intencional** e **quota**. Cada uma tem suas vantagens e desvantagens, sendo escolhido conforme o contexto da pesquisa e os recursos disponíveis.

A amostragem não probabilística é geralmente **mais rápida e menos custosa**. É ideal para estudos exploratórios ou quando a população é difícil de acessar. No entanto, deve ser usada com cautela devido ao potencial de **viés**.





Viés de Sobrevivência

O viés de sobrevivência nos ajuda a entender como a **seleção de dados** pode distorcer nossa percepção da realidade. Este fenômeno ocorre quando apenas os casos de sucesso são considerados, ignorando as falhas. Vamos explorar suas **lições e implicações** em diversas áreas.

O Que é o Viés de Sobrevivência?



O **viés de sobrevivência** refere-se à tendência de concentrar-se apenas nos casos que sobreviveram a um processo, enquanto **os que falharam são ignorados**. Isso pode levar a uma **falsa percepção de sucesso** e à subestimação dos desafios enfrentados por aqueles que não conseguiram.

Exemplos Históricos



Um exemplo famoso é o **estudo sobre os bombardeiros da Segunda Guerra Mundial.**

Os analistas se concentraram em áreas que receberam mais danos, ignorando as que não voltaram. Isso levou a decisões erradas sobre onde reforçar a proteção, evidenciando o viés de sobrevivência.

Impacto em Negócios



No mundo dos negócios, o viés de sobrevivência **pode afetar decisões estratégicas**. Muitas vezes, empresas de sucesso são estudadas como modelos, enquanto as que falharam são deixadas de lado. Isso pode criar uma falsa narrativa sobre o que é necessário para ter sucesso no mercado.



Amostragem Probabilística

Na amostragem probabilística, cada membro da população tem uma chance conhecida de ser selecionado. Isso permite a generalização dos resultados.

Essa técnica é crucial para a **inferência estatística** das pesquisas.

As principais **vantagens** da amostragem probabilística incluem a **representatividade** da amostra, a possibilidade de generalização dos resultados e a redução do **viés**. Isso a torna uma escolha preferencial em pesquisas acadêmicas e de mercado.



Tipos de Amostragem Probabilística

Existem diferentes tipos de amostragem probabilística, como a **amostragem aleatória simples, estratificada e sistemática**. Cada uma tem suas características e é utilizada em situações específicas, dependendo dos objetivos da pesquisa.

Amostragem Aleatória Simples

Definição e Características:

Neste método todos os elementos da população tem igual chance de serem selecionados para compor a amostra. Caracteriza-se por sua simplicidade e neutralidade, permitindo uma representação justa da população. Só deve ser utilizada quando a população é homogênea em relação a variável de interesse.

Processo de Seleção

Escolha aleatória de membros da população. Pode ser feito através de sorteio, uso de tabelas de números aleatórios ou algoritmos computadorizados que garantem a aleatoriedade.

Amostragem Estratificada

Definição e Características:

Neste método a população é dividida em grupos ou estratos, e amostras são extraídas de cada estrato. O principal objetivo é garantir que todos os segmentos da população sejam representados, aumentando a precisão dos resultados.

Para utilização da amostragem estratificada a população deve ser homogênea dentro de cada estrato e heterogênea entre os estratos. Existem diferentes tipos de amostragem estratificada a mais comumente utilizada é a **amostragem estratificada proporcional**.

Amostragem Estratificada

Os **critérios para estratificação** podem incluir características como idade, gênero, renda, ou qualquer outra variável relevante. A escolha adequada dos critérios é essencial para capturar a diversidade dentro da população e evitar vieses.

Processo de Seleção

Divide-se a população em estratos e realiza-se uma amostragem aleatória simples em cada estrato, mantendo na amostra a mesma proporção do estrato presente na população.

Amostragem Estratificada

Exemplo: Considerando a população de 50.000 funcionários da indústria automobilística, formar uma amostra de 2.500 funcionários para calcular o salário médio. Utilizando o critério “cargo” para estratificar a população, determine a amostra em cada estrato.

Cargos	População
Chefes de seção	5.000
Operários especializados	15.000
Operários não especializados	30.000
Total	50.000

Tamanho da amostra

Para amostra aleatória simples

Será revisto com o conteúdo de estimação

VARIÁVEIS QUALITATIVAS

$$n_0 = \frac{z^2 \cdot p \cdot (1 - p)}{d^2}$$

$$n = \frac{n_0}{1 + \frac{n_0}{N}}$$

VARIÁVEIS QUANTITATIVAS

$$n_0 = \frac{z^2 \cdot \sigma^2}{d^2}$$

$$n = \frac{n_0}{1 + \frac{n_0}{N}}$$

Para determinar o tamanho da amostra precisamos:

- **Nível de confiança** (em muitos estudos utiliza-se 95%), que influenciará o valor de z
- O **erro amostral tolerável** ou margem de erro (d)

Z = quantil da distribuição normal padrão, associado ao nível de confiança (para 95% de confiança o valor de $z = 1,96$)

P = proporção de sucesso esperada. Caso não se tenha realizado estudos anteriores considerar $p=0,5$

n = tamanho final da amostra

n₀ = tamanho inicial da amostra, corresponde ao valor que seria obtido para uma população infinita

$$n_0 = \frac{z^2 \cdot p \cdot (1 - p)}{d^2}$$

$$n = \frac{n_0}{1 + \frac{n_0}{N}}$$

n₀ = tamanho inicial da amostra, obtido com a fórmula anterior

N = tamanho da população

d = margem de erro. Para uma margem de erro de 2% o valor de $d=0,02$

Considerando o nível de confiança de 95%, observe o tamanho da amostra de acordo com o tamanho da população considerando a margem de erro de 3% e 5% .

População	Margem de Erro	
	d=3%	d=5%
100	91	79
1.000	516	277
5.000	879	356
20.000	1013	377
100.000	1055	383
500.000	1064	384
1.000.000	1067	384

Cuidados com a amostragem:

- 1) Definição da População
- 2) Definição das unidades amostrais
- 3) Características da população: é homogênea??
- 4) Nível de confiança e margem de erro
- 5) Tamanho da amostra

Exemplo

Considere que deseja calcular o tamanho amostral para estimar uma proporção em uma população de 10.000 indivíduos, nível de confiança de 95% ($z=1,96$) e margem de erro de 8%. Considere $p=0,5$.

Qual o tamanho amostral n ?

Estatística Experimental

A área da estatística conhecida como experimentação foi introduzida por Fischer em 1935 e inicialmente aplicada em experimentos de agricultura.

A experimentação engloba o planejamento e análise de experimentos.

Atualmente, a Estatística Experimental é utilizada para **planejamento e análise de experimentos** em todas as áreas de conhecimentos.

Mas o que é um experimento?

Experimento ou ensaio: é qualquer trabalho científico previamente planejado que segue determinados princípios básicos, no qual se faz comparações entre os efeitos de tratamentos buscando comprovar (ou não) uma **hipótese científica**.

Planejamento de experimentos

Experimentos permitem a observação e a análise de variáveis em um ambiente controlado, com a utilização de tratamentos específicos de acordo com o objetivo do pesquisador.

Para conseguir planejar um experimento é importante conhecer alguns conceitos básicos como: tratamento, controle local, repetição, casualização, variável resposta.

Além disso é importante conhecer alguns delineamentos básicos e algumas estruturas de distribuição de tratamentos, como os esquemas fatoriais.



Experimentos - Conceitos básicos

Tratamento: é formado pelos níveis da variável cujo efeito desejamos medir, avaliar ou comparar em um experimento; é uma característica que permite distinguir diferentes grupos. Os tratamentos podem ser qualitativos ou quantitativos

Podemos ter experimentos com um único fator ou mais de um fator. Os experimentos que envolvem mais de um fator são chamados de experimentos fatoriais.

A forma como é realizada a combinação dos fatores para distribuição nas parcelas (unidades experimentais) é chamada de esquema de tratamentos, no caso de um experimento com mais de um fator temos um esquema fatorial.

Experimentos - Conceitos básicos

Fatores qualitativos: seus níveis apresentam características/qualidades que os distinguem.

Fatores quantitativos: definidos por quantidades de certo produto ou por valores de alguma dimensão.

Os fatores podem ser de efeito fixo ou aleatório.

Experimentos - Conceitos básicos

Delineamento experimental: é o plano (desenho) utilizado na experimentação, em que se define a forma como os tratamentos serão designados às *unidades experimentais*.

Sua escolha envolve um amplo conhecimento do material experimental utilizado e das prováveis fontes de variação do acaso.

Exemplos:

- Delineamento inteiramente casualizado (DIC)
- Delineamento casualizado em blocos (DCB)
- Delineamento em quadrados latinos (DQL)
- Delineamento em *latice*
- *etc.*

Experimentos - Conceitos básicos

Unidade experimental (u.e.) ou parcela: é a unidade básica de material que vai receber o tratamento e fornecer os dados que deverão refletir o efeito deste tratamento. Elas devem ser uniformes e a escolha de sua forma e tamanho deve ser orientada de modo a minimizar o erro experimental.

O tamanho e a forma da unidade experimental dependem, entre outros: dos objetivos da pesquisa, do material utilizado e da quantidade de material disponível, do número de tratamentos em estudo e do custo de cada unidade experimental

O **erro experimental** é uma medida da variação das respostas de unidades experimentais que receberam o mesmo tratamento.

Experimentos - Conceitos básicos

A experimentação obedece a alguns princípios básicos que são indispensáveis na validação das conclusões alcançadas:

A **casualização ou aleatorização** torna os testes estatísticos válidos.

A **repetição** torna os testes estatísticos possíveis e seus resultados, confiáveis.

O **controle local** torna os experimentos mais eficientes.

Experimentos - Conceitos básicos

PRINCÍPIO DA REPETIÇÃO

Consiste na repetição do experimento básico e tem o objetivo de proporcionar uma boa estimativa do erro experimental.

PRINCÍPIO DA CASUALIZAÇÃO OU ALEATORIZAÇÃO

Consiste em designar os tratamentos de forma aleatória às parcelas, para não prejudicar ou favorecer qualquer um deles.

PRINCÍPIO DO CONTROLE LOCAL

Consiste em agrupar o material experimental em subgrupos homogêneos com o objetivo de controlar de forma mais efetiva o erro experimental.

Exemplo:

- Testar diferentes metodologias para extração de informações em um conjunto de dados.

Como você faria?

- Testar diferentes metodologias para classificação de determinados casos.

Como você faria?

Experimentos fatoriais

Fator é uma variável independente cujos valores são controlados, definidos ou escolhidos pelo experimentador. Cada valor que o fator pode assumir é chamado de nível do fator. Experimentos fatoriais são aqueles em que são estudados *simultaneamente* os efeitos de dois ou mais fatores.

Nos experimentos fatoriais chamamos de tratamento cada uma das combinações dos níveis dos diversos fatores.

O experimento fatorial não é um tipo de delineamento experimental, mas sim um esquema orientado de desdobramento dos graus de liberdade de tratamentos e pode ser instalado em qualquer um dos delineamentos experimentais.

Experimentos fatoriais

PRINCIPAL VANTAGEM DE UM EXPERIMENTO FATORIAL:

- Permite o estudo dos efeitos principais dos fatores e dos efeitos da interação entre os níveis de dois ou mais fatores, ou seja, permitem chegar a conclusões mais abrangentes.

PRINCIPAIS DESVANTAGENS:

- O número de tratamentos aumenta rapidamente com o aumento do número de níveis e de fatores, o que pode dificultar o seu uso.

Verificar no livro básico da disciplina a utilização de fatoriais fracionários.



INE 5404

Probabilidade e Estatística: **Análise Exploratória de dados**

Simone Silmara Werner

simone.werner@ufsc.br



Relembrando: Dados e variáveis

As **variáveis** são as características que podem ser observadas (ou medidas) em cada elemento da população, sob as mesmas condições.

Dado é a informação coletada e registrada, referente a uma variável.

Estrutura de um arquivo de dados

- Universalmente os dados costumam ser armazenados em uma estrutura fixa, que possibilita a aplicação de várias técnicas para extrair as informações de interesse.
- As variáveis são registradas nas colunas, e os casos nas linhas. As variáveis são as características pesquisadas ou registradas.

Estrutura de um arquivo de dados


	A	B	C	D	E	F	G	H	I
1	Nome	Sobrenom	Nome Cor	Data de N	Estado de	DDD	Celular	CPF	
2	Rayssa	Valiate	Rayssa Va	32878	Bahia (BA)	71	9,22E+08	8,02E+10	
3	Hygor	Mateus	Hygor Mat	31364	Goiás (GO)	62	9,54E+08	1,89E+10	
4	Dilson	Brandão	Dilson Bra	32739	Espírito Sa	27	9,1E+08	3,25E+10	
5	Alvaro	Bretas	Alvaro Bre	32523	Amapá (A	96	9,47E+08	7,33E+10	
6	Jéssica	Campos	Jéssica Ca	33853	Piauí (PI)	86	9,3E+08	7,4E+10	
7	Adriane	Amaral	Adriane A	31978	Alagoas (A	82	9,92E+08	1,63E+10	
8	Isadora	Elisa	Isadora Eli	31125	Acre (AC)	68	9,49E+08	1,23E+10	
9	Jefferson	Cavadas	Jefferson	32314	Tocantins	63	9,33E+08	9,09E+10	
10	Iris	Hudson	Iris Hudso	33712	Maranhão	98	9,42E+08	9,02E+09	
11	Gizella	Rivero	Gizella Riv	32738	Maranhão	98	9,39E+08	1,06E+10	
12	Zilma	Cassabian	Zilma Cass	34011	Paraíba (P	83	9,4E+08	1,05E+10	
13	Mariana	Felix	Mariana F	33926	Ceará (CE)	88	9,02E+08	8,71E+10	
14	Wesley	Mercês	Wesley M	32063	Piauí (PI)	86	9,94E+08	4,02E+10	
15	Graziela	Marcio	Graziela M	31199	Paraná (PR	41	9,24E+08	1,33E+10	
16	Marisol	Monteiro	Marisol M	32965	Goiás (GO)	62	9,7E+08	7,54E+09	
17	Alecssand	Eduardo	Alecssand	33168	Roraima (R	95	9,84E+08	9,71E+10	
18	Hugo	Medeiros	Hugo Med	34277	Goiás (GO)	62	9,68E+08	5,96E+10	
19	Aledio	Rubim	Aledio Ru	31605	Rondônia	69	9,94E+08	3,25E+10	
20	Cristiane	Fioravante	Cristiane f	33548	Rondônia	69	9,15E+08	6,91E+10	

Estatística Descritiva

O objetivo da **Estatística Descritiva** é resumir as informações de interesse que estão contidas no conjunto de dados, fazendo uso de tabelas, gráficos e resumos numéricos.



Dashboards · Painéis de controle com Estatística Descritiva



Dashboard de Covid-19. Fonte: <https://user-images.githubusercontent.com/44356224/82365851-21ed5e00-99c6-11ea-87b3-d190c2e0dba7.JPG>.

Dashboards - Exemplos



Exemplo de de visualização de dados.

Fonte: <https://www.bizsoft.co.za/wp-content/uploads/2018/08/mobile-data-analytics.png>.

Pré-análise dos Dados

O objetivo é identificar:

- **dados perdidos**
- **erros de registro**
- **valores discrepantes**
- **inconsistências.**

Tabela de frequência

- **Frequência:** quantidade de vezes em que um valor ou um subconjunto de valores do domínio de uma variável aleatória ocorre em uma observação estatística ou em uma experiência
- Tem por objetivo facilitar a visualização dos dados

Vamos considerar os dados de meio de transporte utilizado coletado no formulário que vocês responderam (Turma 2024-2):

<i>Deslocamento para Universidade</i>	Frequência absoluta	Frequência Relativa Percentual
Andando	18	35,29%
Bicicleta	2	3,92%
Carro	5	9,80%
Ônibus	26	50,98%
Total geral	51	100,00%

Tabelas de contingência

- Uma tabela de contingência é uma tabela de dupla entrada, em que os elementos da amostra ou da população são classificados de acordo com dois fatores.

Vamos considerar os dados de meio de transporte utilizado e o fato de ter ou não animal de estimação coletado no formulário que vocês responderam (Turma 2024-2):

<i>Deslocamento para Universidade</i>	<i>Animal de estimação</i>		Total geral
	Não	Sim	
Andando	9	9	18
Bicicleta	0	2	2
Carro	2	3	5
Ônibus	11	15	26
Total geral	22	29	51

É possível utilizar tabela de frequência para variáveis quantitativas?

- Tabela de frequência com intervalos nas classes

É possível utilizar tabela de frequência para variáveis quantitativas?

- Tabela de frequência com intervalos nas classes
- Existem várias maneiras de determinar o número de classes
- Uma das mais conhecidas é a regra de Sturges, que sugere que o número de classes (k) pode ser calculado pela fórmula:

$$\mathbf{k = 1 + 3,322 \log (n)}$$

em que n é o número total de observações

Vamos considerar os dados do número de disciplinas cursadas coletado no formulário que vocês responderam:

Mínimo = Menor valor observado = 5

Máximo = Maior valor observado = 36

n= total de observações = 51

$$k = 1 + 3,322 \log (51)$$

Como construir a tabela?

Resumindo a Informação: “Estatísticas”

As “Estatísticas” são índices numéricos que representam propriedades específicas das variáveis.

- **Medidas de Posição**
 - Medidas de Tendência Central
 - Separatrizes
- **Medidas de Dispersão**

Medidas de Tendência Central

- Média
- Mediana
- Moda

Média aritmética

Dados originais:

$$\bar{X} = \frac{\sum_{i=1}^n x_i}{n}$$

Dados agrupados:

$$\bar{X} = \frac{\sum_{i=1}^k (x_i \times f_i)}{n}$$

Mediana

(Md)

- A mediana é o ponto que **divide o conjunto em duas partes iguais**: metade dos dados têm valor menor do que a mediana e a outra metade têm valor maior do que a mediana
- Pouco afetada por eventuais **valores discrepantes** existentes no conjunto

$$n \text{ ímpar} \Rightarrow Md_X = x_{\left[\frac{n+1}{2}\right]}$$

$$n \text{ par} \Rightarrow Md_X = \frac{x_{\left[\frac{n}{2}\right]} + x_{\left[\frac{n}{2}+1\right]}}{2}$$

onde $x_{[i]}$ é a observação que ocupa a i -ésima posição, no conjunto de dados colocados em ordem crescente ou decrescente.

Moda ***(Mo)***


- A moda é o valor da variável que ocorre com maior frequência no conjunto.
- Nas Variáveis Qualitativas a moda é a classe ou categoria de maior frequência, sendo a “Estatística” de posição mais apropriada para esse tipo de variável.

Separatrizes

- *Quartis*
- *Decis*
- *Percentis*

Quartis

Dividem um conjunto de dados em quatro partes iguais, isto é, 25% dos elementos deve estar em cada parte.



em que:


Q_1 = 1º quartil, deixa 25% dos elementos;

Q_2 = 2º quartil, deixa 50% dos elementos (coincide com a mediana);

Q_3 = 3º quartil, deixa 75% dos elementos.

Percentis

O **Percentil** é uma generalização do conceito de mediana, quartil e decil. Enquanto a mediana divide um conjunto de valores dispostos em ordem crescente em duas partes iguais os percentis podem dividem em **100 partes** iguais.



$$np \text{ inteiro} \Rightarrow P_{100\ p} = \frac{x_{[np]} + x_{[np+1]}}{2}$$

$$np \text{ não inteiro} \Rightarrow P_{100\ p} = x_{[\text{int}(np)+1]}$$

Medidas de Dispersão

- *Amplitude*
- *Distância Interquartílica*
- *Variância amostral*
- *Desvio Padrão amostral*
- *Coeficiente de Variação*

Exemplo de aplicação

Uma Empresa de Papel realizou testes para comparar a produção de papel de três máquinas. Em cada máquina foram tomadas 5 amostras conforme a tabela ao lado.

Qual das máquinas a empresa deve adquirir?

PESO DO PAPEL EM GRAMAS PRODUZIDO
EM DIFERENTES MÁQUINAS

Amostra	Máquinas		
	A	B	C
1	200	152	205
2	210	248	203
3	190	260	195
4	215	200	197
5	185	140	200
Média	200	200	200

Amplitude de Variação e Distância Interquartílica

A maneira mais simples de medir a variabilidade de uma variável é através da “distância” entre duas posições na distribuição.

$$\text{Amplitude de Variação: } A = X_{\text{MÁXIMO}} - X_{\text{MÍNIMO}}$$

$$\text{Distância Interquartílica: } DIQ = Q_3 - Q_1$$

Desvio

Outra forma de se medir a variabilidade de uma variável é quantificando a dispersão das observações em relação a um ponto específico na distribuição.

Distância das Observações para a Média

$$\text{DESVIO: } (X_i - \bar{X})$$

Soma dos Desvios é sempre zero (exceto por problemas de arredondamento).

Variância amostral (s^2)

$$\begin{array}{c} \text{VARIÂNCIA} \\ s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1} \end{array}$$

- Como as variáveis com que trabalhamos possuem UNIDADES DE MEDIDA, é importante considerá-las quando medimos a heterogeneidade dos dados.
- A variância sempre **eleva ao quadrado as unidades de medida**, gerando escalas sem sentido prático.

Desvio Padrão amostral (s)

Se utilizarmos a **raiz quadrada da variância**, recuperamos as unidades originais.

DESVIO PADRÃO

$$s = \sqrt{s^2} = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}}$$

mede a variabilidade
independentemente do número de
observações (n) e com a mesma
unidade de medida da média.

Coeficiente de variação (CV)

O Coeficiente de variação é uma forma de se medir a variabilidade de uma variável de modo independente da UNIDADE DE MEDIDA utilizada ou da ORDEM DE GRANDEZA dos dados.

Razão entre desvio padrão e média torna o CV um número puro.

COEFICIENTE DE VARIAÇÃO

$$CV = \frac{s}{\bar{x}} 100$$

mede a variabilidade numa escala percentual, independe da unidade de medida ou da ordem de grandeza da variável.

Exercício

Os dados abaixo são referentes ao Índice de Preço ao Consumidor (IPCA) anual de 2013 a 2023. Observe que os dados não estão ordenados.

5,91 6,41 10,67 6,29 2,95 3,75 4,31 4,52 10,06 5,69 4,62

- a) Obtenha os valores da média, moda, mediana, variância, desvio padrão e coeficiente de variação?
- b) Considere agora que o valor do IPCA em 2021 foi de 30,06 e não 10,06. Obtenha novamente a média e mediana. O que aconteceu com os valores de ambas? O que você pode perceber em relação à média e a mediana na presença de valores discrepantes?
- c) Some o valor 2 a cada valor do conjunto de dados originalmente apresentado e obtenha novamente os valores da média, moda, mediana, variância, desvio padrão e coeficiente de variação para o novo conjunto. Construa uma tabela comparando os valores obtidos com os dados originais e com os novos valores. O que você percebe?

Gráficos para comunicação estatística

Distribuição: caracterizam a distribuição variáveis qualitativas ou quantitativas.

Relação: exibem a forma da relação ou contraste entre variáveis.


Ordenação: mostram a ordenação de categorias/elementos.

Organização: retratam a estrutura de organização de categorias/elementos.

Evolução: exploram a evolução cronológica de variáveis.

Mapas: representam dados com propriedades geográficas.

Fluxo: descrevem o movimento ou conexão entre categorias/elementos.



Fonte:

http://www.leg.ufpr.br/~paulojus/estbas/slides/100_introducao_estadistica.pdf


<https://r-graph-gallery.com/>

Visualização de dados

A visualização de dados é essencial na análise de dados.

Em um mundo cada vez mais orientado por dados, a capacidade de interpretar e comunicar insights a partir de conjuntos de dados é fundamental para tomar decisões estratégicas.

"...consiste na efetividade de fornecer ao observador o maior número de ideias, no menor tempo, com o mínimo de tinta e no menor espaço." (Ara e Zanluca, 2025)



Representação gráfica

Variáveis Qualitativas

- Gráficos de coluna ou barras
- Gráficos de setores

Gráfico de Barras

Em um dos eixos são colocadas as categorias da variável e no outro as frequências ou percentuais de cada categoria. As barras podem ser horizontais ou verticais

Deslocamento para Universidade versus Deslocamento para Universidade




Gráfico de Barras




Gráfico de Barras




Gráfico de Barras




Gráfico de Pareto

O gráfico de Pareto é uma combinação de um gráfico de barras e um gráfico de linhas usado para visualização.

O eixo vertical direito é usado para frequência cumulativa, enquanto o eixo vertical esquerdo representa a frequência.




Gráfico de Pareto

Gráfico de barras indica a frequência de ocorrência do evento em diferentes categorias em ordem decrescente (da esquerda para a direita), e um gráfico de linhas sobreposto indica a porcentagem cumulativa de ocorrências.

O **princípio de Pareto** (também conhecido como **regra do 80/20**, lei dos poucos vitais ou princípio de escassez do fator) afirma que, para muitos eventos, aproximadamente 80% dos efeitos vêm de 20% das causas.




Gráfico de setores

$$\text{Graus de uma categoria} = \frac{360^\circ \times \text{freq. (prop.) da categoria}}{\text{freq. (prop.) total}}$$

Deslocamento para Universidade





Gráfico donut

Deslocamento para Universidade




Representação gráfica

Variáveis Quantitativas

- Histograma / Densidade
- Gráfico de Caixas (Box-plot)
- Gráfico de Violino


Histogramas

No eixo x é representada a variável e no eixo y a frequência.



Histogramas

Distribuição dos Salários no Departamento de Vendas



Curvas de densidade

Também conhecidos como curvas de densidade suavizadas são uma "suavização dos histogramas"




Gráfico de caixa

É um gráfico que permite avaliar facilmente os valores típicos, a assimetria, a dispersão e os dados discrepantes.

Exige que sejam calculados previamente os valores da Mediana, Quartil Inferior e Quartil Superior do conjunto de dados, bem como a identificação dos extremos superior (maior valor) e inferior (menor valor)




Gráfico de caixa





Gráfico de caixa





Gráfico de Violino



Continua...

Estudar material: Anderson Ara e Amanda Zanluca. Introdução à Visualização de Dados Aplicada