


INE 5404

Probabilidade e Estatística:
**Distribuições amostrais e
estimação de parâmetros**

Simone Silmara Werner


simone.werner@ufsc.br



O que veremos:

- Parâmetros e estatísticas
- Distribuições amostrais
- Estimação de uma média
- Estimação de uma proporção
- Amostragem

Relembrando



Conceitos importantes

População: Conjunto de todos os elementos sob investigação.


Amostra: Subconjunto da população.

Variável de interesse: característica a ser observada em cada indivíduo da amostra.

Variável aleatória: "Uma variável aleatória é uma variável que assume valores numéricos associados aos resultados de um experimento aleatório, em que um (e apenas um) valor numérico é associado com cada ponto do espaço amostral"

Função densidade (ou distribuição) de probabilidade:
uma descrição das probabilidades associadas com os possíveis valores de X . Os valores que X assume determinam o suporte (S) da V.A.





Sugestão de leitura: Breiman (2021) Statistical Modeling: The Two Cultures

Em relação a inferência estatística podemos trabalhar com:

1) Inferência paramétrica (clássica)

Situação mais comum: $X_1, X_2, \dots, X_n$ são i.i.d. (formam uma amostra aleatória simples), com distribuição comum f_θ , conhecida a menos do(s) parâmetro(s).

2) Inferência não paramétrica

Utiliza-se quando alguma pressuposição dos métodos paramétricos falhar, por exemplo a normalidade, homogeneidade de variância, etc.

Trabalha com ranks (rols) das observações.

Se os dados satisfazem as suposições para se utilizar a estatística paramétrica, a inferência não paramétrica têm menor precisão.

3) Inferência Bayesiana

Utiliza-se quando tem-se informação *a priori* dos dados que pode ser inserida no modelo estatístico, de tal forma que os resultados *a posteriori* são melhorados.

A **inferência** pode ser dividida em:

1) Estimação de Parâmetros:

Consiste em avaliar uma medida populacional, a partir da informação amostral.

a) Estimação pontual

b) Estimação intervalar

2) Testes de Hipóteses:

Consiste em julgar hipóteses sobre populações usando

Em inferência estatística utilizamos uma **notação própria** para diferenciar medidas usadas para descrever características da população e da amostra:

Parâmetro é uma medida usada para descrever uma característica da **população**.

$$(\theta, \mu, \sigma^2, \sigma, p, \dots)$$

Estatística (ou **estimador**) é uma medida usada para descrever uma característica da **amostra** (fórmula).

$$(\hat{\theta}, \bar{x}, s^2, s, \hat{p}, \dots)$$

Em um experimento, obtemos dados experimentais (amostra), através do uso de repetições dos tratamentos, generalizamos os resultados para todos os experimentos similares (população conceitual).

Dados experimentais
(amostra)

Generalizações

Todos os valores possíveis
(População)

Definição

Qualquer valor calculado com base nos elementos de uma amostra é chamado uma **estatística** (ou **estimador**) Ou seja,
Dada uma amostra aleatória $(X_1, X_2, \dots, X_n)$, uma estatística T é uma função da amostra: $T = f(X_1, X_2, \dots, X_n)$

Exemplos

❖ Média amostral

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

❖ Menor valor da amostra

$$X_{(1)} = \min(X_1, X_2, \dots, X_n)$$

❖ Variância amostral

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

❖ Maior valor da amostra:

$$X_{(n)} = \max(X_1, X_2, \dots, X_n); \text{ etc.}$$

Logo, como uma estatística T é uma função das variáveis aleatórias $X_1, X_2, \dots, X_n$, podemos dizer que **T é uma variável aleatória.**

Estimação Pontual

- A ideia geral por trás da estimação pontual é muito simples.
- É natural que se procure um método para se achar um bom estimador para θ .
- Existem algumas propriedades que definem o que é um bom estimador, ou o “melhor” estimador entre uma série de candidatos.

Propriedades dos Estimadores

Propriedades dos estimadores

Podemos ter estimadores:



*Sem viés e
Sem precisão*



*Com viés e
Com precisão*



*Sem viés e
Com precisão*

O estimador precisa ter algumas propriedades:


a) Vício:

Um estimador $\hat{\theta}$ é **não viciado** ou **não viesado** para um parâmetro θ se:


$$E(\hat{\theta}) = \theta$$

Em outras palavras, um estimador é não viciado se o seu valor esperado coincide com o parâmetro de interesse.

Não Viesado



Viesado



Um estimador $\hat{\theta}$ é dito **assintoticamente não viciado** se

$$\lim_{n \rightarrow \infty} E[\hat{\theta}] = \theta$$

Ou seja, para grandes amostras, $\hat{\theta}$ passa a ser imparcial.

b) Consistência:

Um estimador é **consistente** se, à medida que o tamanho da amostra aumenta, seu valor esperado converge para o parâmetro de interesse e sua variância converge para zero:

c) Eficiência:

Dados dois estimadores $\hat{\theta}_1$ e $\hat{\theta}_2$, não viciados para um parâmetro θ .

Dizemos que $\hat{\theta}_2$ é mais **eficiente** do que $\hat{\theta}_1$ se:

$$Var(\hat{\theta}_2) < Var(\hat{\theta}_1)$$

Exemplo

Mostre que o estimador que aprendemos para estimar a média e o estimador que aprendemos para estimar a variância são não viciados se considerarmos uma amostra com distribuição Normal.

Considere dois estimadores para média apresentados abaixo. Sendo $X_1, \dots, X_n$, uma amostra i.i.d de uma variável X com distribuição Normal. Qual o melhor estimador?

$$\hat{\theta}_1 = \frac{1}{n} \sum_{i=1}^n X_i \quad \text{e} \quad \hat{\theta}_2 = \frac{X_{(1)} + X_{(n)}}{2}$$




Exemplo

Um responsável pela fábrica de chocolates deseja conhecer o verdadeiro peso das barras de chocolate produzidas.

Vamos supor que o número de barras seja 200.

E que vamos utilizar uma amostra de 10 barras.

Exemplo



Exemplo:

```
pop=rnorm(200,12,3)
A1=round(sample(pop,10),2)

A2=round(sample(pop,10),2)

A3=round(sample(pop,10),2)

A4=round(sample(pop,10),2)
```

```
> A1
[1]  7.53 10.14 13.76 13.15 12.64 12.04  9.97 11.95 11.72  8.29
> A2
[1] 15.44 15.00 11.85 12.13  8.92 11.63  9.89 14.25 11.95 11.75
> A3
[1] 10.64 13.21 11.70 12.39 11.56 13.15 13.89 12.97  7.24 12.28
> A4
[1]  7.84 12.84 13.18  5.85 15.69 12.13 12.57  7.24 11.21 12.09
```



Exemplo:

```
pop=rnorm(200,12,3)
A1=round(sample(pop,10),2)

A2=round(sample(pop,10),2)

A3=round(sample(pop,10),2)

A4=round(sample(pop,10),2)
```

```
> mean(A1)
[1] 11.119
> mean(A2)
[1] 12.281
> mean(A3)
[1] 11.903
> mean(A4)
[1] 11.064
```

```
> A1
[1] 7.53 10.14 13.76 13.15 12.64 12.04 9.97 11.95 11.72 8.29
> A2
[1] 15.44 15.00 11.85 12.13 8.92 11.63 9.89 14.25 11.95 11.75
> A3
[1] 10.64 13.21 11.70 12.39 11.56 13.15 13.89 12.97 7.24 12.28
> A4
[1] 7.84 12.84 13.18 5.85 15.69 12.13 12.57 7.24 11.21 12.09
```



*Posso afirmar que qualquer estatística é
uma variável aleatória?*

*Posso afirmar que qualquer estatística é
uma variável aleatória?*

SIM!

Distribuição amostral

É a distribuição de probabilidade de uma estatística da amostra que é formada quando TODAS as possíveis amostras de tamanho n são retiradas de uma população.

Os valores das estatísticas, calculados nas amostras, vão formar uma nova população (de médias, de variâncias, de proporções, etc), cuja distribuição recebe o nome de distribuição amostral (de médias, de variâncias, de proporções, etc).

Exemplo:

Com as médias das amostras, é possível construir a distribuição de frequências das médias das amostras, denominada **distribuição amostral da média**, cuja média denomina-se **média amostral** e seu desvio padrão é chamado de **erro padrão da média** ou **erro amostral**.

a) Distribuição amostral da média

Se amostras aleatórias de tamanho n forem tomadas de uma população com média μ e desvio padrão σ , então a distribuição amostral de $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$, terá:

1) $\mu_{\bar{X}} = E(\bar{X}) = \mu$

2) $\sigma_{\bar{X}}^2 = Var(\bar{X}) = \frac{\sigma^2}{n} \Rightarrow \sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}}$

Se o tamanho da amostra cresce o desvio padrão da média (**erro padrão da média**) amostral decresce.

3) Se a população original X tem distribuição Normal, então $\bar{X}$ também tem distribuição Normal, ou seja:

$$X \sim N(\mu, \sigma^2) \Rightarrow \bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

Erro padrão da média

É uma medida da dispersão das médias amostrais em torno da média populacional, que é obtida calculando-se:

$$\sigma_{\bar{X}} = \frac{\sigma_X}{\sqrt{n}}$$

Contudo, em geral, não conhecemos σ (desvio padrão populacional)! E aí?




$$s_{\bar{X}} = \frac{s_X}{\sqrt{n}}$$

- Quanto **menor** for o seu valor, mais provável será a chance de obter a média da amostra nas proximidades da média populacional;
- Quanto **maior** for, menos provável se torna esse evento.

Verificando diferentes valores de n:

```
m <- 1000
nval <- c(10, 30, 50, 100, 300)
set.seed(1)
th1 <- sapply(nval,
              function(n){
                replicate(m, mean(rnorm(n, mean = 10, sd = 4)))
              })
```





Teorema do Limite Central

Se a população original tem uma distribuição **QUALQUER** com média μ e variância σ^2 , para n “suficientemente grande” (na prática, quando $n > 30$), então:

$$\left. \begin{array}{l} E(X) = \mu \\ Var(X) = \sigma^2 \end{array} \right\} \Rightarrow \bar{X} \overset{a}{\sim} N\left(\mu, \frac{\sigma^2}{n}\right)$$

Onde $\overset{a}{\sim}$ significa aproximadamente distribuído.

Verificando diferentes distribuições:

```
# Normal(500, 1000)
norm <- rnorm(500, mean = 500, sd = 100)

# Uniforme[200,800]
unif <- runif(500, min = 200, max = 800)

# Exponencial(1)
expo <- rexp(500, rate = 1)

# Poisson(2)
pois <- rpois(500, lambda = 2)
```



Verificando diferentes distribuições:

```
# Normal(500, 1000)
norm <- rnorm(500, mean = 500, sd = 100)

# Uniforme[200,800]
unif <- runif(500, min = 200, max = 800)

# Exponencial(1)
expo <- rexp(500, rate = 1)

# Poisson(2)
pois <- rpois(500, lambda = 2)
```




Verificando diferentes distribuições:

```
n <- c(5, 25, 100) #tamanho da amostra
# m = número de amostras aleatórias de tamanho n
m <- 500 #número de amostras aleatórias de tamanho n

# Distribuição Normal
hist(norm, freq = TRUE, main = "População - N = 500",
      include.lowest = TRUE, right = FALSE, ylab = "Frequência",
      col = "lightgray", xlab = "Normal", xlim = xlim.norm)
for(i in 1:3){
  for(j in 1:m){
    temp[j] <- mean(sample(norm, size = n[i], replace = TRUE))
  }
  hist(temp, freq = TRUE, main = paste("n = ", n[i]),
        include.lowest = TRUE, right = FALSE, ylab = "Frequência",
        xlab = "Médias amostrais", xlim = xlim.norm)
}
```




População - N = 500




Normal

n = 5




Médias amostrais

n = 25




Médias amostrais

n = 100




Médias amostrais

População - N = 500




Uniforme

n = 5




Médias amostrais

n = 25




Médias amostrais

n = 100




Médias amostrais


População - $N = 500$




$n = 5$




$n = 25$




$n = 100$




População - $N = 500$




$n = 5$



$n = 25$



$n = 100$




Verificando diferentes distribuições:


```
# Distribuição Normal
hist(norm, freq = TRUE, main = "População - N = 500",
      include.lowest = TRUE, right = FALSE, ylab = "Frequência",
      col = "lightgray", xlab = "Normal", xlim = xlim.norm)
for(i in 1:3){
  for(j in 1:m){
    temp[j] <- mean(sample(norm, size = n[i], replace = TRUE))
  }
  qqPlot(temp, main = paste("n = ", n[i]),
        ylab = "Médias amostrais", ylim = xlim.norm)
}
```




População - N = 500




n = 5




n = 25




n = 100




População - N = 500




n = 5




n = 25



n = 100




População - N = 500




Exponencial

n = 5




norm quantiles

n = 25




norm quantiles

n = 100




norm quantiles

População - N = 500




Poisson

n = 5




norm quantiles

n = 25



norm quantiles

n = 100



norm quantiles

b) Distribuição amostral da proporção

Seja p a proporção das unidades de uma população que possuem uma certa característica (proporção de “sucessos”).

Se amostras aleatórias de tamanho n forem tomadas de uma população com proporção p , então a distribuição amostral de $\hat{p} = \frac{x}{n}$ é um estimador sem viés de p .

$$1) \quad \mu_{\hat{p}} = E(\hat{p}) = p$$

$$2) \quad \sigma_{\hat{p}}^2 = Var(\hat{p}) = \frac{p(1-p)}{n} \Rightarrow \sigma_{\hat{p}} = \sqrt{\frac{p(1-p)}{n}}$$

Se o tamanho da amostra cresce o **desvio padrão** da proporção amostral decresce.

- 3) Se a população original tem distribuição QUALQUER, para n suficientemente grande ($n \geq 30$), então $\hat{p}$ terá distribuição aproximadamente Normal:

$$\hat{p} \overset{a}{\sim} N\left(p, \frac{p(1-p)}{n}\right)$$

De modo geral, podemos escrever a expressão do valor do **erro amostral máximo** como:

Na estimação de μ

$$\varepsilon_{\max} = z_{\gamma/2} \frac{\sigma}{\sqrt{n}}$$


Na estimação de p

$$\varepsilon_{\max} = z_{\gamma/2} \sqrt{\frac{p(1-p)}{n}}$$

O Intervalo de confiança (IC) no fundo combina o estimador pontual com o erro amostral máximo esperado.

Interpretação:

Ele nos dá um intervalo dentro do qual esperamos, com grau de confiança especificado, que o parâmetro θ se encontre.



Centro do intervalo

Intervalos de Confiança

O problema de utilizarem **estimadores pontuais** é que eles não fornecem uma medida de precisão, isto é, **não demonstram o quanto poderíamos estar errando ao utilizarmos esse único valor para estimar o parâmetro**. Portanto, o processo de estimação deve também levar em conta o possível erro amostral do estimador, que depende da sua distribuição amostral.


Por exemplo, a média dos valores de uma amostra ($\bar{X}$) dificilmente vai ser igual à média verdadeira (μ), apesar de esperarmos obter valores próximos.

A diferença entre a estatística (estimador) e o parâmetro é denominada **erro amostral**.

* No caso da média:

$$e = \bar{X} - \mu$$

Apesar do valor desse erro amostral não poder ser calculado, pois o seu cálculo depende do valor do parâmetro que estamos estimando, **sua magnitude pode ser quantificada a partir da distribuição amostral da média ($\bar{X}$)**



Podemos dizer que:

68% dos possíveis valores da média de uma amostra aleatória simples de tamanho n não se afastam do verdadeiro valor da média em mais do que $\frac{\sigma}{\sqrt{n}}$

Ou

Não esperamos que um erro amostral seja maior do que $\frac{\sigma}{\sqrt{n}}$ com probabilidade de 0,68.

OBS: Podemos aplicar o mesmo raciocínio na cálculo do erro amostral máximo esperado na estimação da proporção populacional (p), pela proporção amostral $\hat{p}$.

Definição

Seja $(X_1, X_2, \dots, X_n)$ uma amostra aleatória de tamanho n de uma população e θ o parâmetro de interesse. Sejam T_l e T_2 estatística tais que:

$$P(T_l(X_1, \dots, X_n) \leq \theta \leq T_2(X_1, \dots, X_n)) = \gamma$$



Limite inferior do
intervalo (LI)



Limite superior do
intervalo (LS)

Então o intervalo $(T_l ; T_2)$ é chamado **intervalo de 100 γ % de confiança (IC) bicaudal para o parâmetro para θ .**

α : **nível de significância** com $0 < \alpha < 1$.

γ : **nível de confiança:**

$$\gamma = 1 - \alpha$$

Comprimento do intervalo:

$$l = T_2(X_1, X_2, \dots, X_n) - T_l(X_1, X_2, \dots, X_n)$$

Especificação de um intervalo de confiança

O que é necessário?

- ✓ Um estimador (pontual) do parâmetro em estudo;
- ✓ Um nível de confiança;
- ✓ Conhecer a dimensão da amostra;
- ✓ Conhecer a distribuição amostral da estatística utilizada para estimar o parâmetro.

1) IC para a média populacional μ

- a) Quando o desvio padrão da população (σ) é **conhecido**;
- b) Quando o desvio padrão da população (σ) **NÃO é conhecido**;

a) IC para a média populacional μ


Considere uma população normal, σ^2 conhecido.

Sejam:

- a) γ o coeficiente de confiança fixo; e
- b) Uma amostra aleatória de tamanho n da população X , tal que,
$$X_1, X_2, \dots, X_n \sim N(\mu, \quad)$$

$$\bar{X} \sim ?$$

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{\sqrt{n}}\right) \longrightarrow Z = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \sim N(0,1)$$



α = nível de significância (**fixado**)

$$P(-z_{\gamma/2} < Z < z_{\gamma/2}) = 1 - \alpha = \gamma \quad (\text{nível de confiança})$$

$$P\left(-z_{\gamma/2} < \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} < z_{\gamma/2}\right) = 1 - \alpha \longrightarrow P\left(\bar{X} - z_{\gamma/2} \frac{\sigma}{\sqrt{n}} < \mu < \bar{X} + z_{\gamma/2} \frac{\sigma}{\sqrt{n}}\right) = 1 - \alpha$$


$$IC(\mu; 100\gamma\%) = \left[\bar{X} \pm z_{\gamma/2} \frac{\sigma}{\sqrt{n}} \right]$$

$$\bar{X} \sim ?$$

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{\sqrt{n}}\right)$$

α = nível de significância (**fixado**)

$1 - \alpha = \gamma$ (nível de confiança)



`qnorm(alpha/2, média, sigma/sqrt(n) )`

`qnorm(1- alpha/2, média, sigma/sqrt(n) )`



Exemplo

Para uma amostra de 36 observações de uma população normal com desvio padrão conhecido $\sigma = 3,6\text{kg}$ e média desconhecida, seja 59,6kg a média amostral. Construir os intervalos de 92% e 99% de confiança para μ .

b) IC para a média populacional μ

Considere uma população normal, isto é, $X \sim N(\mu, \sigma^2)$, sendo σ^2 **desconhecido**, ou **amostra $n < 30$** .

Sejam:

- a) γ o coeficiente de confiança fixo; e
- b) Uma amostra aleatória de tamanho n da população X , tal que,

$$X_1, X_2, \dots, X_n \sim N(\mu, \sigma)$$


Na maioria das situações práticas, o desvio padrão da população, σ , não é conhecido. Nestas situações, ele é substituído pelo seu estimador, s , o desvio padrão amostral. Esta substituição pura e simples, no intervalo de confiança anterior (a), causa uma alteração na distribuição de probabilidade a ser considerada, na realidade, o nível de confiança, isto é, o pesquisador pensa que está trabalhando com um nível de confiança, por exemplo, de 95%, quando na realidade, o nível de confiança é menor; portanto, deve-se utilizar um valor maior do que o valor de z . O valor a ser utilizado é obtido da distribuição ***t de Student***

Como encontrar os limites de confiança?

Se $n \leq 30$

Sabe-se que:

$$T = \frac{\bar{X} - \mu}{\frac{s}{\sqrt{n}}} \sim t_{(n-1)}$$



$$P(-t_{(n-1; \gamma/2)} < T < t_{(n-1; \gamma/2)}) = 1 - \alpha$$

$$t_{(n-1; \gamma/2)} = t_{(n-1)}$$

O IC para a média é dado por:

$$P\left(\bar{X} - t_{(n-1)} \frac{s}{\sqrt{n}} < \mu < \bar{X} + t_{(n-1)} \frac{s}{\sqrt{n}}\right) = 1 - \alpha$$

$$IC(\mu; 100\gamma\%) = \left[\bar{X} \pm t_{(n-1)} \frac{s}{\sqrt{n}} \right]$$

Exemplo


Um pesquisador deseja estabelecer o peso médio dos jovens entre 14 e 20 anos. Apesar de desconhecer a média e o desvio padrão da população, sabe por literatura da área que a distribuição dos pesos é aproximadamente normal. Retira-se uma amostra de 10 jovens obtendo peso médio de 67kg e desvio padrão de 9kg. Estabeleça o intervalo de 98% de confiança para o peso médio da população.

*2) IC para proporção
populacional p*

Pelo teorema do limite central para n grande ($n > 30$),
temos que:

$$\hat{p} \overset{a}{\sim} N\left(p; \frac{p(1-p)}{n}\right)$$

$$\Rightarrow Z = \frac{\hat{p} - p}{\sqrt{\frac{p(1-p)}{n}}} \overset{a}{\sim} N(0,1)$$



Usando $\frac{\hat{p}(1-\hat{p})}{n}$ como estimador de $\frac{p(1-p)}{n}$

$$P(-z_{\gamma/2} < Z < z_{\gamma/2}) = 1 - \alpha$$

$$P\left(-z_{\gamma/2} < \frac{\hat{p} - p}{\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}} < z_{\gamma/2}\right) = 1 - \alpha \Rightarrow P\left(\hat{p} - z_{\gamma/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} < p < \hat{p} + z_{\gamma/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}\right) = 1 - \alpha$$

$$IC(p; 100\gamma\%) = \left[\hat{p} \pm z_{\gamma/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \right]$$

Exemplo

Na observação de 30 medicamentos escolhidos ao acaso em uma determinada farmácia, verificou-se que 6 apresentavam prazo de validade vencido.

- a) Estimar a porcentagem de medicamentos vencidos na farmácia.*
- b) Construir um intervalo de 95% de confiança para a porcentagem de medicamentos vencidos nesta farmácia.*
- c) Construir um intervalo de 99% de confiança para a porcentagem de medicamentos vencidos nesta farmácia.*