


INE 5404

Probabilidade e Estatística: Correlação e Regressão


Simone Silmara Werner
simone.werner@ufsc.br



Análise Bidimensional de Variáveis Quantitativas

Ao investigarmos a relação entre duas variáveis quantitativas, o primeiro passo é realizar uma inspeção gráfica por meio do diagrama de dispersão.

Um diagrama de dispersão, também conhecido como gráfico de dispersão ou gráfico de correlação, é uma representação visual entre duas variáveis quantitativas.



Correlação

A correlação é usada para observar a relação que existe entre duas variáveis quantitativas.

Exemplo :

- Faltas e Notas finais
- Peso e altura

Covariância

A **covariância** entre duas variáveis aleatórias X e Y , com valores esperados $E(X)=\mu_X$ e $E(Y)=\mu_Y$ é definida como uma medida de como duas variáveis variam conjuntamente: $COV(X,Y)=E[(X-\mu_X)(Y-\mu_Y)]$

$$\text{cov}(X, Y) = \frac{1}{n} \left[\sum_{i=1}^n x_i y_i - \frac{1}{n} \left(\sum_{i=1}^n x_i \right) \left(\sum_{i=1}^n y_i \right) \right]$$

Coeficiente de Correlação

O coeficiente de correlação mais utilizado é o Pearson, que considera a linearidade entre as variáveis. É importante entender suas limitações, pois correlações **não implicam em causalidade**. Vamos explorar como calcular e interpretar este coeficiente.

Assistir, memorizar o conceito e se divertir:

<https://youtu.be/D5hxMQNHycf?feature=shared>


Coeficiente de Correlação Linear de Pearson

Mede a intensidade e a direção da relação linear entre duas variáveis.

$$r_{xy} = \frac{\sum x_i y_i - n \bar{x} \bar{y}}{n s_x s_y} = \frac{n \sum x_i y_i - \sum x_i \sum y_i}{\sqrt{n \sum x_i^2 - (\sum x_i)^2} \sqrt{n \sum y_i^2 - (\sum y_i)^2}}.$$


O valor de “ r ” estará sempre no intervalo de -1 a 1

Existem diferentes tipos de correlação: **positiva**, **negativa** e **nula**. A correlação positiva indica que à medida que uma variável aumenta, a outra também aumenta. A correlação negativa indica que uma variável aumenta enquanto a outra diminui. A correlação nula não mostra relação.



Propriedades do Coeficiente de Correlação Linear

- Este coeficiente é adimensional, logo não é afetado pelas unidades de medidas das variáveis X e Y .



É possível testar a hipótese que o coeficiente de correlação seja igual a zero, ou seja,

$$H_0 : \rho = 0$$

$$H_1 : \rho \neq 0$$

O teste estatístico apropriado para esta hipótese é

$$t_{cal} = r \sqrt{\frac{n-2}{1-r^2}} \quad \text{com} \quad r = \text{corr}(X, Y)$$

que segue uma distribuição t com n-2 graus de liberdade.


Exemplo

O coordenador de um curso de CCO está estudando a existência ou não de correlação entre as notas de diversas disciplinas. Analisando uma amostra de 12 alunos encontrou-se uma correlação de 0,6 entre as disciplinas de Estatística e Matemática Discreta.

Teste a hipótese de não haver correlação entre as disciplinas.

Use $\alpha = 5\%$.

Introdução à Regressão




A regressão é uma técnica estatística que permite modelar a relação entre uma variável dependente e uma ou mais variáveis independentes. Ela é amplamente utilizada para previsão e análise de dados, permitindo entender como as variáveis se influenciam mutuamente.

Regressão Linear


Depois de constatar que existe uma correlação linear significativa, você pode escrever uma equação que descreva a relação entre as variáveis x e y . Essa equação chama-se reta de regressão ou reta do ajuste ótimo.

Regressão linear simples


- Relação linear
- Apenas uma variável independente
- $Y = \beta_0 + \beta_1 X + \varepsilon$




Regressão linear simples



Regressão linear simples



- Construção da equação de regressão com base nos dados:



Método dos Mínimos Quadrados

Estimativa de beta:

$$b = \frac{n \cdot \sum (x_i y_i) - (\sum x_i) \cdot (\sum y_i)}{n \cdot \sum x_i^2 - (\sum x_i)^2}$$

Estimativa de alpha :

$$a = \frac{\sum y_i - b \sum x_i}{n}$$

Reta de regressão construída com os dados:

$$\hat{y}_i = a + bx_i$$

a (intercepto) é o valor predito Y em X=0.

b (inclinação ou coeficiente angular) expressa a *taxa de mudança* em Y, isto é, é a mudança em Y quando ocorre a mudança de uma unidade em X.

Regressão Linear

A regressão linear simples constitui uma tentativa de estabelecer uma equação matemática linear (linha reta) que descreva o relacionamento entre duas variáveis, da seguinte forma:

em que::

a – ponto de intersecção da linha de regressão linear com o eixo y (ponto no qual $x = 0$);

b – declividade da linha de regressão (coeficiente angular);

y – valor estimado da variável dependente, dado um valor específico da variável independente “x”;

x – valor específico da variável independente.

Exemplo:

Para contextualizar o modelo de regressão vamos utilizar um modelo bem simples apresentado no livro do professor Barbetta, que busca explicar a altura dos filhos(as) em função da altura dos pais.

Estimativas dos parâmetros β_0 e β_1

$$b = \frac{n \cdot \sum(X \cdot Y) - (\sum X) \cdot (\sum Y)}{n \cdot \sum X^2 - (\sum X)^2}$$


$$b = \frac{9 \cdot (263.483) - (1.539) \cdot (1.540)}{9 \cdot (263.333) - (1.539)^2} = \frac{1.287}{1.476} = 0,872$$

$$a = \frac{\sum Y - b \cdot \sum X}{n}$$


$$a = \frac{1.540 - (0,872) \cdot (1.539)}{9} = 22,00$$

Dados		Cálculos	
X	Y	X ²	X · Y
164	166	26.896	27.224
166	166	27.556	27.556
169	171	28.561	28.899
169	166	28.561	28.054
171	171	29.241	29.241
173	171	29.929	29.583
173	178	29.929	30.794
176	173	30.976	30.448
178	178	31.684	31.684
1.539	1.540	263.333	263.483

Estimativas dos parâmetros β_0 e β_1



Equação de regressão




Valores preditos e resíduos


$$\hat{y} = 22 + 0,872x$$

x	y	Predito	Resíduo
164	166	165,01	0,992
166	166	166,75	-0,752
169	171	169,37	1,632
169	166	169,37	-3,368
171	171	171,11	-0,112
173	171	172,86	-1,856
173	178	172,86	5,144
176	173	175,47	-2,472
178	178	177,22	0,784

$$\hat{e} = y - \hat{y}$$

Valores preditos e resíduos






Variação explicada pelo modelo de regressão

Soma de quadrados devida ao erro aleatório:

$$SQE = \sum (y - \hat{y})^2$$



Variação em relação à média aritmética (variação total)

Soma de quadrado total:

$$SQT = \sum (y - \bar{y})^2$$

Soma de quadrado total:

$$SQT = \sum (y - \bar{y})^2$$

Soma de quadrados do erro:

$$SQE = \sum (y - \hat{y})^2$$

Soma de quadrados da regressão:

$$SQR = SQT - SQE$$


Coeficiente de determinação:

$$R^2 = \frac{SQR}{SQT} = \frac{\text{variação explicada}}{\text{variação total}}$$

$$0 \leq R^2 \leq 1$$

Variação explicada e não-explicada

x	y	Média $\bar{y}$	$y - \bar{y}$	$(y - \bar{y})^2$
164	166	171,11	-5,11	26,11
166	166		-5,11	26,11
169	171		-0,11	0,01
169	166		-5,11	26,11
171	171		-0,11	0,01
173	171		-0,11	0,01
173	178		6,89	47,47
176	173		1,89	3,57
178	178		6,89	47,47
			0	177

$$SQT = \sum (y - \bar{y})^2$$


Lembrando:

$$s^2 = \frac{SQT}{n - 1}$$

Variação explicada e não-explicada

x	y	Preditos $\hat{y}$	$y - \hat{y}$	$(y - \hat{y})^2$
164	166	165,01	0,992	0,98
166	166	166,75	-0,752	0,56
169	171	169,37	1,632	2,66
169	166	169,37	-3,368	11,36
171	171	171,11	-0,112	0,01
173	171	172,86	-1,856	3,46
173	178	172,86	5,144	26,42
176	173	175,47	-2,472	6,1
178	178	177,22	0,784	0,61
0				52

$$SQE = \sum (y - \hat{y})^2$$


Variação explicada e não-explicada

Fonte de variação	Somas de quadrados
Explicada por X pelo modelo de regressão (variação <i>explicada</i>)	$SQR = 125$
Devida ao erro aleatório (variação <i>não-explicada</i>)	$SQE = 52$
Variação total	$SQT = 177$

$$R^2 = \frac{SQR}{SQT} = \frac{125}{177} = 0,706 \text{ ou } 70,6\%$$

Interpretar.

Análise de variância (ANOVA) sobre o modelo

- Usando a razão entre a variação explicada pela regressão e a variação não-explicada (variação aleatória), pode-se testar a **utilidade** do modelo.
 - H_0 : Não há regressão (X não tem efeito sobre Y)
 - H_1 : Há regressão
- Ou, ainda:
 - $H_0: \beta_1 = 0$ e
 - $H_1: \beta_1 \neq 0$ no modelo $Y = \beta_0 + \beta_1 X + \varepsilon$

Análise de variância (ANOVA) sobre o modelo


Fonte de variação	<u>gl</u>	SQ	QM	Razão f
Regressão	1	$SQR = \sum (\hat{y}_i - \bar{y})^2$	$QMR = SQR / 1$	$f = QMR / QME$
Erro	$n - 2$	$SQE = \sum (y_i - \hat{y}_i)^2$	$QME = SQE / n - 2$	
Total	$n - 1$	$SQT = \sum (y_i - \bar{y})^2$	$QMT = SQT / n - 1$	

Compara-se razão f com a *distribuição F* de

$gl = 1$ no numerador e

$gl = n - 2$ no denominador

Análise de variância (ANOVA) sobre o modelo



- Valor- $p < \alpha$ ($= 0,05$) $\rightarrow$ Rejeita H_0 (Há regressão)
- Valor- $p \geq \alpha$ ($= 0,05$) $\rightarrow$ Aceita H_0 (Não há regressão)

Análise de variância (ANOVA) sobre o modelo


Fonte de variação	<u>gl</u>	SQ	QM	Razão f
Regressão	1	$SQR = \sum (\hat{y}_i - \bar{y})^2$	$QMR = SQR / 1$	$f = QMR / QME$
Erro	$n - 2$	$SQE = \sum (y_i - \hat{y}_i)^2$	$QME = SQE / n - 2$	
Total	$n - 1$	$SQT = \sum (y_i - \bar{y})^2$	$QMT = SQT / n - 1$	

Compara-se razão f com a *distribuição F* de

$gl = 1$ no numerador e

$gl = n - 2$ no denominador

Análise de variância (ANOVA) sobre o modelo




- Valor- $p < \alpha$ ($= 0,05$) $\rightarrow$ Rejeita H_0 (Há regressão)
- Valor- $p \geq \alpha$ ($= 0,05$) $\rightarrow$ Aceita H_0 (Não há regressão)

Predição de uma nova observação

- Dado um valor da variável independente, x_0 , qual é o valor predito de Y?
 - Estimativa pontual:

$$\hat{y}_0 = a + bx_0$$



Exercício

Os dados que se seguem (Snedecor e Cochran, 1967) referem-se a medidas de alturas de feijão (Y), durante 7 semanas (amostras aleatórias independentes)

Idade em semanas (X)	1	2	3	4	5	6	7
Alturas em cm (Y)	5	13	16	23	33	38	40

- a) As variáveis Idade em semanas e Altura são correlacionadas? Calcule o coeficiente de correlação Linear de Pearson e verifique se ele difere significativamente de zero (5% de significância)
- b) Obtenha a reta de mínimos quadrados que descreve o comportamento do altura em função da idade
- c) Qual a altura esperada para a 8 semana?

Para tentar reduzir os custos, uma empresa levantou informações de 6 situações relacionando “o número de defeitos nos produtos” em função do “gasto com o controle de qualidade” (R\$). Segue um resumo dos resultados desses dados.

$\sum x$	$\sum x^2$	$\sum y$	$\sum y^2$	$\sum x \cdot y$
325	21075	45	455	3038


Sendo X : “o número de defeitos nos produtos” e Y : “gasto com o controle de qualidade” (R\$).

Foi verificada uma relação linear entre essas variáveis e um modelo de regressão linear simples foi ajustado pelo método de mínimos quadrados. Dessa forma, a estimativa aproximada dos coeficientes linear e angular desse modelo de regressão são, respectivamente:


- (A) 10,82 e 5,78.
- (B) –1,71 e 0,17.
- (C) 15,84 e 5,11.
- (D) –0,31 e 0,15.
- (E) 3,27 e 6,35.

Pressuposições do Modelo de Regressão Linear Clássico




- Normalidade dos resíduos
- Independência das observações
- Homogeneidade de Variâncias



Análise de resíduo e diagnóstico



Análise de resíduo e diagnóstico



Normalidade dos resíduos

- Testes de Hipóteses para verificar a normalidade.
 - Exemplos: Shapiro-Wilk (shapiro.test), Kolmogorov-Smirnov (ks.test)
 - Gráficos quantil-quantil com envelope simulado.

Homogeneidade de Variâncias

- Testes de Hipóteses para verificar homocedasticidade
- Gráficos exploratórios dos resíduos: Resíduos vs variáveis explicativas

Independência das observações

- Gráficos exploratórios dos resíduos e planejamento amostral

Outros pontos importante:

- Valores influentes
- Comparação de modelos

Regressão Múltipla


- Predizer valores de uma variável dependente (Y) em função de variáveis independentes ($X_1, X_2, \dots, X_k$).
- Conhecer o quanto variações de X_j ($j = 1, \dots, k$) podem afetar Y .

Regressão Múltipla

$$(X_1, X_2, \dots, X_k) \quad \Rightarrow \quad Y$$

Aplicação no mercado mobiliário (avaliação) :

X_1 = área construída
 X_2 = distância do centro




Y = preço do imóvel

Regressão Múltipla

$$(X_1, X_2, \dots, X_k) \quad \Rightarrow \quad Y$$

Aplicação na ciência da computação:

X_1 = memória RAM
 X_2 = sistema operacional
 X_3 = tipo de processador



Y = tempo de resposta

Modelo de Regressão Múltipla

$$E[Y] = f(X_1, X_2, \dots, X_k)$$

Linear: $E[Y] = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_k X_k$

Em que $Y, X_1, \dots, X_k$ podem representar as variáveis originais ou transformadas.

Admite-se que $X_1, \dots, X_k$ são variáveis matemáticas e Y é uma variável aleatória.

Modelo de Regressão Múltipla

$$E[Y] = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_k X_k$$

O coeficiente β_k representa a variação esperada de Y para cada unidade de variação em X_k ($k = 1, 2, \dots, k$), considerando as outras variáveis independentes fixas.

O primeiro objetivo é estimar os coeficientes: $\beta_0, \beta_1, \beta_2, \dots, \beta_k$.

Modelo de Regressão Múltipla

AMOSTRA:

obs.	variáveis				
	Y	X ₁	X ₂	...	X _k
1	y ₁	x ₁₁	x ₁₂	...	x _{1k}
2	y ₂	x ₂₁	x ₂₂	...	x _{2k}
...	...	...	...	...	...
n	y _n	x _{n1}	x _{n2}	...	x _{nk}

- $E\{y_i\} = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_k x_{ik}$

- $y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_k x_{ik} + e_i$

termo
aleatório
(erro)

Modelo de Regressão Múltipla

Suposições

- $y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_k x_{ik} + e_i$ 

termo
aleatório
(erro)
- Os erros (e_i) são independentes e variam aleatoriamente segundo uma distribuição (normal) com média zero e variância constante.

Exemplo com regressão linear simples

$$\mathbf{Y} = \mathbf{X} \boldsymbol{\beta} + \boldsymbol{\varepsilon}$$
$$\begin{bmatrix} 98 \\ 110 \\ 112 \\ 115 \\ 122 \end{bmatrix} = \begin{bmatrix} 1 & 20 \\ 1 & 25 \\ 1 & 30 \\ 1 & 35 \\ 1 & 40 \end{bmatrix} \begin{bmatrix} \beta_0 \\ \beta_1 \end{bmatrix} + \begin{bmatrix} e_1 \\ e_2 \\ e_3 \\ e_4 \\ e_5 \end{bmatrix}$$

Exemplo com regressão linear múltipla

i	x_{1i}	x_{2i}	y_i
1	20	70	98
2	25	68	110
3	30	83	112
4	35	77	115
5	40	65	122

Exemplo com regressão linear múltipla

$$\mathbf{Y} = \mathbf{X} \boldsymbol{\beta} + \boldsymbol{\varepsilon}$$

$$\begin{bmatrix} 98 \\ 110 \\ 112 \\ 115 \\ 122 \end{bmatrix} = \begin{bmatrix} 1 & 20 & 70 \\ 1 & 25 & 68 \\ 1 & 30 & 83 \\ 1 & 35 & 77 \\ 1 & 40 & 65 \end{bmatrix} \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{bmatrix} + \begin{bmatrix} e_1 \\ e_2 \\ e_3 \\ e_4 \\ e_5 \end{bmatrix}$$

Modelos lineares:

Estimador de mínimos quadrados

$$Y = X\beta + \varepsilon$$

Estimador de mínimos quadrados de β , isto é, o vetor b que minimiza a função $L(\beta) = \varepsilon'\varepsilon = (Y - X\beta)'(Y - X\beta)$:



$$b = (X'X)^{-1}(X'Y)$$

$$b = (b_0, b_1, \dots, b_k)'$$

Regressão Múltipla

Equação de regressão ajustada aos dados:

$$\hat{y} = b_0 + b_1X_1 + b_2X_2 + \dots + b_kX_k$$

Valores preditos:

$$\hat{y}_i = b_0 + b_1x_{i1} + b_2x_{i2} + \dots + b_kx_{ik}$$

Resíduos:

$$\hat{e}_i = y_i - \hat{y}_i$$

(estimativa da) variância do erro:

$$s_e^2 = \frac{1}{n-k-1} \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \frac{SQE}{n-k-1}$$

Medida do Ajuste

Coeficiente de determinação (R^2)

$$R^2 = \frac{\text{Variação explicada}}{\text{Variação total}} = \frac{\sum (\hat{y}_i - \bar{y})^2}{\sum (y_i - \bar{y})^2}$$

$$0 \leq R^2 \leq 1$$

Coef. de correlação múltiplo (R):
coef. de correlação entre y_i e $\hat{y}_i$

Regressão Múltipla: *teste sobre o modelo*

$$E[Y] = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_k X_k$$

$$H_0: \beta_1 = \beta_2 = \dots = \beta_k = 0$$

$$SQE = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

$$SQT = \sum_{i=1}^n (y_i - \bar{y})^2$$

$$SQR = SQT - SQE$$

$$f = \frac{SQR / k}{SQE / (n - k - 1)}$$

Sob H_0 e considerando as suposições

do modelo, f tem distrib. F com g.l. k (no num.) e $(n-k-1)$ (no denom.)

Ex. de regressão múltipla:

O sistema de entrega de um distribuidor de cervejas

Pretende-se prever o tempo (y) requerido para se fazer um lote de entregas. O Eng. de produção encarregado de fazer o estudo sugere que o tempo é influenciado fundamentalmente por dois fatores: o número de entregas (x_1) e a distância máxima (x_2) que o entregador precisa fazer por viagem.

Sistema de entrega do distribuidor de cerveja

ENTREGAS	DISTANC	TEMPO	
(X1)	(X2)	(Y)	
1	10	30	24
2	15	25	27
3	10	40	29
4	20	18	31
5	25	22	25
6	18	31	33
7	12	26	26
8	14	34	28
9	16	29	31
10	22	37	39
11	24	20	33
12	17	25	30
13	13	27	25
14	30	23	42
15	24	33	40

Métodos de Seleção de Variáveis

Determinar quantos termos (variáveis explanatórias) são necessários na estrutura linear para uma descrição razoável dos dados?

- Muitas variáveis → boa explicação porém com complexidade de interpretação;
- Poucas variáveis → fácil interpretação mas pobre em termos de qualidade de ajuste.
- **Busca por um modelo parcimonioso.**
- Existem diversas estratégias para seleção de variáveis e também vários critérios que podem ser utilizados para seleção, veremos apenas alguns.

Critérios de Seleção

- Critérios de Seleção: qual estatística você vai monitorar para selecionar um modelo;
 - Critérios de Informação (AIC e BIC):

$$AIC = -2\ln(L) + 2p$$

$$BIC = -2\ln(L) + \ln(np)$$

em que: L é o máximo da função de verossimilhança.

Métodos de Seleção de Variáveis

- Métodos básicos de seleção:
 - Todas as regressões possíveis;
 - Método do passo atrás: Backward;
 - Método do passo a frente: Forward;
 - Método do passo a frente passo atrás: Stepwise;
- o número de (e quais) variáveis explanatórias no modelo final pode variar dependendo do método e critério utilizados.

Métodos de Seleção de Variáveis

- Todas as regressões possíveis: suponha que temos k covariáveis disponíveis: ajustar o modelo nulo (apenas β_0) e os modelos com 1, 2, 3, ..., até k covariáveis.
 - Dividir os modelos em classes:
 - Classe A: Modelo nulo (0 covariáveis);
 - Classe B: Todos os modelos com 1 covariável;
 - Classe C: Todos os modelos com 2 covariáveis;
 - ...
 - Classe Z: Modelo com k covariáveis.
 - Ordenar os modelos em cada classe, de acordo com um dos critérios;
 - Escolher o “melhor” modelo dentro de cada classe;
 - Selecionar o modelo, a partir do qual, o nível do critério varia pouco quando aumenta o número de covariáveis.

Métodos de Seleção de Variáveis

- Método do passo atrás (Backward):
 - Ajustar o modelo completo (K covariáveis) e retirá-las uma a uma de acordo com algum critério de parada → Estatística F
 - Exemplo: 3 covariáveis (X_1, X_2 e X_3)
 - **Primeiro passo:** Ajustar o modelo completo
$$Y_i = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \varepsilon_i$$
A partir do ajuste deste modelos obter:
$$SQRes_c \rightarrow \text{Soma de quadrados do Resíduo do modelo completo}$$
$$gl_c = n - p \rightarrow \text{graus de liberdade do resíduo do modelo completo}$$

Métodos de Seleção de Variáveis

- Método do passo atrás (Backward):
 - Ajustar o modelo completo (K covariáveis) e retirá-las uma a uma de acordo com algum critério de parada → Estatística F
 - Exemplo: 3 covariáveis (X_1, X_2 e X_3)

- **Segundo passo:** Ajustar os modelos reduzidos (retirando uma covariável de cada vez)

$$Y_i = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \varepsilon_i$$

$$Y_i = \beta_0 + \beta_1 X_1 + \beta_3 X_3 + \varepsilon_i$$

$$Y_i = \beta_0 + \beta_2 X_2 + \beta_3 X_3 + \varepsilon_i$$

$$F_c = \frac{SQRes_r - SQRes_c}{QMRes_c}$$

Selecionar o modelo com o menor valor de F_c para comparar com um quantil da dist. F → $F_{saída} = F_{\gamma;1,gl_c}$

Métodos de Seleção de Variáveis

- Método do passo atrás (Backward):
 - Ajustar o modelo completo (K covariáveis) e retirá-las uma a uma de acordo com algum critério de parada → Estatística F
 - Exemplo: 3 covariáveis (X_1, X_2 e X_3)
 - **Segundo passo:**
 H_0 : modelo reduzido versus H_a : modelo completo
- Regra de decisão:
- Se $F_{\min} > F_{saída}$, rejeita-se a H_0 → não elimina nenhuma variável
 - Se $F_{\min} < F_{saída}$, não rejeita a H_0 → elimina a variável em questão e volta ao passo 1 com esse modelo sendo o modelo completo

Métodos de Seleção de Variáveis

- Método do passo a frente (Forward):
 - Ajustar o modelo nulo (0 covariáveis) ou um modelo com apenas uma covariável (qual?)
 - A covariável inicial é aquela com maior correlação simples com a variável Y;
 - Avalia a necessidade de inclusão das demais covariáveis de acordo com algum critério → Estatística F

Métodos de Seleção de Variáveis

- Método do passo a frente (Forward):
 - Exemplo: 3 covariáveis (X_1, X_2 e X_3)
 - **Primeiro passo:** Ajustar o modelo reduzido (Supondo a variável X_1 a de maior correlação com Y)

$$Y_i = \beta_0 + \beta_1 X_1 + \varepsilon_i$$

Para este modelo (reduzido) obter a $SQRes_r$ e $gl_r = n - p = n - 2$.

Métodos de Seleção de Variáveis

- Método do passo atrás (Backward):
 - Ajustar o modelo completo (K covariáveis) e retirá-las uma a uma de acordo com algum critério de parada → Estatística F
 - Exemplo: 3 covariáveis (X_1, X_2 e X_3)
 - **Primeiro passo:** Ajustar o modelo completo
$$Y_i = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \varepsilon_i$$
A partir do ajuste deste modelos obter:
$$SQRes_c \rightarrow \text{Soma de quadrados do Resíduo do modelo completo}$$
$$gl_c = n - p \rightarrow \text{graus de liberdade do resíduo do modelo completo}$$

Métodos de Seleção de Variáveis

- Método do passo atrás (Backward):
 - Ajustar o modelo completo (K covariáveis) e retirá-las uma a uma de acordo com algum critério de parada → Estatística F
 - Exemplo: 3 covariáveis (X_1, X_2 e X_3)
 - **Segundo passo:** Ajustar os modelos reduzidos (retirando uma covariável de cada vez)

$$Y_i = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \varepsilon_i$$

$$Y_i = \beta_0 + \beta_1 X_1 + \beta_3 X_3 + \varepsilon_i$$

$$Y_i = \beta_0 + \beta_2 X_2 + \beta_3 X_3 + \varepsilon_i$$

$$F_c = \frac{SQRes_r - SQRes_c}{QMRes_c}$$

Selecionar o modelo com o menor valor de F_c para comparar com um quantil da dist. F → $F_{saída} = F_{\gamma;1,gl_c}$

Métodos de Seleção de Variáveis

- Método do passo atrás (Backward):
 - Ajustar o modelo completo (K covariáveis) e retirá-las uma a uma de acordo com algum critério de parada → Estatística F
 - Exemplo: 3 covariáveis (X_1, X_2 e X_3)
 - **Segundo passo:**
 H_0 : modelo reduzido versus H_a : modelo completo

Regra de decisão:
 - Se $F_{\min} > F_{saída}$, rejeita-se a $H_0 \rightarrow$ não elimina nenhuma variável
 - Se $F_{\min} < F_{saída}$, não rejeita a $H_0 \rightarrow$ elimina a variável em questão e volta ao passo 1 com esse modelo sendo o modelo completo

Métodos de Seleção de Variáveis

- Método do passo a frente (Forward):
 - Ajustar o modelo nulo (0 covariáveis) ou um modelo com apenas uma covariável (qual?)
 - A covariável inicial é aquela com maior correlação simples com a variável Y;
 - Avalia a necessidade de inclusão das demais covariáveis de acordo com algum critério → Estatística F

Métodos de Seleção de Variáveis

- Método do passo a frente (Forward):
 - Exemplo: 3 covariáveis (X_1, X_2 e X_3)
 - **Primeiro passo:** Ajustar o modelo reduzido (Supondo a variável X_1 a de maior correlação com Y)

$$Y_i = \beta_0 + \beta_1 X_1 + \varepsilon_i$$

Para este modelo (reduzido) obter a $SQRes_r$ e $gl_r = n - p = n - 2$.

Métodos de Seleção de Variáveis

- Método do passo a frente (Forward):
 - Exemplo: 3 covariáveis (X_1, X_2 e X_3)
 - **Segundo passo:** Ajustar os modelos completos (em relação ao modelo do passo 1) incluindo uma covariável de cada vez

$$Y_i = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \varepsilon_i$$

$$Y_i = \beta_0 + \beta_1 X_1 + \beta_3 X_3 + \varepsilon_i$$

Para cada modelo (completo) obter a $SQRes_c$, $gl_c = n - p$ e
Calcular a estatística F_c

$$F_c = \frac{SQRes_r - SQRes_c}{QMRes_c}$$

Selecionar o modelo com o maior valor de F_c para comparar com um quantil da dist.

$$F \rightarrow F_{\text{entrada}} = F_{\gamma; 1, gl_c}$$

Métodos de Seleção de Variáveis

- Método do passo a frente (Forward):

- Exemplo: 3 covariáveis (X_1, X_2 e X_3)

- **Segundo passo:**

H_0 : modelo reduzido versus H_a : modelo completo

Regra de decisão:

- Se $F_{máx} > F_{entrada}$, rejeita-se a $H_0 \rightarrow$ inclui a variável em questão no modelo e volta ao passo 1 com esse modelo sendo o modelo reduzido
- Se $F_{máx} < F_{entrada}$, não rejeita a $H_0 \rightarrow$ não inclui nenhuma variável no modelo (além da inicial, neste exemplo a X_1).

Métodos de Seleção de Variáveis

- Método do passo a frente passo atrás (Stepwise):
 - É uma mistura dos dois métodos anteriores, começando com o Forward
 - Faremos um exemplo!
- Importante ter em mente que:
 - a) Diferentes combinações de critérios/métodos nem sempre levam a mesma seleção de variáveis, pois diferentes modelos podem ter ajustes equivalentes;
 - b) Nenhuma combinação de critérios/métodos pode garantir que o “melhor” modelo foi obtido

Exemplo:

Um experimento para avaliar quais dos elementos químicos: $X_1=\text{N}$, $X_2=\text{P}$, $X_3=\text{K}$, $X_4=\text{CA}$, $X_5=\text{MG}$, $X_6=\text{S}$ influenciam na granulometria do solo, obteve-se os dados apresentados a seguir, onde $Y = \%$ terra retida na peneira 18.

Fazer a análise de regressão linear múltipla, fazendo a seleção do modelo pelo método Backward.

X1	X2	X3	X4	X5	X6	Y
2,92	0,53	1,40	0,06	0,12	0,21	17,54
2,75	0,52	1,45	0,08	0,13	0,22	5,08
2,78	0,51	1,52	0,09	0,13	0,20	6,90
2,73	0,52	1,53	0,09	0,13	0,21	19,34
2,45	0,47	1,55	0,14	0,14	0,20	4,57
2,89	0,48	1,49	0,12	0,14	0,20	7,28
2,98	0,53	1,52	0,07	0,12	0,22	9,40
2,78	0,51	1,42	0,07	0,13	0,20	15,66
2,32	0,48	1,50	0,10	0,13	0,20	10,76
2,87	0,49	1,51	0,08	0,13	0,21	13,94