

INE5633 - Introdução à Redes Neurais

Rodrigo Rodrigues

Universidade Federal de Santa Catarina

1. Conceitos
2. Funcionamento de uma CNN
3. Parâmetros de uma rede neural

Objetivos

Introdução aos seguintes tópicos:

1. Redes Neurais Convolucionais (CNN);
2. Funções de ativação, acurácia da rede e função de erro;
3. Trabalho prático.

Contextualização




Figure: Extraído de <https://medium.com/alumnaiacademy/introduction-to-computer-vision-4fc2a2ba9dc>

Contextualização

1. Redes Neurais Convolucionais são usadas na área de visão computacional para o processamento e análise de imagens digitais
 - 1.1 Detecção de objetos;
 - 1.2 Classificação de objetos;
 - 1.3 Veículos autônomos, detecção facial, laudos;
 - 1.4 Carro chefe do deep learning.

Representação de uma imagem




Figure: Representação de uma imagem como matriz

Representação de uma imagem

1. Uma imagem digital é representada através de uma matriz;
2. Cada elemento representa um pixel;
3. O valor de um pixel corresponde aos valores das intensidades dos canais RGB.

Representação de uma imagem




Figure: RGB em uma matriz - 8 bits para cada intensidade de cor.

Parte intuitiva - Classificação de imagens



Figure: Sonic e Mario.

Modelar as principais diferenças entre o Mario e o Sonic


1. Formato da cabeça;
2. Orelhas;
3. Nariz ou focinho;
4. Iterar sobre as imagens e mapear as cores.

Modelagem de classificação de objetos

1. Criar um dataset com as principais características;
2. Rotular as imagens:
 - 2.1 0.99, 0.88, 0.343, 0, 0, 0, ..., Mario;
 - 2.2 0, 0, 0, 0.96, 0.85, 0.99, ..., Sonic.
3. Alimentar a rede neural com as principais características;

Classificação de dígitos

1. Leitura de pixel a pixel;
2. Definir vetor de entrada da rede neural.



Entrada da rede neural

1. Matriz 5×5 ;
2. 0, 1, 1, 1, 0, 0, 1, 0, 1, 0, 0, 1, 1, 1, 0, 0, 0, 0, 1, 0, 0, 1, 1, 1, 0 - 9 ;
3. Vetor é usado para alimentar a entrada de uma rede.

Quais são as principais limitações da abordagem com extrator de características e da leitura de todos os pixels de uma imagem?

Limitações

1. Abordagem 1: nem sempre é uma tarefa fácil construir um extrator. É possível que alguma coisa possa ficar de fora;
2. Abordagem 2: ler todos os pixels pode não ser eficiente em casos do mundo real. Resoluções atuais de 2000x1500 pixels usando os canais RGB teriam que ser usadas como entrada de uma NN.


1. Conceitos
2. Funcionamento de uma CNN
3. Parâmetros de uma rede neural

Redes Neurais Convolucionais

É uma rede neural tradicional, porém:

1. Transforma os dados na camada de entrada. Isso evita que todos os dados de uma imagem sejam usados como entrada.
2. Automatiza a descoberta das características mais relevantes de uma imagem.

Exemplo de uma CNN



Redes Neurais Convolucionais

1. Etapa 1 - Operação de convolução;
2. Etapa 2 - Pooling;
3. Etapa 3 - Flattening;
4. Etapa 4 - Rede neural densa.

Etapa 2 - Operação de convolução

Definição: É o processo de adicionar cada elemento da imagem para seus vizinhos, ponderado por um kernel.

Etapa 1 - Operação de convolução - Explicação

1. Operação de multiplicação entre a matriz de entrada e um kernel (matriz);
2. Kernel - é usado para aplicar efeitos (desfoque, sharpening, delinear bordas e etc) em uma determinada imagem;
3. <https://setosa.io/ev/image-kernels/>

Etapa 1 - Operação de convolução - Explicação




Figure: Operação de convolução - Matriz 5x5 e kernel 3x3

$$2*1 + 4*2 + 9*3 + 2*(-4) + 1*7 + 4*4 + 1*2 + 1*(-5) + 2*1 = 51$$

Etapa 1 - Operação de convolução - Explicação




Figure: Operação de convolução - Matriz 5x5 e kernel 3x3

$$4*1 + 9*2 + 1*3 + 1*(-4) + 4*7 + 4*4 + 1*2 + 2*(-5) + 9*1 = 66$$

Etapa 1 - Operação de convolução - Explicação




Figure: Operação de convolução - Matriz 5x5 e kernel 3x3

$$2*1 + 9*2 + 2*3 + 5*(-4) + 1*7 + 3*4 + 4*2 + 8*(-5) + 5*1 = -2$$

Etapa 1 - Operação de convolução

1. Facilita o processamento - imagem fica menor;
2. Detecta as principais partes da imagem (existe o risco de algo ser perdido);
3. As principais características da imagem são preservadas.

Etapa 1 - Operação de convolução

1. Na prática teremos uma imagem e várias aplicações de kernels;
2. O resultado é um conjunto de mapas de características, também conhecido como camada de convolução;
3. A rede pode decidir qual detector de características deverá ser usado!

Etapa 2 - Pooling

1. Abstração de uma matriz;
2. Diminuir ainda mais a dimensão da matriz resultante da operação de convolução;
3. Etapa usada para obter os valores mais expressivos de uma determinada região.

Etapa 2 - Pooling - exemplo

21	59	37	-19	2
30	51	66	20	43
-14	31	49	101	-19
59	15	53	-2	21
49	57	64	76	10

Convolved
Feature

59			

Max Pooled
Feature

Etapa 2 - Pooling - exemplo

21	59	37	-19	2
30	51	66	20	43
-14	31	49	101	-19
59	15	53	-2	21
49	57	64	76	10

Convolved
Feature

59	66		

Max Pooled
Feature

Etapa 2 - Pooling - exemplo

21	59	37	-19	2
30	51	66	20	43
-14	31	49	101	-19
59	15	53	-2	21
49	57	64	76	10

Convolved
Feature

59	66	66	43
51	66	101	101
59	53	101	101
59	64	76	76

Max Pooled
Feature

Etapa 2 - Pooling

1. Deslocamento da janela e tamanho do pooling podem ser customizados;
2. Deslocamento é conhecido como stride;
3. Podemos usar uma função de ativação para obter mais características relevantes
4. A função de ativação pode ser usada no fim da etapa 1 ou no fim da etapa 2;

ReLU como uma função de ativação

1. ReLU (rectified linear unit) - $\max(0, x)$;
2. Exemplo:
 - 2.1 Se o valor obtido do neurônio for 2.4, então a saída da função de ativação será 2.4.
 - 2.2 Se o valor obtido for -5 , então a saída será 0.
3. **Deixa mais evidente mudanças na imagem;**
4. Menor custo computacional e traz resultados parecido de outras funções de ativação;

Imagem original



Figure: Imagem original

Exemplo de imagem após uso da ReLU




Figure: Imagem após aplicação da ReLU

ReLU vs Sigmoid vs Tanh

1. Sigmoid e Tanh possuem o termo e^{-z} e e^{-2z} ;
2. Isso é computacionalmente caro!
3. Ambas possuem uma convergência lenta em comparação com a ReLU;
4. ReLU - Treinamento mais rápido.

Etapa 3 - Flattening - Achatamento

Consiste em transformar a matriz em um vetor. Esse vetor é usado para alimentar a entrada de uma rede neural.



Visualização da CNN

Visualização
CNN Explainer

1. Conceitos
2. Funcionamento de uma CNN
3. Parâmetros de uma rede neural

Performance da rede

1. Erro/Perda: Métrica para avaliar a qualidade dos parâmetros aprendidos durante a etapa de treinamento, como por exemplo, os pesos;
2. Acurácia: porcentagem de vezes que o modelo acerta. Comparação do valor obtido pela rede e do valor definido no dataset;
3. Objetivo é tentar minimizar o erro/perda e aumentar a acurácia.

Parâmetros - batch size e época

1. Batch size: Quantidade de entradas que serão passadas para a rede;
2. Época: processamento de todos os dados de entradas;
3. 1000 entradas;
4. batch size = 10 - rede irá processar 10 entradas por vez e atualizar seus pesos;
5. 100 batches para executar uma época completa.

Como escolher os valores para o batch size?

Como escolher os valores para o batch size?

1. Keras - valor default 32;
2. Quanto maior o batch size, mais rápido o treinamento, porém, é necessário mais memória;
3. Valores maiores podem afetar a generalização da rede;
4. Deve ser testado com base no dataset e poder computacional disponível;

Como escolher a quantidade de épocas?

Como escolher a quantidade de épocas?

1. Valor ideal depende muito da complexidade do dataset;
2. Um bom valor inicial é três vezes o número de colunas do dataset;
3. Aumentar a quantidade e verificar impacto na acurácia e erro
 - 3.1 Se performance estiver melhorando ao final do treinamento, aumentar a quantidade de épocas;
 - 3.2 Se performance estiver estável ao final do treinamento, diminuir a quantidade de épocas.
4. No Keras existe o EarlyStopping que pode auxiliar em achar o valor ideal!

Conclusões

1. CNN é usada para análise de imagens digitais
2. Uma CNN consiste em manipular os aspectos da imagem através da convolução, pooling e flattening;
3. Resultado das etapas anteriores são usados como entrada de uma NN;
4. Parâmetros da rede desempenham um papel importante nos resultados;
5. Funções de ativação, épocas e batch size necessitam de um entendimento do dataset e da arquitetura utilizada;

Trabalho prático

1. Treinamento de duas redes neurais para:
 - 1.1 Reconhecimento de números;
 - 1.2 Reconhecimento de roupas e calçados.
2. Duas arquiteturas de redes neurais;
3. Objetivo: realizar conjunto de experimentos e verificar o impacto no resultado;

Referências



Convolutional Neural Networks — A Beginner's Guide

<https://towardsdatascience.com/convolution-neural-networks-a-beginners-guide-implementing-a-mnist-hand-written-digit-8aa60330d022>



An Interactive Node-Link Visualization of Convolutional Neural Networks

https://adamharley.com/nn_vis/



Redes neurais convolucionais

<https://www.udemy.com/course/formacao-deep-learning-pytorch-pytho>



Convolutional Neural Networks (CNN): Step 1(b) - ReLU Layer

<https://www.superdatascience.com/blogs/convolutional-neural-networks-cnn-step-1b-relu-layer>



Activation Functions


<https://www.v7labs.com/blog/neural-networks-activation-functions>



Batch Size in Neural Networks

<https://deeplizard.com/learn/video/U4WB9p6ODjM>

Relembrando: Função de ativação




Papel de uma função de ativação

1. Define se um neurônio deve ser ativado ou não, ou seja, decide se a entrada de um neurônio é importante ou não através da aplicação de operações matemáticas;
2. Existem diferentes tipos de funções de ativação e seu uso está atrelado ao cenário de aplicação.
3. Linear x Não-linear;

Tipos de funções de ativação - Binária

Se o valor obtido no nodo for maior que um limiar, então ele é ativado.



1. $f(x) = c * x$
2. Pontos positivos:
 - 2.1 Resultado não está em um intervalo entre 0 e 1.
 - 2.2 Permite resolver problemas de regressão.

Funções de ativação não lineares

1. Funções não lineares permitem modelar mapeamentos complexos entre uma entrada e saída.
2. Modelagens mais complexas através da adição de mais camadas.





Figure: Definição de uma função não linear

Sigmoid




Sigmoid

1. Saída modela probabilidade entre 0 e 1;
2. Valores muito negativos são convertidos para valores próximos de 0 e valores muito positivos para 1;
3. Valor 0 é convertido para 0.5, que representa um limiar de pertencimento de uma entrada a dois tipos de classes.

Sigomoid

1. No passado era utilizada nas camadas ocultas;
2. Pode ser aplicada na camada de saída para a modelagem de uma classificação binária (pertencimento ou não a uma classe);
3. Problemas de eficiência computacional por conta do termo e^z ;
4. Convergência lenta.


Tangente hiperbólica



Tangente hiperbólica


1. Saída entre -1 e $+1$;
2. Vantagem no processo de otimização;
3. Usada como função de ativação das camadas ocultas de algumas redes;
4. Não é usada na camada de saída!
5. Ainda possui o termo e^z , que é computacionalmente caro!

ReLU - Rectified Linear Unit



1. Computacionalmente barata e representa um importante avanço na área;
2. Rápida convergência e processo de aprendizagem;
3. É a função de ativação default para as camadas ocultas de MLPs e CNNs;
4. Não é usada na camada de saída!
5. Ponto negativo é que valores positivos podem afetar o desempenho durante o treinamento da rede;

Leaky ReLU




Leaky ReLU

1. Se o valor é maior que 0, então a saída da função é igual a ReLU;
2. Se o valor for menor que 0, então a saída será um valor negativo pequeno;
3. Na ReLU esses valores negativos afetam a habilidade de treinamento do modelo;
4. Mesma aplicação que o ReLU (camadas ocultas);
5. Possíveis problemas com a predição de entradas negativas.

Parametric ReLU

1. Uma outra variação da ReLU;
2. O α é um parâmetro que é aprendido;
3. O valor de α é usado em cada neurônio da rede.

ReLU6



1. ReLU permite positivos grandes para entradas positivas;
2. ReLU6 restringe esse valor para 6;

$$\textit{Softmax}(z_i) = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}}$$

1. Calcula a probabilidade de um evento pertencer a um conjunto de classes;
2. Essa função de ativação é usada na camada de saída de um problema de classificação com diversas classes;
3. Probabilidade de um animal pertencer às seguintes classes: gato (0.01), cachorro (0.96), macaco (0.02) e elefante (0.01).