



6. Coleta, Preparação e Análise de Dados para Modelagem e Simulação

6.1 Introdução

Nos capítulos anteriores, o problema foi formulado, o sistema foi descrito e especificado, o modelo conceitual foi construído e o paradigma de modelagem foi escolhido. Além disso, já se discutiu que a escolha da linguagem, do ambiente e do simulador deve ser subordinada ao tipo de representação desejada e aos objetivos do estudo. Falta, entretanto, uma etapa sem a qual o modelo permanece apenas estruturalmente correto, mas operacionalmente frágil: a definição disciplinada dos dados que alimentarão a simulação.

Esse ponto é central porque um modelo conceitualmente elegante pode produzir conclusões ruins se suas entradas forem mal especificadas. De modo correspondente, um modelo relativamente simples pode tornar-se extremamente útil quando é alimentado por dados consistentes, interpretados corretamente e compatíveis com a semântica do sistema estudado. Em outras palavras, a qualidade de um estudo de simulação depende não apenas da estrutura lógica do modelo, mas também da forma como o mundo real é traduzido em parâmetros, distribuições, séries, condições iniciais, regras e entradas exógenas.

Deve-se observar, entretanto, que esta etapa não se limita à mera coleta de números. O problema não é apenas obter dados, mas decidir *quais* dados são relevantes, *como* devem

ser medidos, *em que escala* devem ser organizados, *que tipo de variabilidade* carregam, *que dependências* apresentam e *como* serão transformados em entradas do modelo. Essa transformação exige interpretação técnica, análise estatística e cuidado metodológico. Por essa razão, a coleta e o tratamento dos dados não devem ser vistos como atividade auxiliar, mas como parte constitutiva da própria modelagem.

Também é importante delimitar o escopo deste capítulo. Aqui serão discutidos os dados desde sua obtenção até sua representação final como entradas do modelo. Isso inclui qualidade, limpeza, preparação, estatística descritiva, análise exploratória, dependência temporal, ajuste de distribuições e formas de mapear essas representações para o simulador. Contudo, este capítulo não tratará da infraestrutura algorítmica interna usada pelos simuladores para gerar números pseudoaleatórios e amostras de distribuições. Esse tema será apresentado separadamente no Anexo III, pois, embora seja essencial para a execução da simulação estocástica, não pertence diretamente à lógica metodológica da coleta e análise de dados de entrada.

A figura 6.1 resume o encadeamento tratado neste capítulo. Ela mostra que os dados saem do sistema real, passam por preparação, análise, seleção de representação e só então se tornam parâmetros, distribuições ou séries incorporáveis ao modelo.




Figura 6.1: Fluxo metodológico da transformação de dados observados em entradas utilizáveis pelo modelo de simulação.

6.2 Função dos dados em um estudo de simulação

Dados podem participar de um estudo de simulação de diferentes maneiras, e essa distinção precisa ser explícita desde o início. Uma primeira função é **descrever o sistema**. Nessa função, os dados ajudam a compreender como o sistema opera, que ordens de grandeza estão envolvidas, que variáveis parecem relevantes e que regimes de comportamento podem existir. Uma segunda função é **parametrizar o modelo**. Aqui, os dados servem para atribuir valores a parâmetros, selecionar distribuições, definir condições iniciais, estimar taxas, estabelecer regras probabilísticas ou representar séries temporais. Uma terceira função é **avaliar a credibilidade do modelo**, pois dados observados do sistema também são necessários para validação e, em alguns casos, calibração.

Essa tripla função é metodologicamente importante porque evita confundir todos os dados do projeto como se servissem para o mesmo propósito. Um conjunto de observações suficientemente rico para descrever o sistema pode ainda ser insuficiente para ajustar uma distribuição com segurança. De modo análogo, dados usados para parametrização podem não ser adequados para validação, sobretudo quando provêm exatamente do mesmo recorte temporal ou do mesmo cenário operacional usado na construção do modelo. Em estudos mais maduros, convém tratar explicitamente essas funções e, quando possível, separar conjuntos ou papéis distintos de dados.

Além disso, dados não são neutros. Eles carregam métodos de medição, unidades, granularidade temporal, convenções de registro, possíveis erros de instrumento, critérios de arredondamento e filtros já aplicados por sistemas de informação. Por isso, inserir um conjunto de dados em um simulador sem examinar sua origem e significado equivale, em muitos casos, a transferir para o modelo uma estrutura implícita que não foi criticamente avaliada. O problema não é apenas estatístico, mas semântico.

6.3 Planejamento da coleta de dados

A coleta de dados precisa ser planejada de forma compatível com o problema formulado e com o modelo que se pretende construir. Não é metodologicamente adequado começar por recolher “todo dado disponível” para depois decidir o que é útil. Essa estratégia tende a produzir acúmulo desorganizado de informações, aumentando custo analítico sem garantir ganho real de qualidade. O ponto de partida mais robusto é o conjunto de perguntas do estudo e as variáveis que, segundo o modelo conceitual, devem ser observadas ou estimadas.

6.3.1 Definição das necessidades de dados

A primeira tarefa consiste em explicitar que dados são necessários, com que precisão, em que unidade, com que resolução temporal e com que finalidade no modelo. Tempos entre chegadas, tempos de atendimento, tempos de falha, tempos de reparo, volumes de demanda, níveis de estoque, parâmetros físicos, sequências de estados, sinais de sensores e medições laboratoriais são exemplos de entradas que podem aparecer em estudos distintos. O ponto

importante é que essas variáveis não devem ser listadas apenas nominalmente; precisam ser ligadas ao papel que desempenharão no modelo.

Essa ligação é o que permite avaliar se a coleta será viável. Em alguns casos, a variável desejada já existe em base histórica. Em outros, precisa ser inferida a partir de registros indiretos. Em outros ainda, sua coleta exigirá instrumentação adicional, observação de campo ou experimentação específica. Essa diferença afeta cronograma, custo e nível de confiança nos dados que serão obtidos.

6.3.2 Fontes de dados

As fontes de dados podem ser classificadas, de forma geral, em quatro grupos: medição direta, registros operacionais, literatura especializada e julgamento de especialistas. Medição direta tende a ser a fonte mais valiosa quando se deseja forte aderência ao sistema específico em estudo, mas nem sempre é operacionalmente possível. Registros operacionais, por sua vez, costumam ser abundantes, porém frequentemente foram produzidos para fins administrativos ou de controle e não para fins de modelagem, o que exige cuidado adicional na interpretação.

Dados de literatura são especialmente úteis quando o sistema ainda não existe, quando se trabalha em fase preliminar de projeto ou quando se quer obter ordens de grandeza plausíveis para parâmetros físicos, biológicos ou operacionais. O julgamento de especialistas, embora mais subjetivo, pode ser indispensável em fases iniciais, em sistemas raros ou em situações em que não há dados observacionais disponíveis. Em todos esses casos, a fonte deve ser documentada explicitamente, juntamente com suas limitações e com a justificativa de uso.

6.3.3 Escala temporal, resolução e amostragem

Uma decisão metodológica frequentemente negligenciada é a escala temporal em que os dados são observados e armazenados. Uma variável registrada minuto a minuto pode revelar padrões invisíveis em médias horárias; por outro lado, registros excessivamente finos podem introduzir ruído irrelevante quando o modelo opera em escala mais agregada. Portanto, a resolução dos dados precisa ser compatível com a escala temporal do fenômeno e com o nível de abstração do modelo.

Esse ponto é particularmente relevante em séries temporais, em chegadas não estacionárias e em sistemas com múltiplos regimes operacionais. Em muitos contextos, a questão central não é apenas a média da variável, mas a forma como ela varia ao longo do tempo. Se essa estrutura temporal for perdida na agregação, o modelo poderá reproduzir adequadamente o valor médio e, ainda assim, falhar em representar congestionamentos, picos, sazonalidades ou períodos críticos.

6.4 Qualidade, consistência e preparação dos dados

Coletar dados não significa ainda poder usá-los. Antes de qualquer análise mais profunda, os dados precisam ser examinados quanto a qualidade, completude, consistência semântica e adequação ao estudo. Essa preparação é particularmente importante em projetos de simulação porque muitas variáveis são posteriormente usadas como entradas probabilísticas, e pequenos problemas de consistência podem produzir efeitos significativos no comportamento do modelo.

6.4.1 Inconsistências, ausências e valores extremos

Problemas comuns incluem registros duplicados, unidades inconsistentes, valores faltantes, observações fora do domínio físico possível e erros de codificação. Em alguns casos, essas anomalias decorrem de falhas de medição; em outros, de transformação indevida entre sistemas, de arredondamentos, de erros humanos ou de mudanças de convenção ao longo do tempo.

Valores extremos merecem atenção especial. Um valor extremo pode ser erro de medição, mas pode também corresponder a evento raro operacionalmente importante. Eliminar automaticamente observações extremas apenas porque parecem “estranhas” é metodologicamente perigoso. A decisão deve sempre considerar contexto operacional, mecanismo provável de geração do dado e impacto potencial sobre o modelo.

6.4.2 Padronização, limpeza e documentação

A preparação dos dados também inclui padronização de unidades, tratamento de formatos, alinhamento temporal entre fontes distintas, identificação clara de variáveis e documentação do que foi modificado. Em projetos bem conduzidos, cada transformação relevante deve ser registrável: que observações foram removidas, que valores faltantes foram tratados e por quê, que agregações foram realizadas, que filtros foram aplicados e em que ordem.

Essa documentação não é burocracia inútil. Ela sustenta rastreabilidade, reprodutibilidade e capacidade de auditoria metodológica. Em projetos de simulação com várias iterações, é comum voltar aos dados para revisar hipóteses ou reparametrizar partes do modelo. Sem registro adequado, esse retorno torna-se inseguro.

6.4.3 Segmentação e regimes operacionais

Nem todo conjunto de dados deve ser tratado como homogêneo. Em muitos sistemas, o comportamento varia conforme turno, dia da semana, estação do ano, tipo de entidade, classe de operação ou condição externa. Nesses casos, misturar tudo em uma única amostra pode produzir uma distribuição média estatisticamente estável, porém fenomenologicamente artificial.

Segmentar dados por regimes operacionais é, portanto, uma decisão metodológica importante. Isso não significa necessariamente multiplicar modelos ou distribuições sem critério,

mas reconhecer que diferentes partes do horizonte observado podem corresponder a mecanismos diferentes. A segmentação adequada frequentemente melhora mais a fidelidade do modelo do que o ajuste sofisticado de uma única família probabilística sobre uma amostra mal misturada.

Exemplo 6.1 Explique por que a eliminação automática de todos os valores extremos de uma amostra pode comprometer a qualidade do modelo de simulação.

Solução: Porque valores extremos podem representar eventos raros reais e operacionalmente relevantes, como congestionamentos atípicos, falhas, atrasos excepcionais ou regimes críticos. Eliminá-los sem análise pode reduzir artificialmente a variabilidade do sistema e tornar o modelo excessivamente otimista ou pouco realista. ■

6.5 Análise exploratória dos dados

Depois de preparados e documentados, os dados devem ser analisados exploratoriamente. O objetivo dessa etapa não é ainda decidir definitivamente a representação das entradas, mas compreender estrutura, variabilidade, concentração, assimetria, presença de regimes, possíveis dependências e compatibilidade com hipóteses simplificadoras frequentemente adotadas em simulação.

6.5.1 Medidas descritivas

Medidas como média, mediana, moda, quartis, variância, desvio-padrão, coeficiente de variação e medidas de assimetria continuam sendo ferramentas indispensáveis. Elas ajudam a quantificar posição central, dispersão e forma geral da amostra, e permitem comparar variáveis ou subconjuntos de dados de maneira objetiva.

Em termos formais, se $x_1, \dots, x_n$ representam uma amostra observada, então a média amostral e a variância amostral podem ser escritas como

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad \text{e} \quad s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2.$$

Também é útil calcular o coeficiente de variação

$$CV = \frac{s}{\bar{x}},$$

pois ele expressa dispersão relativa e facilita comparações entre variáveis em escalas distintas.

Essas medidas, entretanto, não devem ser interpretadas isoladamente. Duas amostras podem ter a mesma média e variância e ainda assim possuir comportamentos muito diferentes em termos de assimetria, caudas, multimodalidade ou organização temporal. Portanto, estatísticas descritivas são necessárias, mas não suficientes.

6.5.2 Análise visual

A análise visual é componente indispensável da investigação exploratória. Histogramas, *box-plots*, funções empíricas acumuladas, gráficos quantil-quantil e gráficos temporais frequentemente revelam padrões que medidas numéricas resumidas ocultam. Em simulação, isso é especialmente importante porque a forma da variabilidade muitas vezes influencia o comportamento do sistema tanto quanto seu valor médio.

Os histogramas, por exemplo, ajudam a identificar suporte, assimetria e multimodalidade. Já os gráficos temporais ajudam a reconhecer tendência, sazonalidade, dependência serial, mudanças de regime e estruturas não estacionárias. *Boxplots* podem ser úteis para comparar rapidamente subconjuntos operacionais diferentes, como turnos ou tipos de entidade.

Contudo, representações visuais também exigem cuidado. A forma aparente de um histograma depende da escolha das classes, e diferentes escalas temporais podem sugerir leituras distintas do mesmo processo. Por isso, a análise visual deve ser combinada com leitura fenomenológica do sistema e com medidas numéricas apropriadas.

6.6 Representação probabilística e temporal das entradas

Uma vez compreendida a estrutura geral dos dados, o passo seguinte consiste em decidir como a entrada será representada no modelo. Essa decisão pode assumir diferentes formas. Em alguns casos, a entrada será tratada como constante. Em outros, como distribuição de probabilidade paramétrica. Em outros ainda, como distribuição empírica, tabela de valores, série temporal, função do tempo ou mecanismo condicional associado ao tipo de entidade, ao estado do sistema ou ao período operacional.

Essa pluralidade é metodologicamente importante porque impede reduzir o tratamento de entradas ao simples ajuste de uma distribuição em todos os casos. A representação correta depende da natureza da variável e do papel que ela desempenha no modelo.

6.6.1 Distribuições de probabilidade candidatas

Quando a entrada é naturalmente tratada como variável aleatória e a hipótese de independência temporal local é aceitável, distribuições de probabilidade tornam-se uma representação conveniente. A escolha da família candidata deve ser guiada por compatibilidade entre suporte, forma dos dados e plausibilidade do processo. Tempos e durações, por exemplo, exigem distribuições predominantemente positivas. Contagens exigem suporte discreto. Proporções podem exigir suporte limitado.

As figuras 6.2, 6.3 e 6.4 apresentam famílias frequentemente usadas em simulação.

A distribuição exponencial continua importante para tempos entre chegadas associados a processos de Poisson homogêneos. Famílias como gamma, Erlang, Weibull e lognormal são




Figura 6.2: Algumas distribuições contínuas frequentemente empregadas em simulação: normal, lognormal, Weibull, gamma, beta e triangular.




Figura 6.3: Outras famílias contínuas relevantes em modelagem e simulação: Erlang, qui-quadrado, t de Student e F.




Figura 6.4: Distribuições discretas frequentemente utilizadas em simulação: binomial e geométrica.

úteis para tempos positivos com diferentes graus de assimetria e dispersão. A normal pode ser aceitável para variáveis aproximadamente simétricas e afastadas da região negativa. A triangular pode ser útil quando se conhecem apenas mínimo, máximo e valor mais provável.

6.6.2 Distribuições empíricas

Nem sempre uma família paramétrica simples representa adequadamente os dados. Amostras multimodais, fortemente truncadas, segmentadas por regimes ou produzidas por processos compostos podem ser melhor tratadas por distribuições empíricas. Essas distribuições são particularmente úteis em fases iniciais do projeto e em contextos em que se deseja preservar a forma observada dos dados sem impor estrutura paramétrica excessiva.

Entretanto, distribuições empíricas também exigem cautela. Elas dependem fortemente da representatividade da amostra e não substituem a interpretação fenomenológica do processo. Em alguns casos, o aparente fracasso das distribuições teóricas não indica que o processo seja “intrinsecamente empírico”, mas que os dados ainda não foram corretamente segmentados ou que variáveis explicativas importantes estão ocultas.

6.6.3 Tabelas, séries e funções do tempo

Quando há não estacionariedade, sazonalidade, tendência ou dependência temporal forte, a representação por uma única distribuição estacionária pode ser inadequada. Nessas situações, torna-se mais apropriado usar séries temporais, funções por partes, tabelas de taxa ou segmentação do horizonte em intervalos aproximadamente homogêneos.

Se a taxa de chegada varia ao longo do tempo, por exemplo, pode ser mais correto modelar

$$\lambda = \lambda(t),$$

do que usar apenas um valor médio global. A figura 6.5 destaca esse contraste entre processo variável no tempo e sua média agregada.

Essa decisão é importante porque muitos problemas operacionais são determinados não pela média global da demanda, mas por sua organização temporal. Congestionamentos, filas máximas e violações de nível de serviço costumam depender de picos locais muito mais do que de médias agregadas.

6.6.4 Dependência temporal e correlação entre variáveis

Outro cuidado importante é não assumir independência automaticamente. Duas sequências podem ter o mesmo histograma e a mesma média e, ainda assim, exigir tratamentos distintos se uma delas apresentar forte autocorrelação e a outra não. Em situações análogas, duas variáveis marginais ajustadas corretamente podem produzir combinações artificialmente improváveis se a correlação entre elas for ignorada.




Figura 6.5: Exemplo conceitual de processo de chegada não estacionário comparado com uma taxa média constante.

Isso significa que a representação das entradas deve preservar, quando relevante, não apenas distribuições marginais, mas também estrutura temporal e dependência conjunta. Em alguns casos, isso exigirá modelagem condicional, vetores correlacionados, séries multivariadas ou reamostragem estruturada. Em outros, bastará reconhecer que certas simplificações foram adotadas e discutir seu impacto potencial.

Exemplo 6.2 Explique por que duas sequências de dados podem ter o mesmo histograma e, ainda assim, exigir representações diferentes em simulação.

Solução: Porque o histograma descreve apenas a distribuição marginal dos valores, e não sua organização temporal. Duas sequências podem ter mesma forma marginal, mas uma ser praticamente independente e a outra apresentar forte autocorrelação, tendência ou regime alternante. Se o comportamento do sistema depende dessa estrutura temporal, a representação das duas entradas não pode ser a mesma. ■

6.7 Ajuste de distribuições e avaliação de aderência

Quando se opta por representação paramétrica, é necessário ajustar quantitativamente as distribuições candidatas aos dados observados. O objetivo dessa etapa não é descobrir a “verdadeira” distribuição do processo em sentido absoluto, mas encontrar uma representação suficientemente adequada para o uso no modelo de simulação.

6.7.1 Estimação de parâmetros

Toda distribuição paramétrica depende de um conjunto finito de parâmetros. Esses parâmetros podem ser estimados por métodos como método dos momentos e máxima verossimilhança. Em termos práticos, ferramentas computacionais realizam esses cálculos automaticamente,

mas o modelador deve compreender o sentido do que está sendo estimado.

Por exemplo, para a distribuição exponencial com parâmetro λ , o estimador de máxima verossimilhança é

$$\hat{\lambda} = \frac{1}{\bar{x}},$$

onde $\bar{x}$ é a média amostral. Para a distribuição normal, estimadores usuais são

$$\hat{\mu} = \bar{x} \quad \text{e} \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2.$$

Em distribuições mais flexíveis, como Weibull e gamma, a estimação pode exigir métodos numéricos.

Exemplo 6.3 Uma amostra de tempos entre chegadas possui média de 4,2 minutos. Admitindo, como hipótese inicial, uma distribuição exponencial, estime o parâmetro λ .

Solução: Para a distribuição exponencial,

$$\hat{\lambda} = \frac{1}{\bar{x}} = \frac{1}{4,2} \approx 0,2381.$$

Logo, a taxa estimada é de aproximadamente 0,2381 chegadas por minuto. ■

6.7.2 Aderência estatística e plausibilidade fenomenológica

O ajuste não deve ser avaliado apenas por aparência visual nem apenas por um único teste estatístico. Histogramas com curvas superpostas, funções empíricas e acumuladas teóricas, testes de aderência e medidas de distância são todos úteis. Contudo, aderência estatística e plausibilidade fenomenológica não são a mesma coisa.

Uma distribuição pode ser estatisticamente compatível com a amostra e ainda assim ser operacionalmente inadequada. Uma densidade que atribua probabilidade relevante a valores negativos, por exemplo, pode ser conceitualmente imprópria para tempos de serviço, mesmo que o teste formal não a descarte em determinada amostra. Em simulação, essa distinção é crucial: o objetivo não é vencer um teste, mas representar de forma coerente o fenômeno real.

6.7.3 Escolha final da representação

A escolha final entre distribuição paramétrica, distribuição empírica, tabela, série temporal ou função do tempo deve resultar da integração entre análise estatística, conhecimento do sistema e finalidade do estudo. Não existe regra única. Em alguns casos, uma distribuição teórica simples é metodologicamente suficiente e operacionalmente elegante. Em outros, a fidelidade exigida ao comportamento observado justifica representação mais rica.

O importante é que a decisão seja documentada. Deve-se registrar que dados foram

usados, que famílias foram testadas, que critérios orientaram a escolha e que limitações permanecem. Esse registro será valioso para futura verificação, validação e revisão do modelo.

6.8 Do dado observado ao parâmetro do simulador

Uma vez decidida a forma final de representação, ainda é necessário realizar a tradução metodologicamente correta entre a variável observada e o elemento do modelo ao qual ela será associada. Esse passo é frequentemente subestimado. Contudo, uma distribuição estatisticamente adequada pode ser operacionalmente mal utilizada se for associada ao componente errado, na unidade errada ou sem considerar o contexto da sua observação.

A figura 6.6 resume esse encadeamento.




Figura 6.6: Da variável observada no sistema real ao parâmetro efetivamente usado no simulador.

Tempos entre chegadas devem ser associados ao mecanismo que gera entidades. Tempos de processamento devem ser associados a atividades ou atrasos específicos. Taxas de falha e reparo devem ser vinculadas aos mecanismos correspondentes de indisponibilidade. Probabilidades de roteamento devem ser associadas a decisões internas do fluxo do modelo. Além disso, a unidade usada nos dados deve coincidir com a unidade de tempo, espaço, massa ou energia efetivamente adotada no simulador.

Esse mapeamento é também o ponto em que o modelador precisa decidir se a representação será fixa, amostrada, dependente do tempo ou dependente do estado. Assim, a tradução da análise estatística para o simulador não é puramente sintática; ela continua sendo uma decisão de modelagem.

6.9 Ferramentas de apoio à análise de dados

A análise de dados de entrada pode ser operacionalizada por diferentes ambientes computacionais. Nesta obra, duas classes de ferramenta merecem destaque. A primeira é composta por ambientes de análise programável, como Scilab, Python ou R, que permitem leitura, limpeza, estatística descritiva, visualização e prototipação explícita de rotinas analíticas. A segunda é composta por ferramentas especializadas de ajuste de entrada, como o Input Analyzer do Arena, particularmente úteis para seleção e ajuste de distribuições candidatas.

O uso dessas ferramentas não altera a lógica metodológica discutida ao longo do capítulo. Elas apenas oferecem suporte computacional para torná-la mais eficiente, mais transparente ou mais automatizável. Mesmo quando uma ferramenta calcula parâmetros e testes automaticamente, o julgamento final sobre a adequação da representação continua sendo responsabilidade do modelador.

A figura 6.7 organiza esse papel auxiliar das ferramentas.




Figura 6.7: Fluxo integrado de apoio computacional à preparação e análise de dados para modelagem e simulação.

Exemplo 6.4 Considere uma amostra de tempos entre chegadas observados em um sistema real. Descreva um procedimento completo para transformá-la em entrada utilizável por um modelo de simulação, sem discutir ainda a geração interna das amostras pelo simulador.

Solução: Um procedimento metodologicamente consistente pode ser organizado nas seguintes etapas: importar os dados; verificar consistência e unidades; realizar limpeza e documentação das transformações; produzir estatísticas descritivas e gráficos exploratórios; segmentar a amostra, se necessário; selecionar representações candidatas compatíveis com o fenômeno; ajustar parâmetros ou construir representação empírica; avaliar aderência e plausibilidade; escolher a representação final; traduzir essa representação para o componente correto do modelo; e documentar origem, critérios de escolha e forma de uso no simulador. ■

6.10 Considerações Finais

Este capítulo procurou mostrar que a coleta, a preparação e a análise de dados de entrada são parte estruturante do projeto de simulação. Os dados não servem apenas para preencher parâmetros; eles ajudam a compreender o sistema, a definir escalas relevantes de observação, a sustentar escolhas de modelagem e a dar credibilidade ao estudo. Por isso, a qualidade do modelo depende fortemente da forma como os dados são obtidos, tratados, segmentados, analisados e traduzidos para a semântica do simulador.

Também se discutiu que a representação das entradas não se reduz, em todos os casos, ao ajuste de uma distribuição isolada. Dependência temporal, não estacionariedade, correlação entre variáveis, regimes operacionais distintos e limitações semânticas do processo observado podem exigir séries, funções do tempo, tabelas ou representações empíricas. Assim, o trata-

mento de dados precisa ser simultaneamente estatístico e fenomenológico, isto é, orientado tanto por medidas numéricas quanto pelo significado operacional do sistema.

Por fim, o capítulo foi deliberadamente encerrado na etapa em que a entrada já está metodologicamente definida para uso no modelo, mas ainda sem discutir os algoritmos internos pelos quais o simulador produzirá amostras compatíveis com essas especificações. Esse passo pertence à infraestrutura computacional da simulação estocástica e será tratado no Anexo III, dedicado à geração de números pseudoaleatórios e de variáveis aleatórias que seguem distribuições de probabilidade.

6.11 Resumo

Seção 6.1 Introdução

- A qualidade de um estudo de simulação depende não apenas da estrutura lógica do modelo, mas também da forma como o sistema real é traduzido em entradas utilizáveis.
- Este capítulo trata os dados desde sua obtenção até sua representação final como parâmetros, distribuições, séries ou funções de entrada do modelo.
- A geração interna de números pseudoaleatórios e de variáveis aleatórias não faz parte do escopo principal deste capítulo.

Seção 6.2 Função dos dados em um estudo de simulação

- Dados podem ser usados para compreender o sistema, parametrizar o modelo e avaliar sua credibilidade.
- Diferentes funções dos dados exigem tratamento metodológico distinto e, quando possível, separação explícita de papéis.
- A interpretação semântica da origem, da unidade e do contexto dos dados é tão importante quanto sua manipulação estatística.

Seção 6.3 Planejamento da coleta de dados

- A coleta deve ser planejada em função das perguntas do estudo e do papel futuro das variáveis no modelo.
- Fontes de dados incluem medição direta, registros operacionais, literatura especializada e julgamento de especialistas.
- Resolução temporal, granularidade e escala de observação precisam ser compatíveis com a dinâmica do fenômeno e com o nível de abstração do modelo.

Seção 6.4 Qualidade, consistência e preparação dos dados

- Antes da análise, os dados devem ser verificados quanto a inconsistências, ausências, valores extremos e problemas de unidade ou codificação.
- A limpeza e a padronização dos dados precisam ser documentadas para preservar rastreabilidade e reprodutibilidade.
- Segmentação por regimes operacionais pode ser mais importante para a fidelidade do modelo do que o ajuste sofisticado de uma única distribuição global.

Seção 6.5 Análise exploratória dos dados

- Estatísticas descritivas ajudam a quantificar posição central, dispersão e forma, mas não substituem análise estrutural mais profunda.
- Histogramas, *boxplots*, funções empíricas e gráficos temporais são ferramentas centrais de diagnóstico.
- A interpretação correta da variabilidade depende da combinação entre análise numérica, análise visual e conhecimento do processo observado.

Seção 6.6 Representação probabilística e temporal das entradas

- Entradas podem ser representadas por distribuições paramétricas, distribuições empíricas, tabelas, séries temporais ou funções do tempo.
- A escolha da representação depende do suporte da variável, da forma dos dados, da plausibilidade fenomenológica e da dinâmica temporal do processo.
- Não estacionariedade e correlação podem tornar inadequada a hipótese simplificadora de entradas independentes e identicamente distribuídas.

Seção 6.7 Ajuste de distribuições e avaliação de aderência

- O ajuste de distribuições envolve estimação de parâmetros e avaliação de compatibilidade entre dados observados e famílias candidatas.
- Aderência estatística e plausibilidade fenomenológica são dimensões complementares e não devem ser confundidas.
- A escolha final da representação precisa ser documentada e justificada em função do propósito do estudo.

Seção 6.8 Do dado observado ao parâmetro do simulador

- A variável observada no sistema real precisa ser corretamente associada ao elemento correspondente do modelo de simulação.
- Distribuições, séries e parâmetros podem ser operacionalmente mal utilizados se ligados ao componente errado, à unidade errada ou ao regime errado.
- A tradução das entradas para o simulador continua sendo uma decisão de modelagem e não apenas um ajuste sintático.

Seção 6.9 Ferramentas de apoio à análise de dados

- Ambientes de análise programável e ferramentas especializadas de ajuste de entrada ajudam a operacionalizar a metodologia discutida no capítulo.
- Essas ferramentas não substituem o julgamento técnico do modelador, mas tornam mais eficiente a leitura, a inspeção, o ajuste e a documentação dos dados.
- O uso de ferramentas deve preservar transparência metodológica e rastreabilidade das decisões tomadas.

6.12 Exercícios Propostos

Conceituação

Exercício 6.1 Explique a diferença entre dados usados para compreensão do sistema, dados usados para parametrização do modelo e dados usados para validação do modelo.

Exercício 6.2 Discuta por que substituir uma variável aleatória de entrada por seu valor médio pode comprometer fortemente a validade de um estudo de simulação.

Exercício 6.3 Explique por que o tratamento de dados de entrada em simulação precisa ser simultaneamente estatístico e fenomenológico.

Exercício 6.4 Discuta por que uma distribuição estatisticamente bem ajustada pode ainda assim ser inadequada para representar certo processo real.

Exercício 6.5 Explique a diferença entre uma entrada representada por distribuição estacionária, por série temporal e por função do tempo.

Aplicação

Exercício 6.6 Considere um sistema de atendimento com registros de tempos entre chegadas e tempos de serviço. Descreva um procedimento completo para decidir como cada uma dessas variáveis deve ser representada no modelo.

Exercício 6.7 Escolha um sistema de sua área de interesse e liste que dados precisariam ser coletados para parametrizar um primeiro modelo de simulação.

Exercício 6.8 Para um conjunto de dados hipotético com forte variação entre turnos, explique como você decidiria se deve usar uma única distribuição global ou segmentar os dados por regimes operacionais.

Exercício 6.9 Considere uma amostra de tempos de processamento com valores extremamente altos em poucos casos. Discuta como você investigaria se esses valores são erro, ruído ou eventos raros reais.

Exercício 6.10 Escolha uma variável de entrada relevante em um problema de simulação e descreva como ela seria mapeada do sistema real para o componente correspondente do simulador.

Investigação

Exercício 6.11 Pesquise um caso real de estudo de simulação em que a má qualidade ou a má interpretação dos dados de entrada comprometeu os resultados. Analise o que poderia ter sido feito de forma metodologicamente melhor.

Exercício 6.12 Investigue diferentes ferramentas para análise de dados de entrada em simulação e compare suas vantagens e limitações em termos de transparência, automação e controle metodológico.

Exercício 6.13 Escolha uma área de aplicação, como logística, manufatura, redes, saúde, finanças ou bioengenharia, e discuta que tipos de estruturas de entrada são mais comuns nela: distribuições simples, séries temporais, dados correlacionados, tabelas por regime ou outros.

Exercício 6.14 Pesquise um exemplo de processo não estacionário relevante para simulação

e explique por que sua representação por uma única média global seria inadequada.

Exercício 6.15 Explique, com base em um problema real ou plausível, por que a correlação entre variáveis de entrada pode ser decisiva para a fidelidade de um modelo de simulação.

Base bibliográfica do capítulo. Este capítulo se apoia principalmente em [29], [24], [42], [34] e [4] para tratar da coleta, preparação e análise de dados de entrada para simulação, incluindo planejamento da coleta, limpeza, análise exploratória, ajuste de distribuições, avaliação de aderência e tradução dos dados observados em parâmetros utilizáveis pelo modelo. A discussão também dialoga com [46] e [20] na medida em que os dados são apresentados como parte constitutiva da modelagem, e não como simples etapa acessória. No uso de ferramentas de apoio e na transição entre análise estatística e representação operacional das entradas, o capítulo também se apoia na prática consolidada descrita em [42] e [24].

RASCUNHO