



10. Modelagem por Processos Estocásticos e Redes de Filas

10.1 Introdução

Processos estocásticos constituem uma das principais ferramentas matemáticas para descrever sistemas cuja evolução temporal incorpora incerteza, variabilidade e aleatoriedade intrínseca. Diferentemente dos modelos puramente determinísticos, nos quais o estado futuro do sistema é completamente determinado pelo estado presente e pelos parâmetros do modelo, em um processo estocástico a evolução futura é representada probabilisticamente. Em outras palavras, mesmo conhecendo-se o estado atual do sistema, o futuro não é descrito por uma única trajetória possível, mas por um conjunto de trajetórias possíveis, cada uma associada a determinadas probabilidades.

Essa perspectiva é particularmente importante em problemas de engenharia e ciência da computação, pois muitos sistemas reais exibem comportamento essencialmente aleatório. Em redes de computadores, pacotes chegam em instantes não determinísticos, enlaces falham aleatoriamente e mecanismos de retransmissão são acionados de forma dependente do histórico recente do sistema. Em sistemas eletrônicos e de automação, ruído, falhas intermitentes, perdas de comunicação e variações operacionais também possuem natureza probabilística. Em bioengenharia e engenharia bioquímica, processos como ativação gênica, ligação de molé-

culas, variações populacionais de microrganismos e mudanças entre estados metabólicos frequentemente são mais bem descritos por modelos estocásticos do que por modelos puramente determinísticos.

De maneira geral, um processo estocástico pode ser entendido como uma família de variáveis aleatórias indexadas por um parâmetro, usualmente o tempo. Essa visão permite representar a evolução de um sistema como uma sucessão de estados observados ao longo do tempo, preservando explicitamente a incerteza associada a essa evolução. Essa formulação é particularmente útil didaticamente, pois liga diretamente a noção abstrata de processo à ideia concreta de comportamento temporal do sistema.

Uma classificação fundamental dos processos estocásticos considera duas dimensões: a natureza do espaço de estados e a natureza do parâmetro temporal. O espaço de estados pode ser discreto, quando o sistema só pode ocupar um conjunto finito ou enumerável de estados, ou contínuo, quando o estado assume valores em um domínio contínuo. O tempo, por sua vez, pode ser discreto, quando o sistema é observado em instantes igualmente espaçados ou em passos enumeráveis, ou contínuo, quando a evolução pode ser descrita em qualquer instante de um intervalo temporal. Essas duas dimensões dão origem a quatro classes gerais de processos, cada uma adequada a diferentes tipos de sistema e de objetivo de modelagem.

		Tempo	
		Discreto	Contínuo
Espaço de Estados	Discreto	Estados discretos e tempo discreto	Estados discretos e tempo contínuo
	Contínuo	Estados contínuos e tempo discreto	Estados contínuos e tempo contínuo

Tabela 10.1: Classificação geral de processos estocásticos segundo a natureza do espaço de estados e do parâmetro temporal.

No contexto desta obra, a classe de maior interesse imediato é a dos processos com espaço de estados discreto e tempo discreto, em especial as cadeias de Markov. Essa escolha não é casual. Cadeias de Markov oferecem um equilíbrio muito favorável entre expressividade matemática, interpretabilidade e aplicabilidade prática. Elas permitem descrever sistemas com comportamento aleatório, mantendo uma estrutura analítica relativamente simples, fortemente baseada em matrizes de transição, vetores de probabilidade e propriedades assintóticas bem estabelecidas. Além disso, aparecem naturalmente em numerosos problemas de computação e engenharia, como modelos de confiabilidade, disponibilidade, protocolos de comunicação, ocupação de *buffers*, modos operacionais de controladores, degradação de componentes e dinâmica de estados discretizados de sistemas biológicos.

Isso não significa, contudo, que os demais processos sejam irrelevantes. Processos de Poisson ocupam papel central como modelos de contagem e de chegadas aleatórias, sendo particularmente importantes em telecomunicações, filas, tráfego e confiabilidade. Da mesma forma, sistemas de filas podem ser entendidos como aplicações especializadas e extremamente

relevantes de processos estocásticos, sobretudo quando formulados por processos de nascimento e morte. Entretanto, neste capítulo, ambos serão tratados de forma mais sintética e funcional, como extensões importantes ao núcleo conceitual principal, que será dedicado às cadeias de Markov e à sua utilização na modelagem e simulação.

A escolha desse foco também se justifica do ponto de vista pedagógico. Em um livro de modelagem e simulação, o objetivo principal não é apenas apresentar definições abstratas, mas ensinar como construir modelos úteis. Para isso, é mais produtivo concentrar a atenção em um formalismo que permita ao leitor passar rapidamente da formulação matemática à construção de modelos concretos e à realização de simulações. Nesse aspecto, cadeias de Markov são particularmente adequadas: a identificação dos estados, a construção da matriz de transição, o cálculo de distribuições futuras e a simulação computacional podem ser apresentados de forma integrada e operacional.

Convém também distinguir dois modos de uso de processos estocásticos em engenharia. O primeiro é analítico: busca-se obter resultados fechados ou semi-fechados sobre probabilidades de ocupação de estados, tempos médios de permanência, comportamento assintótico ou métricas de desempenho. O segundo é computacional: o processo é utilizado como base para gerar trajetórias simuladas, estimar grandezas de interesse por amostragem e comparar cenários alternativos. Ambos os usos são importantes e complementares. Sempre que possível, este capítulo procurará apresentar os dois: primeiro a formulação matemática do modelo, depois sua interpretação operacional e, em seguida, sua implementação computacional.

Como ilustração inicial, considere o preço de uma ação ao longo do tempo. Embora esse seja um exemplo típico da área financeira, ele é útil para introduzir a ideia de trajetória aleatória. Se a variação diária do preço for modelada como uma variável aleatória, então a sequência de preços observados ao longo de vários dias constitui uma realização do processo estocástico. Cada repetição da simulação produz uma nova trajetória possível. Ainda que esse exemplo utilize um espaço de estados contínuo, ele é didaticamente valioso porque evidencia a diferença entre uma única realização do processo e o conjunto de todas as evoluções possíveis.

?

Figura não encontrada

capitulo10/figs/geraFigura1CenarioProcessoExemploAcao

Figura 10.1: Uma possível realização de um processo estocástico que representa a evolução do preço de uma ação ao longo de um ano. A figura evidencia que uma trajetória observada é apenas uma entre muitas trajetórias possíveis do mesmo processo.

A figura 10.1 representa exatamente esse ponto: uma realização isolada não caracteriza plenamente o processo. Ela mostra apenas um cenário possível entre muitos. Para compreender o comportamento probabilístico do sistema, é necessário considerar um conjunto de trajetórias. Esse raciocínio é central em modelagem e simulação: um experimento computacional não fornece “o” futuro do sistema, mas sim amostras possíveis de seu comportamento.




Figura 10.2: Conjunto de trajetórias possíveis para o mesmo processo estocástico de evolução de preço de ação. A figura mostra explicitamente a variabilidade entre realizações e reforça que a descrição do processo é probabilística, não determinística.

10.2 Processos estocásticos: conceitos essenciais

10.2.1 Espaço de estados e parâmetro temporal

Formalmente, um processo estocástico pode ser definido como uma família de variáveis aleatórias

$$\{X_t\}_{t \in T},$$

em que T é o conjunto de índices temporais, e cada variável aleatória X_t assume valores em um espaço de estados E . Assim, para cada instante t , a variável X_t descreve o estado aleatório do sistema naquele instante.

Do ponto de vista prático, essa definição pode ser interpretada de forma bastante concreta:

- o **parâmetro temporal** indica quando o estado do sistema é observado;
- o **espaço de estados** indica quais valores ou categorias esse estado pode assumir;
- e a família completa $\{X_t\}$ descreve a evolução temporal aleatória do sistema.

Se $T = \{0, 1, 2, \dots\}$, o processo é de tempo discreto. Se $T = [0, \infty)$, o processo é de tempo contínuo. Analogamente, se o espaço de estados E é finito ou enumerável, o processo possui estados discretos. Se $E \subseteq \mathbb{R}^n$, o processo possui estados contínuos.

No contexto deste capítulo, o caso de maior interesse será:

$$T = \{0, 1, 2, \dots\} \quad \text{e} \quad E = \{e_0, e_1, \dots, e_M\},$$

ou seja, processos com tempo discreto e espaço de estados discreto.

Exemplos típicos incluem:

- o estado de disponibilidade de um servidor computacional em ciclos de monitoramento;
- o modo de operação de um controlador embarcado a cada período de amostragem;
- o estado discreto de uma célula, como *inativa*, *ativa* ou *degradada*, em instantes discretizados de observação.

10.2.2 Trajetórias e realizações do processo

Uma **trajetória** ou **realização** de um processo estocástico é uma sequência concreta de estados observados ao longo do tempo, correspondente a uma execução particular do mecanismo aleatório. Se o processo é denotado por $\{X_t\}$, então uma realização é uma função $t \mapsto X_t(\omega)$, para um certo resultado aleatório ω do experimento subjacente.

Em termos práticos, cada simulação computacional do processo produz uma trajetória. Quando o processo é de tempo discreto, essa trajetória assume a forma de uma sequência

$$x_0, x_1, x_2, \dots$$

em que cada x_n é um estado observado no passo n . Se repetirmos a simulação várias vezes, obteremos várias trajetórias possíveis do mesmo processo. O conjunto dessas trajetórias, e não apenas uma trajetória isolada, é o que caracteriza o comportamento probabilístico do sistema.

Essa distinção é metodologicamente importante. Em modelagem e simulação, uma única execução do modelo não deve ser confundida com o comportamento global do processo. O modelo descreve uma distribuição sobre trajetórias possíveis; a simulação produz apenas amostras dessa distribuição.

10.2.3 Distribuições unidimensionais e distribuições finito-dimensionais

Para um instante fixo t , a variável aleatória X_t possui uma distribuição de probabilidade. Essa distribuição é chamada **distribuição unidimensional** do processo no instante t . Em um processo com espaço de estados discreto, ela pode ser representada por um vetor de probabilidades

$$\mu_t = (P(X_t = e_0), P(X_t = e_1), \dots, P(X_t = e_M)),$$

caso o espaço de estados seja $E = \{e_0, e_1, \dots, e_M\}$.

Mais geralmente, para instantes $t_1 < t_2 < \dots < t_k$, a distribuição conjunta do vetor aleatório

$$(X_{t_1}, X_{t_2}, \dots, X_{t_k})$$

é chamada **distribuição finito-dimensional** do processo. Essa distribuição contém informação muito mais rica do que as distribuições unidimensionais isoladas, porque descreve dependências temporais entre os estados observados em diferentes instantes.

Do ponto de vista prático, isso significa que não basta saber apenas a probabilidade de o sistema estar em determinado estado em um instante. Em muitos problemas, é necessário saber como a ocupação de estados em um instante influencia a ocupação futura, isto é, como o processo evolui ao longo do tempo. Esse é justamente o aspecto que torna cadeias de Markov tão importantes: elas oferecem uma estrutura simples para representar essa dependência temporal.

10.2.4 Esperança, variância e interpretação física

Como cada X_t é uma variável aleatória, podem ser definidos, para cada instante t , o valor esperado $E[X_t]$, a variância $Var(X_t)$ e outras estatísticas de interesse. Quando o estado do sistema é representado por números com interpretação quantitativa direta, essas grandezas podem ter significado físico imediato. Por exemplo:

- em um processo de contagem, $E[X_t]$ pode representar o número médio de eventos até o instante t ;
- em um sistema de filas, $E[X_t]$ pode representar o número médio de clientes no sistema no instante t ;
- em um sistema de confiabilidade com estados codificados numericamente, a esperança pode fornecer um resumo global do grau médio de degradação.

Contudo, em processos com estados discretos puramente qualitativos, como *operacional*, *degradado* e *falho*, a interpretação mais natural não é via média numérica do estado, mas via vetor de probabilidades dos estados possíveis. Por isso, neste capítulo, trabalharemos principalmente com distribuições de probabilidade e matrizes de transição, e não com médias de valores de estado.

10.2.5 A propriedade de Markov

O conceito central deste capítulo é a **propriedade de Markov**. Intuitivamente, ela estabelece que, conhecido o estado presente do sistema, o futuro é independente do passado mais remoto. Em termos conceituais, isso significa que o estado atual resume toda a informação relevante do histórico para fins de previsão probabilística do próximo comportamento do sistema.

Em um processo de tempo discreto, essa propriedade pode ser escrita como

$$P(X_{n+1} = j \mid X_n = i, X_{n-1} = i_{n-1}, \dots, X_0 = i_0) = P(X_{n+1} = j \mid X_n = i),$$

para todos os estados admissíveis e todos os instantes n .

Essa fórmula não afirma que o passado seja irrelevante para o sistema real. Ela afirma apenas que, dentro do modelo, o estado presente foi definido de maneira suficientemente rica para condensar toda a informação relevante do passado. Essa observação é extremamente importante em modelagem. A hipótese markoviana não é uma verdade absoluta sobre o sistema real; ela é uma hipótese de modelagem, cuja adequação depende de como os estados foram definidos.

Por exemplo, em um modelo simples de disponibilidade de um servidor, pode-se usar os estados

$$E = \{\text{operacional, degradado, falho}\}.$$

Se a probabilidade futura de falha depender apenas de qual desses três estados o servidor ocupa agora, então a hipótese de Markov é razoável. Mas, se essa probabilidade também depender fortemente do tempo já gasto no estado atual ou do número acumulado de falhas anteriores, então talvez seja necessário enriquecer o espaço de estados para preservar a propriedade de Markov no modelo.

Essa observação leva a uma diretriz prática importante:

um bom modelo markoviano não é apenas aquele que usa uma matriz de transição, mas aquele em que os estados foram definidos de tal forma que o presente realmente resume, com aproximação adequada, a informação relevante do passado.

Exemplo 10.1 Considere um equipamento que, a cada ciclo de inspeção, pode estar em um dos estados {normal, degradado, falho}. Suponha que, se hoje ele está em estado *degradado*, a probabilidade de falhar no próximo ciclo é 0,25, independentemente de há quantos ciclos ele já está degradado. Suponha ainda que, se hoje está *normal*, a probabilidade de passar a *degradado* no próximo ciclo é 0,10, e que, se hoje está *falho*, ele permanece falho com probabilidade 1. Escreva uma matriz de transição compatível com esse modelo, assumindo que um equipamento degradado permanece degradado com probabilidade 0,55 e retorna a normal com probabilidade 0,20, enquanto um equipamento normal permanece normal com probabilidade 0,90.

Solução:

Adotando a ordem dos estados (normal, degradado, falho), cada linha da matriz deve conter as probabilidades de transição a partir de um estado atual.

Para o estado *normal*:

$$P(\text{normal} \rightarrow \text{normal}) = 0,90, \quad P(\text{normal} \rightarrow \text{degradado}) = 0,10, \quad P(\text{normal} \rightarrow \text{falho}) = 0.$$

Para o estado *degradado*:

$$P(\text{degradado} \rightarrow \text{normal}) = 0,20, \quad P(\text{degradado} \rightarrow \text{degradado}) = 0,55, \quad P(\text{degradado} \rightarrow \text{falho}) = 0,25$$

Para o estado *falho*:

$$P(\text{falho} \rightarrow \text{normal}) = 0, \quad P(\text{falho} \rightarrow \text{degradado}) = 0, \quad P(\text{falho} \rightarrow \text{falho}) = 1.$$

Logo, a matriz de transição é

$$P = \begin{pmatrix} 0.90 & 0.10 & 0.00 \\ 0.20 & 0.55 & 0.25 \\ 0.00 & 0.00 & 1.00 \end{pmatrix}.$$

10.2.6 Quando a hipótese de Markov é adequada

A hipótese de Markov é particularmente adequada em situações em que:

- os estados do sistema podem ser definidos em níveis discretos bem identificáveis;
- a evolução do sistema é observada em ciclos, passos ou eventos sucessivos;
- o passado influencia o futuro apenas por meio do estado atual, ou pode ser razoavelmente aproximado dessa forma;
- o objetivo do estudo é analisar probabilidades de ocupação de estados, transições e comportamento assintótico.

Isso ocorre com frequência em aplicações como:

- confiabilidade de sistemas computacionais e eletrônicos;
- protocolos e enlaces de comunicação;
- modos de operação de sistemas embarcados;
- ocupação discreta de *buffers*, servidores ou canais;
- modelos simplificados de expressão gênica e estados metabólicos;
- clientes ou tarefas em sistemas de filas discretizados por eventos ou passos de observação.

Por outro lado, a hipótese pode ser inadequada quando:

- o tempo de permanência no estado atual altera fortemente as probabilidades futuras;
- o passado acumulado carrega informação relevante que não foi codificada no estado atual;
- o sistema possui memória longa ou dependência explícita de trajetória;
- a discretização escolhida destrói características dinâmicas essenciais do sistema.

Nesses casos, existem duas estratégias principais. A primeira é enriquecer o espaço de estados, incorporando ao estado atual informação adicional sobre o passado relevante. A segunda é escolher outro paradigma de modelagem mais adequado. Em muitos problemas práticos, no entanto, uma cadeia de Markov bem construída fornece uma aproximação suficientemente boa para análise e simulação.

10.3 Cadeias de Markov em tempo discreto

Uma **cadeia de Markov em tempo discreto** é um processo estocástico $\{X_n\}_{n \geq 0}$ com espaço de estados discreto que satisfaz a propriedade de Markov. Se o espaço de estados é $E =$

$\{e_0, e_1, \dots, e_M\}$, então a dinâmica da cadeia é completamente determinada, em sua forma mais simples, por:

- uma **distribuição inicial** $\mu^{(0)}$, que informa a probabilidade de ocupação de cada estado no instante inicial;
- e uma **matriz de transição** P , cujos elementos p_{ij} representam a probabilidade de transição do estado e_i para o estado e_j em um único passo.

Assim,

$$p_{ij} = P(X_{n+1} = e_j \mid X_n = e_i),$$

e a matriz P é estocástica por linhas, isto é,

$$p_{ij} \geq 0 \quad \text{e} \quad \sum_{j=0}^M p_{ij} = 1$$

para toda linha i .

10.3.1 Distribuição inicial e evolução temporal

Se a distribuição inicial é

$$\mu^{(0)} = (P(X_0 = e_0), P(X_0 = e_1), \dots, P(X_0 = e_M)),$$

então a distribuição após um passo é obtida por multiplicação matricial:

$$\mu^{(1)} = \mu^{(0)} P.$$

Depois de dois passos,

$$\mu^{(2)} = \mu^{(1)} P = \mu^{(0)} P^2,$$

e, em geral,

$$\mu^{(n)} = \mu^{(0)} P^n.$$

Essa expressão possui grande importância metodológica, porque conecta diretamente a interpretação probabilística do modelo com uma estrutura computacional simples. Uma vez definida a matriz P , toda a evolução das distribuições futuras pode ser obtida por potências sucessivas da matriz.

Do ponto de vista da modelagem, isso significa que a construção da cadeia exige duas decisões centrais:

1. definir corretamente o conjunto de estados;
2. estimar ou justificar corretamente as probabilidades de transição.

Se essas duas etapas forem bem realizadas, a análise do modelo se torna direta: distribuições futuras, ocupações médias e comportamento assintótico passam a ser calculáveis de forma sistemática.

10.3.2 Interpretação da matriz de transição

A matriz de transição não deve ser encarada apenas como artefato algébrico. Cada linha da matriz codifica um conjunto local de regras probabilísticas de evolução a partir de um estado atual. Em outras palavras, a linha i da matriz responde à pergunta: “se o sistema está agora no estado e_i , com que probabilidades ele estará em cada estado possível no próximo passo?”

Isso confere à matriz uma interpretação operacional muito forte. Em um modelo de confiabilidade, uma linha pode descrever as transições entre *operacional*, *degradado* e *falho*. Em um protocolo de comunicação, uma linha pode descrever a evolução entre *transmitindo*, *aguardando confirmação*, *erro* e *retransmissão*. Em um modelo bioquímico discretizado, uma linha pode representar mudanças entre *estado basal*, *estado ativado* e *estado inibido*.

Graficamente, uma cadeia de Markov pode ser representada por um grafo orientado, em que:

- cada nó corresponde a um estado;
- cada aresta orientada $i \rightarrow j$ corresponde a uma transição possível;
- o rótulo da aresta é a probabilidade p_{ij} .

A figura 10.3 mostra um exemplo genérico desse tipo de representação.




Figura 10.3: Representação gráfica de uma cadeia de Markov finita, em que os nós representam estados e as arestas orientadas representam probabilidades de transição em um passo.

10.3.3 Exemplo aplicado: confiabilidade simplificada de um servidor

Considere novamente o modelo simplificado de um servidor com três estados:

$$E = \{\text{Operacional}, \text{Degradoado}, \text{Falho}\}.$$

Suponha a matriz de transição

$$P = \begin{pmatrix} 0.90 & 0.10 & 0.00 \\ 0.20 & 0.55 & 0.25 \\ 0.00 & 0.00 & 1.00 \end{pmatrix}.$$

Se o sistema inicia certamente em *Operacional*, então

$$\mu^{(0)} = (1, 0, 0).$$

Após um passo,

$$\mu^{(1)} = (1, 0, 0) \begin{pmatrix} 0.90 & 0.10 & 0.00 \\ 0.20 & 0.55 & 0.25 \\ 0.00 & 0.00 & 1.00 \end{pmatrix} = (0.90, 0.10, 0.00).$$

Após dois passos,

$$\mu^{(2)} = \mu^{(1)} P = (0.90, 0.10, 0.00) \begin{pmatrix} 0.90 & 0.10 & 0.00 \\ 0.20 & 0.55 & 0.25 \\ 0.00 & 0.00 & 1.00 \end{pmatrix} = (0.83, 0.145, 0.025).$$

Esses números possuem interpretação operacional direta:

- após dois ciclos, a probabilidade de o servidor ainda estar operacional é 0,83;
- a probabilidade de estar degradado é 0,145;
- a probabilidade de já ter falhado é 0,025.

Esse tipo de cálculo é importante porque mostra que o modelo markoviano não serve apenas para gerar trajetórias amostrais. Ele também permite estimar diretamente a distribuição probabilística futura do sistema, o que pode ser extremamente útil em análise de disponibilidade, planejamento de manutenção e projeto de políticas de redundância.

10.4 Transições em múltiplos passos e equações de Chapman-Kolmogorov

10.4.1 Transições em dois passos

Se p_{ij} representa a probabilidade de ir de e_i para e_j em um passo, então a probabilidade de ir de e_i para e_j em dois passos pode ser obtida somando sobre todos os estados intermediários possíveis:

$$p_{ij}^{(2)} = \sum_k p_{ik} p_{kj}.$$

Essa expressão tem interpretação intuitiva clara. Para chegar a e_j em dois passos a partir de e_i , o processo precisa passar, no primeiro passo, por algum estado intermediário e_k . Como esses caminhos são mutuamente exclusivos, suas probabilidades podem ser somadas.

Em notação matricial, isso equivale exatamente ao elemento (i, j) da matriz P^2 .

10.4.2 Equações de Chapman-Kolmogorov

Generalizando o raciocínio anterior, a probabilidade de transição em $n + m$ passos satisfaz

$$p_{ij}^{(n+m)} = \sum_k p_{ik}^{(n)} p_{kj}^{(m)}.$$

Essa relação é conhecida como **equação de Chapman-Kolmogorov**. Em notação matricial,

$$P^{(n+m)} = P^{(n)} P^{(m)}.$$

Quando a cadeia é homogênea no tempo, isto é, quando a mesma matriz P vale em todos os passos,

$$P^{(n)} = P^n.$$

Essa propriedade é central porque transforma a análise temporal da cadeia em problema de potências de matriz. Isso permite tanto interpretação teórica quanto implementação computacional eficiente.

10.4.3 Exemplo aplicado: mudança de estados de um sensor inteligente

Considere um sensor inteligente que, em cada ciclo de diagnóstico, pode estar nos estados

$$E = \{\text{Normal, Ruído, Falha}\}.$$

Suponha a matriz

$$P = \begin{pmatrix} 0.85 & 0.10 & 0.05 \\ 0.30 & 0.50 & 0.20 \\ 0.00 & 0.00 & 1.00 \end{pmatrix}.$$

Se desejamos a probabilidade de o sensor estar em *Falha* após dois passos, iniciando em *Normal*, devemos calcular o elemento correspondente em P^2 . Em vez de multiplicar toda a matriz, podemos usar diretamente Chapman-Kolmogorov:

$$P_{\text{Normal}, \text{Falha}}^{(2)} = P_{\text{Normal}, \text{Normal}} P_{\text{Normal}, \text{Falha}} + P_{\text{Normal}, \text{Ruído}} P_{\text{Ruído}, \text{Falha}} + P_{\text{Normal}, \text{Falha}} P_{\text{Falha}, \text{Falha}}.$$

Substituindo:

$$p_{N,F}^{(2)} = 0.85 \cdot 0.05 + 0.10 \cdot 0.20 + 0.05 \cdot 1 = 0.0425 + 0.02 + 0.05 = 0.1125.$$

Assim, mesmo que a probabilidade de falha em um único passo a partir do estado normal seja apenas 0,05, a probabilidade acumulada em dois passos já sobe para 0,1125, pois também inclui trajetórias intermediárias que passam por *Ruído* e depois chegam a *Falha*.

Exemplo 10.2 Considere a cadeia com matriz

$$P = \begin{pmatrix} 0.7 & 0.3 \\ 0.4 & 0.6 \end{pmatrix}.$$

Calcule a probabilidade de ir do estado 1 ao estado 2 em dois passos e interprete o resultado.

Solução:

A probabilidade de ir do estado 1 ao estado 2 em dois passos é

$$p_{12}^{(2)} = p_{11}p_{12} + p_{12}p_{22}.$$

Substituindo os valores,

$$p_{12}^{(2)} = 0.7 \cdot 0.3 + 0.3 \cdot 0.6 = 0.21 + 0.18 = 0.39.$$

Isso significa que, se o sistema começa no estado 1, a probabilidade de estar no estado 2 exatamente após dois passos é 0,39. Esse valor inclui tanto a trajetória $1 \rightarrow 1 \rightarrow 2$ quanto a trajetória $1 \rightarrow 2 \rightarrow 2$. ■

10.5 Classificação dos estados e comportamento assintótico

A análise de cadeias de Markov não se limita ao cálculo de distribuições em poucos passos. Em muitos problemas, interessa compreender o que acontece no longo prazo. Para isso, é necessário classificar estados e classes de estados quanto à sua conectividade e quanto ao seu papel assintótico.

10.5.1 Acessibilidade e comunicação

Diz-se que um estado j é **acessível** a partir de i se existe algum número $n \geq 0$ tal que

$$p_{ij}^{(n)} > 0.$$

Em outras palavras, há pelo menos um caminho com probabilidade positiva que leve i a j em algum número finito de passos.

Se i é acessível a partir de j e j é acessível a partir de i , então os estados **se comunicam**. Essa relação induz classes de comunicação no espaço de estados.

Essas definições têm importância prática imediata. Em um modelo de disponibilidade, por exemplo, pode ser que um estado de falha total seja acessível a partir de todos os estados normais, mas que o caminho de volta não exista se o modelo não incluir reparo. Nesse caso, a estrutura de comunicação do modelo já revela algo qualitativo importante sobre o sistema.

10.5.2 Estados absorventes e classes fechadas

Um estado i é **absorvente** se

$$p_{ii} = 1.$$

Isso significa que, uma vez atingido, o processo permanece nele para sempre. Estados absorventes aparecem com frequência em modelos de falha irreversível, morte, término de protocolo ou absorção final por alguma condição de encerramento.

Mais geralmente, uma classe de estados é **fechada** se, uma vez que o processo entre nessa classe, não pode mais sair dela. Estados absorventes são um caso particular de classe fechada unitária.

Do ponto de vista da modelagem, a presença de estados absorventes altera fortemente o comportamento assintótico da cadeia. Em muitos casos, significa que, a longo prazo, parte da massa de probabilidade tenderá a se concentrar em tais estados.

10.5.3 Irredutibilidade

Uma cadeia é dita **irredutível** se todos os estados se comunicam entre si. Em termos práticos, isso significa que a cadeia é composta por uma única classe de comunicação.

Irredutibilidade é uma propriedade importante porque simplifica fortemente a análise assintótica. Em cadeias finitas irredutíveis, a existência de distribuição estacionária e o comportamento de longo prazo possuem estrutura particularmente bem comportada, sobretudo quando combinados com aperiocidade.

10.5.4 Periodicidade e aperiocidade

O **período** de um estado i é o máximo divisor comum dos números $n \geq 1$ para os quais

$$p_{ii}^{(n)} > 0.$$

Se esse máximo divisor comum é 1, o estado é dito **aperiódico**. Em cadeias irredutíveis, todos os estados possuem o mesmo período, de modo que faz sentido falar no período da cadeia.

A periodicidade é relevante porque pode impedir convergência ponto a ponto das distribuições $\mu^{(n)}$, mesmo quando existe distribuição estacionária. Em cadeias aperiódicas, essa oscilação estrutural desaparece, e o comportamento assintótico tende a ser mais simples.

10.5.5 Recorrência e transitoriedade

Um estado é **recorrente** se, uma vez visitado, o processo retorna a ele com probabilidade 1. É **transiente** se existe probabilidade positiva de nunca mais voltar a ele após deixá-lo.

Em cadeias finitas, todo estado pertencente a uma classe fechada irredutível é recorrente. Estados fora dessas classes podem ser transientes. Em termos práticos, estados transientes

representam frequentemente regimes de passagem, aquecimento inicial, degradação intermédia ou outros comportamentos não permanentes do sistema.

10.5.6 Distribuições estacionárias

Uma distribuição π é **estacionária** se satisfaz

$$\pi = \pi P, \quad \sum_i \pi_i = 1, \quad \pi_i \geq 0.$$

Isso significa que, se a cadeia começa distribuída segundo π , ela permanece distribuída segundo π após cada passo.

A distribuição estacionária não deve ser interpretada apenas como objeto algébrico. Em muitos modelos, ela representa a distribuição de longo prazo do sistema. Se a cadeia é finita, irredutível e aperiódica, então a distribuição das ocupações converge para π , independentemente da distribuição inicial:

$$\mu^{(n)} \rightarrow \pi \quad \text{quando } n \rightarrow \infty.$$

Essa propriedade é extremamente importante em aplicações, porque permite interpretar π_i como a fração de tempo de longo prazo em que o sistema ocupa o estado i .

10.5.7 Exemplo aplicado: disponibilidade de um enlace de comunicação

Considere um enlace de comunicação com estados

$$E = \{\text{Operacional}, \text{Degradado}, \text{Indisponível}\}$$

e matriz

$$P = \begin{pmatrix} 0.92 & 0.07 & 0.01 \\ 0.30 & 0.50 & 0.20 \\ 0.25 & 0.35 & 0.40 \end{pmatrix}.$$

Como todas as entradas são positivas, a cadeia é irredutível e aperiódica. Portanto, admite distribuição estacionária única. Resolver

$$\pi = \pi P, \quad \pi_1 + \pi_2 + \pi_3 = 1$$

fornece as probabilidades assintóticas de o enlace estar em cada condição.

Esse resultado tem valor operacional direto. Se, por exemplo, $\pi_{\text{Operacional}}$ for elevado, isso indica alta disponibilidade de longo prazo. Se $\pi_{\text{Indisponível}}$ for relevante, o sistema pode requerer redundância, manutenção preventiva ou revisão de arquitetura.

10.5.8 Convergência e significado prático

Quando a cadeia converge para distribuição estacionária, o modelador obtém uma descrição sintética poderosa do comportamento de longo prazo. Isso não elimina a importância das trajetórias individuais nem da evolução transitória, mas acrescenta uma camada de compreensão sobre regimes permanentes e ocupações médias assintóticas.

Em engenharia, essa interpretação é particularmente útil em:

- disponibilidade e confiabilidade;
- tempo médio de ocupação de modos de operação;
- frações de uso de estados de controle;
- desempenho de protocolos discretos;
- análise simplificada de processos biológicos discretizados.

10.6 Modelagem de sistemas por cadeias de Markov

10.6.1 Definição do objetivo do modelo

Antes de definir estados ou probabilidades, é necessário explicitar o objetivo do modelo. Deseja-se estimar disponibilidade? Evolução de modos operacionais? Probabilidade de atingir estado crítico? Regime de longo prazo? Comparação entre cenários? Sem essa definição, a construção da cadeia tende a ser arbitrária.

10.6.2 Escolha do conjunto de estados

A escolha dos estados é a etapa mais importante da modelagem markoviana. Estados muito agregados podem violar a hipótese de Markov, pois deixam de codificar memória relevante do passado. Estados excessivamente detalhados podem produzir explosão combinatória e tornar o modelo pouco interpretável.

Em termos práticos, estados devem ser:

- semanticamente claros;
- mutuamente exclusivos;
- coletivamente exaustivos em relação ao objetivo do estudo;
- suficientemente ricos para sustentar, com boa aproximação, a propriedade de Markov.

10.6.3 Escolha da escala temporal

Como a cadeia é de tempo discreto, é necessário definir o que constitui um passo da evolução. Esse passo pode ser um ciclo de inspeção, uma unidade de tempo discretizada, um instante de decisão, um evento relevante ou outro marco operacional adequado. Se a escala temporal for mal escolhida, o modelo pode introduzir dependências artificiais ou perder informação dinâmica importante.

10.6.4 Determinação da matriz de transição

A matriz de transição pode ser obtida por diferentes estratégias:

- estimação empírica a partir de dados observados;
- julgamento de especialistas;
- derivação a partir de mecanismos físicos ou lógicos simplificados;
- calibração para reproduzir estatísticas observadas do sistema.

Se houver dados suficientes, uma estratégia simples é estimar

$$\hat{p}_{ij} = \frac{N_{ij}}{\sum_j N_{ij}},$$

onde N_{ij} é o número de transições observadas do estado i para o estado j .

10.6.5 Validação do modelo markoviano

Uma cadeia de Markov deve ser validada em dois níveis. O primeiro é estrutural: estados, escala temporal e transições fazem sentido à luz do sistema real? O segundo é comportamental: distribuições futuras, tempos de ocupação ou estatísticas simuladas são compatíveis com o que se conhece do sistema?

Essa validação é especialmente importante porque um modelo markoviano pode ser matematicamente correto e ainda assim representar inadequadamente o fenômeno por ter definido mal seus estados.

10.6.6 Exemplo completo de modelagem: modos operacionais de um controlador embarcado

Considere um controlador embarcado que, a cada ciclo de diagnóstico, pode estar em um dos modos:

$$E = \{\text{Normal}, \text{Sobrecarga}, \text{Recuperação}, \text{Falha}\}.$$

Suponha que:

- em *Normal*, ele permanece normal com probabilidade 0,88, entra em *Sobrecarga* com probabilidade 0,10 e falha diretamente com probabilidade 0,02;
- em *Sobrecarga*, ele vai para *Recuperação* com probabilidade 0,60, permanece em *Sobrecarga* com probabilidade 0,20 e falha com probabilidade 0,20;
- em *Recuperação*, ele retorna a *Normal* com probabilidade 0,70, permanece em *Recuperação* com probabilidade 0,20 e falha com probabilidade 0,10;
- em *Falha*, permanece em *Falha* com probabilidade 1.

A matriz de transição é então

$$P = \begin{pmatrix} 0.88 & 0.10 & 0.00 & 0.02 \\ 0.00 & 0.20 & 0.60 & 0.20 \\ 0.70 & 0.00 & 0.20 & 0.10 \\ 0.00 & 0.00 & 0.00 & 1.00 \end{pmatrix}.$$

Esse modelo pode ser usado para:

- estimar a probabilidade de falha após certo número de ciclos;
- estudar a ocupação dos modos transitórios;
- comparar políticas de recuperação;
- gerar trajetórias amostrais para análise de cenários.

10.7 Simulação de cadeias de Markov

10.7.1 Algoritmo básico de simulação

A simulação de uma cadeia de Markov é conceitualmente simples. Dado um estado inicial, cada novo estado é sorteado de acordo com a linha correspondente da matriz de transição. Em pseudoalgoritmo:

1. escolher X_0 segundo a distribuição inicial $\mu^{(0)}$;
2. para $n = 0, 1, \dots, N - 1$:
 - (a) consultar a linha de P correspondente ao estado atual X_n ;
 - (b) sortear X_{n+1} segundo essa distribuição;
 - (c) registrar a transição.

Do ponto de vista da implementação, isso significa que cada passo da simulação exige apenas uma amostragem categórica sobre a linha adequada da matriz.

10.7.2 Simulação analítica versus simulação amostral

Uma vantagem especial das cadeias de Markov é que elas podem ser estudadas tanto por via analítica quanto por simulação amostral. A via analítica calcula distribuições futuras por $\mu^{(n)} = \mu^{(0)}P^n$. A via amostral gera trajetórias individuais do processo. As duas abordagens são complementares:

- a análise matricial fornece probabilidades exatas ou quase exatas dentro do modelo;
- a simulação produz trajetórias concretas e permite estimar estatísticas por repetição.

Em muitos problemas, vale a pena usar ambas: a primeira para entender a estrutura global do processo e a segunda para interpretar cenários operacionais e validar implementações.

10.7.3 Exemplo de simulação em Python

A listagem 10.1 mostra uma implementação simples de simulação de cadeia de Markov em Python.

```
1  import random
2
3  states = ["Normal", "Overload", "Recovery", "Failure"]
4
5  P = {
6      "Normal": [0.88, 0.10, 0.00, 0.02],
7      "Overload": [0.00, 0.20, 0.60, 0.20],
8      "Recovery": [0.70, 0.00, 0.20, 0.10],
9      "Failure": [0.00, 0.00, 0.00, 1.00]
10 }
11
12 def next_state(current):
13     probs = P[current]
14     return random.choices(states, weights=probs, k=1)[0]
15
16 trajectory = ["Normal"]
17 for _ in range(20):
18     trajectory.append(next_state(trajectory[-1]))
19
20 print(trajectory)
```

Listing 10.1: Simulação simples de uma cadeia de Markov em Python

Esse código é suficiente para gerar uma trajetória amostral do modelo do controlador embarcado descrito anteriormente. A interpretação é direta: cada execução do programa produz uma sequência possível de modos operacionais ao longo do tempo.

10.7.4 Exemplo de modelagem em bioengenharia

Considere uma população celular simplificada em que cada célula pode estar, a cada ciclo de observação, em um dos estados

$$E = \{\text{Basal}, \text{Ativada}, \text{Inibida}\}.$$

Suponha uma matriz

$$P = \begin{pmatrix} 0.70 & 0.20 & 0.10 \\ 0.25 & 0.60 & 0.15 \\ 0.30 & 0.10 & 0.60 \end{pmatrix}.$$

Mesmo sendo um modelo bastante agregado, ele permite estudar:

- a probabilidade de encontrar a célula em cada estado após certo número de ciclos;

- a distribuição estacionária de estados;
- trajetórias individuais em simulações repetidas;
- efeitos de mudanças de parâmetro sobre ocupações de longo prazo.

Esse tipo de abstração é particularmente útil quando o objetivo não é reproduzir toda a dinâmica bioquímica fina, mas estudar alternância probabilística entre modos celulares relevantes.

10.7.5 Comparação entre teoria e simulação

Uma forma didática extremamente valiosa de usar cadeias de Markov é comparar:

- a distribuição teórica $\mu^{(n)}$ obtida por potência de matriz;
- as frequências relativas estimadas por repetição de simulações amostrais.

Se o número de repetições for suficientemente grande, essas frequências tendem a se aproximar das probabilidades teóricas previstas pelo modelo. Essa comparação é importante porque conecta diretamente análise matemática e experimentação computacional, dois eixos centrais desta obra.

10.8 Processo de Poisson

Embora o foco principal deste capítulo recaia sobre processos estocásticos em espaço de estados discreto e, em particular, sobre cadeias de Markov, é conveniente apresentar de forma sintética o **processo de Poisson**, pois ele ocupa posição importante como modelo de contagem aleatória e como ponte conceitual para sistemas de filas, confiabilidade e tráfego.

10.8.1 Definição e interpretação

Um processo de Poisson homogêneo $\{N(t)\}_{t \geq 0}$ com taxa $\lambda > 0$ é um processo estocástico de tempo contínuo e espaço de estados discreto que satisfaz, em sua formulação clássica:

- $N(0) = 0$;
- possui incrementos independentes;
- possui incrementos estacionários;
- o número de ocorrências em um intervalo de comprimento t segue distribuição de Poisson com parâmetro λt .

Assim, para $k = 0, 1, 2, \dots$,

$$P(N(t) = k) = \frac{(\lambda t)^k e^{-\lambda t}}{k!}.$$

A interpretação mais comum é a de um contador acumulado de eventos. Esses eventos podem representar chegadas de clientes, falhas, pacotes recebidos, emissões de sinais, ocor-

rências experimentais ou outros fenômenos pontuais que ocorram ao longo do tempo com taxa média aproximadamente constante.

O valor esperado e a variância desse processo, em um instante t , são

$$E[N(t)] = \lambda t, \quad \text{Var}(N(t)) = \lambda t.$$

Esse resultado é particularmente importante porque mostra que, no processo de Poisson, média e variância crescem linearmente com o tempo e possuem o mesmo valor.

10.8.2 Tempos entre ocorrências

Uma propriedade central do processo de Poisson é que os tempos entre ocorrências sucessivas são independentes e identicamente distribuídos segundo distribuição exponencial com parâmetro λ . Se T representa o tempo até a próxima ocorrência, então

$$P(T > t) = e^{-\lambda t}, \quad t \geq 0,$$

e, portanto, sua densidade é

$$f_T(t) = \lambda e^{-\lambda t}, \quad t \geq 0.$$

Essa ligação entre processo de contagem e distribuição exponencial é extremamente útil em modelagem e simulação, porque fornece um mecanismo natural para gerar instantes aleatórios de chegada. Além disso, a distribuição exponencial possui a conhecida propriedade de ausência de memória, o que conecta diretamente o processo de Poisson à estrutura markoviana em tempo contínuo.

10.8.3 Uso em modelagem

Do ponto de vista desta obra, o processo de Poisson é importante principalmente em três contextos:

1. como modelo simplificado de chegadas aleatórias;
2. como base para processos de nascimento e morte;
3. como componente de diversos modelos de filas e confiabilidade.

Entretanto, como o objetivo principal deste capítulo não é desenvolver profundamente a teoria de processos de contagem em tempo contínuo, o processo de Poisson será tratado aqui como extensão natural das ideias markovianas já estabelecidas, e não como eixo dominante da exposição.

Exemplo 10.3 Considere um processo de Poisson com taxa $\lambda = 3$ eventos por hora. Calcule a probabilidade de ocorrerem exatamente 2 eventos em um intervalo de meia hora.

Solução:

Em meia hora, o parâmetro é

$$\lambda t = 3 \cdot 0.5 = 1.5.$$

Logo,

$$P(N(0.5) = 2) = \frac{(1.5)^2 e^{-1.5}}{2!} = \frac{2.25 e^{-1.5}}{2} = 1.125 e^{-1.5}.$$

Numericamente,

$$P(N(0.5) = 2) \approx 1.125 \cdot 0.2231 \approx 0.251.$$

10.9 Redes e Sistemas de Filas

Sistemas de filas constituem uma das aplicações mais importantes de processos estocásticos em engenharia e computação. Eles aparecem em manufatura, telecomunicações, sistemas operacionais, redes de computadores, hospitais, centrais de atendimento, cadeias logísticas, sistemas de transporte, bioengenharia laboratorial e em diversos outros contextos nos quais entidades competem por recursos limitados.

Neste capítulo, entretanto, sua apresentação será intencionalmente sintética. O objetivo não é esgotar a teoria de filas, mas mostrar como ela se conecta naturalmente às ideias já desenvolvidas sobre processos estocásticos e, em particular, sobre cadeias de Markov.

10.9.1 Estrutura básica de um sistema de filas

Um sistema de filas pode ser descrito, em sua forma mais simples, pelos seguintes elementos:

- um processo de chegada de entidades;
- um ou mais servidores ou recursos de atendimento;
- uma disciplina de fila, como FIFO, LIFO ou prioridade;
- uma regra de saída ou roteamento após o atendimento.

O estado do sistema é frequentemente representado pelo número de entidades presentes, ou por uma descrição mais rica que inclua também a ocupação dos servidores e a posição relativa das entidades na fila. Em muitos casos, esse estado é discreto e evolui por incrementos unitários associados a chegadas e saídas, o que conduz naturalmente a modelos markovianos ou a processos de nascimento e morte.

10.9.2 Processos de nascimento e morte

Uma forma clássica de representar sistemas de filas simples é por **processos de nascimento e morte**. Neles, o estado n representa, por exemplo, o número de clientes no sistema. Uma

chegada aumenta esse número em uma unidade, enquanto uma saída o reduz em uma unidade.

Em formulação contínua, esse tipo de processo é uma cadeia de Markov em tempo contínuo. Em termos conceituais, contudo, ele pode ser entendido como extensão direta da lógica apresentada neste capítulo: o sistema possui estados discretos, transições probabilísticas locais e forte interpretação operacional.

Em um sistema elementar com uma única fila e um único servidor, é comum representar:

- taxa de chegada λ , responsável pelas transições $n \rightarrow n + 1$;
- taxa de atendimento μ , responsável pelas transições $n \rightarrow n - 1$, para $n \geq 1$.

10.9.3 O sistema $M/M/1$

O sistema $M/M/1$ é o modelo de fila mais clássico da literatura. Sua notação significa:

- chegadas segundo processo de Poisson, ou tempos entre chegadas exponenciais;
- tempos de atendimento exponenciais;
- um único servidor.

Quando $\lambda < \mu$, o sistema admite regime estacionário, e a probabilidade de haver n clientes no sistema é

$$\pi_n = (1 - \rho)\rho^n, \quad n = 0, 1, 2, \dots$$

onde

$$\rho = \frac{\lambda}{\mu}$$

é a taxa de utilização do sistema.

A partir dessa distribuição, podem ser obtidas métricas clássicas como:

$$L = \frac{\rho}{1 - \rho}, \quad L_q = \frac{\rho^2}{1 - \rho}, \quad W = \frac{1}{\mu - \lambda}, \quad W_q = \frac{\rho}{\mu - \lambda},$$

em que:

- L é o número médio de clientes no sistema;
- L_q é o número médio de clientes na fila;
- W é o tempo médio no sistema;
- W_q é o tempo médio de espera na fila.

Essas expressões mostram como um sistema operacional com incerteza pode ser analisado por meio de uma estrutura estocástica relativamente compacta.

10.9.4 Redes de filas

Quando múltiplas filas e servidores são interligados, surgem as **redes de filas**. Nessas redes, uma entidade pode passar por vários centros de serviço, ser roteada entre módulos diferentes, retornar a um centro anterior ou deixar o sistema após determinado atendimento.

Do ponto de vista conceitual, redes de filas podem ser vistas como generalizações estruturadas de cadeias de estados discretos, nas quais o estado global do sistema descreve o número de entidades em cada subsistema ou uma combinação equivalente de ocupações locais. Em contextos mais simples, esse estado global ainda pode ser tratado markovianamente. Em contextos mais complexos, a análise fechada se torna difícil, e a simulação discreta orientada a eventos passa a ser o instrumento principal de estudo.

Essa observação é importante para a lógica global do livro: embora sistemas de filas possuam forte base estocástica e markoviana, seu estudo detalhado muitas vezes transita naturalmente para a simulação discreta orientada a eventos, que será retomada de forma específica mais adiante na obra.

10.9.5 Papel metodológico das filas neste capítulo

A razão de apresentar filas de forma mais breve aqui é metodológica. O capítulo tem como eixo principal a modelagem por processos estocásticos e, sobretudo, por cadeias de Markov. Processos de Poisson e sistemas de filas permanecem importantes, mas seu papel, neste ponto da obra, é principalmente o de ilustrar desdobramentos práticos da abordagem markoviana.

Em outras palavras, a ideia central que se pretende consolidar é a seguinte: muitos sistemas aleatórios podem ser modelados por estados discretos e regras probabilísticas de transição; alguns desses sistemas dão origem naturalmente a modelos de contagem e filas, que, por sua vez, conectam a teoria estocástica a aplicações clássicas de engenharia.

Exemplo 10.4 Considere um sistema $M/M/1$ com taxa de chegada $\lambda = 2$ clientes por minuto e taxa de atendimento $\mu = 5$ clientes por minuto. Calcule a utilização ρ e o número médio de clientes no sistema L .

Solução:

A utilização é

$$\rho = \frac{\lambda}{\mu} = \frac{2}{5} = 0.4.$$

Como $\rho < 1$, o sistema admite regime estacionário. O número médio de clientes no sistema é

$$L = \frac{\rho}{1 - \rho} = \frac{0.4}{0.6} = \frac{2}{3} \approx 0.667.$$

Portanto, em regime estacionário, o sistema possui em média aproximadamente 0.667 clientes. ■

10.10 Considerações Finais

Este capítulo apresentou processos estocásticos como ferramenta central para modelar sistemas cuja evolução temporal é intrinsecamente aleatória. A exposição foi organizada de modo a enfatizar, acima de tudo, os processos com espaço de estados discreto e tempo discreto, pois eles oferecem uma ponte especialmente fértil entre formalização matemática, interpretação operacional e implementação computacional. Dentro dessa classe, as cadeias de Markov receberam atenção principal por permitirem representar, de maneira compacta e analiticamente tratável, sistemas nos quais o futuro depende probabilisticamente do estado presente.

A propriedade de Markov foi discutida não como dogma abstrato, mas como hipótese de modelagem cuja adequação depende fortemente da escolha dos estados. Essa observação é metodologicamente decisiva: estados bem definidos tornam plausível a hipótese markoviana; estados mal definidos podem comprometer o modelo, ainda que a álgebra matricial esteja correta. A partir disso, foram desenvolvidas as ideias de matriz de transição, evolução de distribuições, equações de Chapman-Kolmogorov, classificação de estados, distribuições estacionárias e simulação amostral de trajetórias.

Também se mostrou que processos de Poisson e sistemas de filas se conectam naturalmente a esse núcleo conceitual, embora tenham sido tratados aqui de forma mais sintética. O processo de Poisson aparece como modelo de contagem aleatória e como base de chegadas em muitos sistemas operacionais, enquanto filas podem ser interpretadas como aplicações estocásticas particularmente relevantes em engenharia. Contudo, ao longo deste capítulo, o eixo central permaneceu corretamente concentrado em processos estocásticos e, principalmente, em cadeias de Markov, preservando o foco conceitual da técnica. No contexto do livro como um todo, esse capítulo encerra a sequência de paradigmas e técnicas de modelagem da Parte III, e prepara o terreno para a Parte IV, em que o foco se deslocará para verificação, validação, credibilidade, experimentação e análise de resultados dos modelos de simulação.

10.11 Resumo

Seção 10.1 Introdução

- Processos estocásticos descrevem a evolução temporal probabilística de sistemas sujeitos a incerteza, variabilidade e aleatoriedade intrínseca.
- A classe de maior interesse neste capítulo é a dos processos com espaço de estados discreto e tempo discreto.
- Cadeias de Markov ocupam papel central porque combinam expressividade, clareza conceitual e forte aplicabilidade prática.
- Processos de Poisson e redes de filas aparecem como extensões importantes, mas subordinadas ao foco principal em processos estocásticos e cadeias de Markov.

Seção 10.2 Processos estocásticos: conceitos essenciais

- Um processo estocástico é uma família de variáveis aleatórias indexadas no tempo.
- Espaço de estados e parâmetro temporal classificam o processo segundo a natureza

discreta ou contínua de estado e tempo.

- Uma trajetória simulada é apenas uma realização possível do processo, e não sua descrição completa.
- Distribuições unidimensionais descrevem o estado em um instante, enquanto distribuições finito-dimensionais capturam dependência temporal.
- A propriedade de Markov estabelece que, no modelo, o estado presente resume a informação relevante do passado para prever o futuro.

Seção 10.3 Cadeias de Markov em tempo discreto

- Uma cadeia de Markov em tempo discreto é caracterizada por uma distribuição inicial e por uma matriz de transição estocástica por linhas.
- A evolução das distribuições é obtida por multiplicação sucessiva da distribuição inicial por potências da matriz de transição.
- A matriz de transição possui interpretação operacional direta: cada linha codifica as probabilidades de evolução futura a partir de um estado atual.
- Cadeias de Markov podem ser usadas para modelar sistemas de confiabilidade, protocolos, modos operacionais e estados discretizados de processos biológicos.

Seção 10.4 Transições em múltiplos passos e equações de Chapman-Kolmogorov

- Probabilidades de transição em múltiplos passos são obtidas pela composição das probabilidades de passo único.
- As equações de Chapman-Kolmogorov ligam a interpretação probabilística da cadeia à álgebra matricial de potências da matriz de transição.
- Essa estrutura permite calcular distribuições futuras e probabilidades de ocupação de estados após vários passos.

Seção 10.5 Classificação dos estados e comportamento assintótico

- Acessibilidade e comunicação permitem identificar classes estruturais de estados.
- Estados absorventes e classes fechadas desempenham papel importante no comportamento de longo prazo do sistema.
- Irredutibilidade e aperiocidade simplificam a análise assintótica da cadeia.
- Distribuições estacionárias descrevem regimes probabilísticos invariantes e, em muitos casos, o comportamento de longo prazo da cadeia.

Seção 10.6 Modelagem de sistemas por cadeias de Markov

- A construção de um modelo markoviano exige definição clara do objetivo do estudo.
- A escolha dos estados é a etapa mais importante da modelagem, porque dela depende a plausibilidade da hipótese de Markov.
- A escala temporal e a matriz de transição devem ser compatíveis com a dinâmica relevante do sistema.
- Um modelo markoviano deve ser validado tanto estruturalmente quanto comportamentalmente.

Seção 10.7 Simulação de cadeias de Markov

- A simulação de uma cadeia de Markov consiste em gerar trajetórias amostrais sorteadando sucessivamente o próximo estado segundo a linha adequada da matriz de transição.
- Cadeias de Markov permitem tanto análise matricial quanto simulação amostral, e essas duas abordagens são complementares.
- Modelos markovianos podem ser implementados facilmente em código e aplicados em contextos de engenharia e bioengenharia.

Seção 10.8 Processo de Poisson

- O processo de Poisson é um modelo de contagem aleatória em tempo contínuo com incrementos independentes e estacionários.
- O número de eventos em um intervalo de comprimento t segue distribuição de Poisson com parâmetro λt .
- Tempos entre ocorrências sucessivas seguem distribuição exponencial, conectando o processo de Poisson a modelos markovianos em tempo contínuo.

Seção 10.9 Redes e Sistemas de Filas

- Sistemas de filas são aplicações clássicas de processos estocásticos em que entidades competem por recursos limitados.
- Processos de nascimento e morte fornecem formulação natural para diversos sistemas de filas simples.
- O sistema $M/M/1$ é o exemplo mais clássico e permite derivar métricas de desempenho em regime estacionário.
- Redes de filas podem ser vistas como desdobramentos estruturados da modelagem estocástica por estados discretos, frequentemente conectando-se à simulação discreta orientada a eventos.

10.12 Exercícios Propostos

Conceituação

Exercício 10.1 Explique a diferença entre uma trajetória individual de um processo estocástico e a descrição probabilística completa do processo.

Exercício 10.2 Explique por que a propriedade de Markov deve ser entendida como hipótese de modelagem e não como verdade absoluta sobre o sistema real.

Exercício 10.3 Discuta a diferença entre distribuição unidimensional e distribuição finito-dimensional de um processo estocástico.

Exercício 10.4 Explique a importância da matriz de transição em uma cadeia de Markov em tempo discreto.

Exercício 10.5 Explique a diferença entre estado absorvente, classe fechada, estado transitente e estado recorrente.

Aplicação com cadeias de Markov

Exercício 10.6 Considere uma cadeia com estados $\{A, B, C\}$ e matriz de transição

$$P = \begin{pmatrix} 0.6 & 0.3 & 0.1 \\ 0.2 & 0.5 & 0.3 \\ 0.0 & 0.0 & 1.0 \end{pmatrix}.$$

Classifique o estado C e determine se a cadeia é irredutível.

Exercício 10.7 Para a matriz do exercício anterior, suponha distribuição inicial $\mu^{(0)} = (1, 0, 0)$. Calcule $\mu^{(1)}$ e $\mu^{(2)}$.

Exercício 10.8 Escolha um sistema real de sua área de interesse e proponha um modelo markoviano com pelo menos três estados, justificando a escolha do espaço de estados e da escala temporal.

Exercício 10.9 Considere um controlador embarcado com modos *Normal*, *Sobrecarga* e *Falha*. Explique como você obteria empiricamente a matriz de transição a partir de dados observados.

Exercício 10.10 Explique por que duas definições diferentes de estado para o mesmo sistema podem produzir modelos markovianos com qualidades metodológicas muito diferentes.

Comportamento assintótico

Exercício 10.11 Explique o significado prático de uma distribuição estacionária em uma cadeia de Markov finita.

Exercício 10.12 Considere uma cadeia finita, irredutível e aperiódica. Explique por que a distribuição inicial deixa de ser relevante para o comportamento de longo prazo.

Exercício 10.13 Dê um exemplo de sistema em que estados transientes façam sentido operacional claro.

Exercício 10.14 Discuta por que a presença de periodicidade pode impedir a convergência direta das distribuições $\mu^{(n)}$, mesmo quando existe distribuição estacionária.

Exercício 10.15 Pesquise ou proponha um sistema em que o comportamento assintótico seja mais importante do que a dinâmica transitória, e outro em que a dinâmica transitória seja mais importante do que o regime de longo prazo.

Poisson e filas

Exercício 10.16 Considere um processo de Poisson com taxa $\lambda = 4$ eventos por hora. Calcule a probabilidade de ocorrer exatamente 1 evento em 15 minutos.

Exercício 10.17 Explique a relação entre processo de Poisson e distribuição exponencial dos tempos entre chegadas.

Exercício 10.18 Considere um sistema $M/M/1$ com $\lambda = 3$ e $\mu = 5$. Calcule ρ e L .

Exercício 10.19 Explique por que sistemas de filas podem ser entendidos como aplicações especializadas de processos estocásticos e, em muitos casos, de estruturas markovianas.

Exercício 10.20 Discuta por que redes de filas tendem a aproximar-se naturalmente da simulação discreta orientada a eventos quando sua estrutura se torna mais rica.

Investigação e implementação

Exercício 10.21 Implemente em Python, Julia, MATLAB, Scilab ou outra linguagem de sua escolha a simulação de uma cadeia de Markov finita com pelo menos quatro estados, e compare frequências observadas com distribuições teóricas em múltiplos passos.

Exercício 10.22 Escolha um problema de confiabilidade, protocolo de comunicação, bioengenharia ou computação e proponha uma cadeia de Markov para modelá-lo, indicando possíveis usos analíticos e de simulação.

Exercício 10.23 Pesquise um exemplo real de aplicação de cadeias de Markov em biologia, engenharia biomédica, computação ou finanças e explique por que a hipótese de Markov é razoável nesse contexto.

Exercício 10.24 Escolha um sistema cuja dinâmica real tenha memória longa e discuta por que uma cadeia de Markov simples pode ser inadequada para representá-lo.

Exercício 10.25 Discuta criticamente as vantagens e limitações de modelos markovianos em comparação com modelos contínuos, híbridos e orientados a eventos estudados nos capítulos anteriores.

Base bibliográfica do capítulo. Este capítulo se apoia principalmente em [4], [13], [35] e [43] para a apresentação de processos estocásticos, cadeias de Markov, processo de Poisson e fundamentos de sistemas de filas, com ênfase na interpretação probabilística, na formulação por estados e na evolução temporal do sistema. A articulação entre modelagem estocástica, construção de modelos úteis e simulação computacional também dialoga com [29], especialmente no tratamento da passagem entre formulação matemática, interpretação operacional e uso da simulação como instrumento complementar de análise. Em perspectiva mais ampla de modelagem, o capítulo também mantém continuidade com [20] e [46], ao tratar processos estocásticos e cadeias de Markov como formalismos de representação de sistemas dinâmicos em engenharia, computação e bioengenharia.

RASCUNHO