



14. Planejamento e Execução dos Experimentos de Simulação

14.1 Introdução

Nos capítulos anteriores, o leitor aprendeu a construir modelos, a selecionar paradigmas adequados ao problema, a preparar dados e, sobretudo, a submeter o modelo a verificação, validação e análise de credibilidade. Contudo, um modelo validado ainda não responde automaticamente às perguntas do projeto. Ele apenas se torna um instrumento potencialmente utilizável. Para que esse instrumento produza conhecimento útil, é necessário submetê-lo a **experimentos de simulação** cuidadosamente planejados.

Esse ponto merece ênfase. Em um projeto real, não basta alterar parâmetros informalmente, executar algumas corridas e observar saídas numericamente plausíveis. Esse procedimento pode até produzir intuições iniciais, mas dificilmente sustenta conclusões robustas. Em geral, ele desperdiça esforço computacional, explora mal o espaço de possibilidades, dificulta a interpretação dos resultados e, sobretudo, aumenta o risco de conclusões equivocadas. Quando o número de fatores cresce, quando o modelo é estocástico e quando múltiplas medidas de desempenho precisam ser analisadas simultaneamente, a ausência de um plano experimental explícito torna-se rapidamente um problema metodológico sério.

Portanto, este capítulo trata o modelo como um **laboratório computacional**. Uma vez

verificado e validado, o modelo passa a poder ser interrogado de forma sistemática. Isso significa decidir:

- quais fatores serão variados;
- quais níveis serão testados;
- quais respostas serão observadas;
- quantas replicações serão necessárias;
- como lidar com variabilidade estocástica;
- como organizar warm-up, horizonte de simulação e ordem de execução;
- como comparar alternativas;
- e como extrair, das corridas realizadas, conhecimento efetivamente útil.

Nesse sentido, o planejamento e a execução de experimentos de simulação pertencem ao núcleo metodológico da área. Eles articulam estatística, ciência experimental, engenharia de sistemas e computação. Também aproximam a simulação do método científico em seu sentido mais operacional: formular questões, definir fatores, controlar condições, realizar observações estruturadas e interpretar respostas à luz de hipóteses e objetivos claramente estabelecidos.

Este capítulo foi organizado para refletir essa amplitude. Inicialmente, discute-se a natureza dos experimentos com modelos de simulação, a estrutura das saídas e a organização das corridas. Em seguida, tratam-se comparação entre configurações, custo experimental e eficiência estatística. Só então o texto entra no bloco clássico de planejamento fatorial, partindo da ponte entre testes de hipótese, análise de variância e planejamento de experimentos. A partir daí, são apresentados planejamentos 2^k , planejamentos replicados $(2^k).r$, frações fatoriais 2^{k-p} , planejamentos replicados $(2^{k-p}).r$, o modelo de regressão linear empírico associado ao experimento e a interpretação de efeitos e interações. Por fim, o capítulo discute execução prática das campanhas experimentais, com ênfase em Arena, e situa brevemente extensões mais avançadas, como pontos centrais, superfícies de resposta, metamodelagem, *data farming* e simulação-otimização.

14.2 Natureza dos Experimentos com Modelos de Simulação

A experimentação com modelos de simulação difere da observação direta de sistemas reais em um aspecto essencial: o modelador possui controle muito maior sobre as condições do experimento. Em vez de esperar que o sistema real opere sob determinadas condições, o experimentador pode impor cenários, alterar parâmetros, repetir corridas, eliminar certas fontes de ruído, isolar mecanismos específicos e comparar alternativas sob condições equivalentes. Essa controlabilidade é uma das maiores forças da simulação, mas também exige disciplina metodológica.

14.2.1 O Modelo como Sistema Experimental Controlável

Quando um modelo é suficientemente confiável para uso, ele se torna um objeto experimental. Isso significa que o pesquisador pode formular perguntas do tipo:

- o que acontece se a capacidade do recurso principal for aumentada?
- qual é o impacto de reduzir o tempo médio de atendimento?
- uma política de prioridade melhora ou piora o nível de serviço?
- o sistema é mais sensível à taxa de chegada ou à variabilidade do processamento?
- existe interação relevante entre número de servidores e disciplina de fila?

Essas perguntas não são, em essência, diferentes daquelas que um pesquisador faria em um laboratório físico ou em um projeto experimental industrial. A diferença está no fato de que, em simulação, o sistema experimental é uma representação computacional. Isso permite economia, repetibilidade e exploração de cenários impossíveis ou indesejáveis no sistema real. Em contrapartida, exige grande cuidado com a estrutura do experimento, pois a facilidade de executar muitas corridas pode induzir à falsa sensação de rigor metodológico.

14.2.2 Tipos de Experimentos em Simulação

Os experimentos com modelos de simulação podem perseguir finalidades bastante diferentes. Entre as mais comuns estão:

- **comparação entre alternativas**, quando se deseja escolher entre configurações, políticas ou arquiteturas diferentes;
- **análise de sensibilidade**, quando se deseja estudar a influência de certos parâmetros sobre as respostas do modelo;
- **triagem de fatores**, quando há muitos fatores candidatos e se deseja identificar os mais relevantes;
- **exploração de cenários**, quando se deseja avaliar desempenho sob diferentes regimes de operação;
- **calibração e ajuste**, quando se procura aproximar melhor o comportamento do modelo ao sistema real;
- **apoio à otimização**, quando se quer encontrar combinações promissoras de fatores ou parâmetros.

Essas finalidades não são mutuamente exclusivas. Em muitos projetos, a campanha experimental começa com análise exploratória ampla, segue para um planejamento mais estruturado de fatores e termina em uma busca orientada a melhoria de desempenho. Por isso, planejar experimentos de simulação não significa apenas escolher um projeto fatorial; significa escolher uma estratégia de investigação.

14.2.3 Elementos Básicos do Experimento

Para organizar a terminologia deste capítulo, convém distinguir alguns elementos fundamentais.

Um **fator** é uma variável controlável pelo experimentador, cujo efeito sobre as respostas do modelo se deseja estudar. Um fator pode corresponder a um parâmetro do sistema, a uma política operacional, a uma decisão de projeto, a uma regra de controle ou a uma condição de cenário.

Um **nível** é um valor específico assumido por um fator no experimento. Em planejamentos fatoriais clássicos com dois níveis, cada fator assume apenas um nível baixo e um nível alto. Em outros experimentos, podem existir três ou mais níveis.

Um **tratamento** é uma combinação específica de níveis dos fatores. Em um experimento com dois fatores A e B , por exemplo, cada combinação (A_i, B_j) constitui um tratamento.

Uma **resposta** é a variável de saída observada e analisada, como tempo médio de espera, utilização de recurso, throughput ou custo.

Uma **corrida** é uma execução do modelo sob determinado tratamento, semente, horizonte de tempo e demais condições de execução.

Uma **replicação** é uma repetição estatisticamente independente de uma corrida sob o mesmo tratamento.

Por fim, uma **campanha experimental** é o conjunto organizado de corridas e replicações planejadas para responder à pergunta do estudo.

14.2.4 Experimentos Terminantes e em Estado Estacionário

Uma distinção central na experimentação em simulação diz respeito à natureza temporal do sistema estudado. Em um **experimento terminante**, existe um horizonte natural ou um evento de término claramente definido. Exemplos incluem simulações de um dia de operação, de uma jornada de trabalho, de uma missão, de uma campanha logística com fim determinado ou de um lote de produção até seu término.

Em um **experimento em estado estacionário**, o interesse recai sobre o comportamento de longo prazo de um sistema que, em princípio, poderia operar indefinidamente, como um sistema de filas contínuo, um servidor computacional ou uma linha de produção permanente. Nesses casos, o transiente inicial pode enviesar as medidas, o que motiva a discussão sobre **warm-up** ou descarte de observações iniciais.

Essa distinção afeta diretamente a forma de organizar corridas, a escolha do horizonte, o tratamento da variabilidade e o tipo de análise estatística apropriada. Por isso, ela precisa aparecer logo no início do capítulo.

14.3 Estrutura das Saídas e Medidas de Desempenho

Nenhum experimento é melhor do que as respostas que ele foi projetado para observar. Em simulação, esse ponto é ainda mais importante porque um mesmo modelo pode produzir grande quantidade de saídas potenciais, enquanto o projeto normalmente necessita de apenas algumas

medidas realmente relevantes.

14.3.1 Respostas de Interesse

Dependendo do sistema modelado, as respostas de interesse podem incluir:

- tempo médio em fila;
- tempo médio no sistema;
- número médio de entidades em fila;
- utilização de recursos;
- throughput;
- taxa de perdas;
- proporção de clientes atendidos dentro de um limite;
- custo operacional;
- consumo de recursos;
- medidas compostas de desempenho.

A escolha das respostas não deve ser guiada pela facilidade com que o simulador as disponibiliza, mas pelos objetivos do projeto. Se a pergunta central do estudo é nível de serviço, então throughput isolado pode ser pouco informativo. Se a questão é gargalo operacional, então custo total pode ser secundário na fase inicial de exploração. A coerência entre pergunta e resposta deve ser mantida desde o início da campanha experimental.

14.3.2 Respostas Escalares, Vetoriais e Temporais

As saídas de um experimento de simulação nem sempre são simples médias finais. Em alguns estudos, a resposta de interesse é escalar, como o tempo médio no sistema. Em outros, a resposta é um vetor de medidas, como um conjunto de tempos médios em diferentes estações. Em outros ainda, a resposta pode ser uma curva temporal, como ocupação ao longo do dia, temperatura ao longo do tempo ou número de entidades no sistema em regime transiente.

Essa distinção importa porque o projeto experimental e a análise subsequente dependem do tipo de resposta. Comparar tratamentos com base em uma média final é muito diferente de comparar tratamentos com base em perfis temporais ou distribuições inteiras. Em termos práticos, o modelador deve perguntar desde cedo se o experimento busca:

- uma resposta agregada final;
- um comportamento dinâmico ao longo do tempo;
- ou múltiplas respostas simultâneas.

14.3.3 Múltiplas Respostas

Em problemas reais, é frequente que o desempenho do sistema não possa ser resumido por uma única métrica. Um hospital pode desejar simultaneamente reduzir tempo de espera, manter utilização de leitos em intervalo aceitável e controlar custos. Um sistema logístico pode buscar throughput alto, atrasos baixos e baixo nível de ociosidade. Isso transforma a campa-

nha experimental em um problema de múltiplas respostas.

Do ponto de vista deste capítulo, não será desenvolvido um tratamento completo de otimização multiobjetivo. Contudo, é importante registrar que a presença de múltiplas respostas:

- influencia a escolha dos fatores e dos níveis;
- dificulta a interpretação de melhor tratamento;
- e frequentemente exige compromisso entre objetivos.

14.3.4 Ligação entre Objetivo do Projeto e Variável-Resposta

Um erro metodológico frequente consiste em executar experimentos extensos e só depois decidir quais saídas são relevantes. Esse procedimento é frágil porque transforma a análise em busca oportunista por padrões. O correto é definir, antes da campanha experimental, quais respostas são centrais e por quê.

Em termos formais, se o projeto pretende responder à pergunta Q , então deve existir um conjunto de respostas $Y = \{Y_1, \dots, Y_m\}$ tal que a interpretação de Q seja possível a partir de Y . Sem essa ligação, a campanha pode ser extensa, mas pouco conclusiva.

14.4 Organização das Corridas: Replicação, Sementes, Warm-up e Horizonte

Planejar experimentos de simulação não significa apenas escolher fatores e tratamentos. Significa também definir como cada corrida será executada e registrada. Essa infraestrutura experimental é especialmente importante em modelos estocásticos.

14.4.1 Replicação em Simulação

Em simulação estocástica, uma única corrida sob um tratamento raramente basta para caracterizar a resposta do modelo. O valor observado em uma execução depende não apenas dos fatores controlados, mas também da realização aleatória efetivamente gerada durante a corrida. Por isso, é usual realizar **replicações** independentes de cada tratamento.

Se Y_{ij} representa a resposta observada na j -ésima replicação do i -ésimo tratamento, então a média por tratamento pode ser estimada por

$$\bar{Y}_i = \frac{1}{r} \sum_{j=1}^r Y_{ij},$$

onde r é o número de replicações. A variabilidade entre replicações fornece informação essencial sobre a precisão com que o tratamento foi avaliado.

É fundamental distinguir:

- **variari fatores**, que significa mudar o tratamento;

- **replicar**, que significa repetir estatisticamente o mesmo tratamento.

Sem essa distinção, o experimentador corre o risco de confundir efeito de fator com ruído estocástico.

14.4.2 Controle de Sementes e Reprodutibilidade

As sementes dos geradores de números aleatórios fazem parte do protocolo experimental. Em projetos bem conduzidos, elas não devem ser tratadas como detalhe irrelevante. O controle explícito das sementes permite:

- reprodutibilidade das corridas;
- rastreabilidade de resultados;
- repetição do experimento em caso de revisão;
- uso criterioso de técnicas como *common random numbers*.

Do ponto de vista metodológico, isso significa que o planejamento experimental não termina na matriz de tratamentos. Ele inclui também a definição de como as corridas serão inicializadas, identificadas e armazenadas.

14.4.3 Warm-up e Remoção do Transiente Inicial

Em sistemas cujo interesse recai sobre comportamento de longo prazo, a condição inicial do modelo pode distorcer as medidas observadas. Se um sistema de filas é inicializado vazio, por exemplo, os primeiros instantes de operação tendem a apresentar filas menores do que aquelas típicas do regime estabelecido. Em muitos casos, isso motiva a introdução de um **período de warm-up**, isto é, um intervalo inicial de tempo simulado cujas observações não são utilizadas nas estatísticas finais.

A lógica é simples: se o sistema real não é observado a partir do vazio absoluto no contexto de interesse, então medir a resposta do modelo desde essa condição inicial pode introduzir viés. O warm-up, contudo, não é solução universal. Sua necessidade depende do sistema, da pergunta do estudo e do tipo de experimento.

Arena, por exemplo, permite configurar explicitamente um período de aquecimento nas definições de execução, o que evidencia que esse tema pertence à infraestrutura do experimento, e não apenas à análise posterior.

14.4.4 Horizonte de Simulação e Tamanho da Corrida

Outra decisão central é o horizonte de cada corrida. Em um experimento terminante, o horizonte pode ser natural, como um dia de operação ou até o término de todos os pedidos do lote. Em um experimento em estado estacionário, o horizonte precisa ser suficientemente longo para reduzir incerteza estatística e capturar o regime de interesse.

Essa decisão possui impacto direto sobre:

- a variabilidade das respostas;
- o custo computacional do experimento;
- a necessidade de warm-up;
- a comparabilidade entre tratamentos.

Horizontes muito curtos podem produzir estimativas instáveis. Horizontes excessivamente longos podem desperdiçar esforço computacional sem ganho proporcional de informação.

14.4.5 Ordem e Rastreabilidade das Execuções

Em campanhas experimentais maiores, a simples lista de corridas já se torna um objeto metodológico relevante. É necessário registrar:

- qual tratamento foi executado;
- em que ordem;
- com que semente;
- com quantas replicações;
- com que warm-up;
- com que horizonte;
- e com que identificador de versão do modelo.

Sem essa rastreabilidade, a repetição do estudo e a interpretação de discrepâncias se tornam difíceis. Em outras palavras, planejamento experimental também é disciplina de documentação.

14.5 Comparação entre Configurações e Alternativas

Antes mesmo de entrar em planejamento fatorial, muitos estudos de simulação precisam comparar alternativas claramente definidas: duas políticas de operação, três arquiteturas de sistema, quatro configurações de atendimento ou diferentes tamanhos de capacidade. Esse problema merece tratamento próprio porque nem sempre se reduz naturalmente à lógica de fatores controláveis.

14.5.1 Comparação de Duas Configurações

Suponha que duas configurações de um sistema estejam em avaliação, por exemplo:

- política FIFO versus política com prioridade;
- dois versus três atendentes;
- fila única versus filas separadas;
- algoritmo A versus algoritmo B.

Nesse caso, o problema experimental central é comparar respostas como μ_1 e μ_2 , médias associadas às duas configurações. Em princípio, esse problema pode ser tratado com

ferramentas clássicas de estimação e teste de hipótese. Contudo, no contexto de simulação, deve-se lembrar que a qualidade da comparação depende também de como as corridas foram planejadas, se houve replicação suficiente, se o warm-up foi tratado corretamente e se houve controle razoável das fontes de variabilidade.

14.5.2 Comparação de Múltiplas Configurações

Quando o número de alternativas cresce, comparar tudo por testes binários sucessivos deixa de ser metodologicamente atraente. Além do aumento do risco de interpretações equivocadas, perde-se a visão integrada da variabilidade entre tratamentos. É nesse ponto que a análise de variância ganha importância como estrutura estatística para a comparação de múltiplas médias.

Ainda assim, é importante distinguir **comparação entre configurações de planejamento fatorial**. Em uma comparação entre configurações, cada alternativa já pode ser um sistema completo diferente. Em um planejamento fatorial, o interesse recai sobre decompor efeitos atribuíveis a fatores explicitamente definidos e combinados.

14.5.3 Introdução Conceitual a *Ranking and Selection*

Em alguns estudos, o objetivo não é apenas estimar médias ou detectar diferenças, mas escolher a melhor alternativa entre várias. Esse problema pertence ao domínio de *ranking and selection*. Em termos conceituais, ele pergunta: como selecionar, com risco controlado, a melhor entre diversas configurações simuladas?

Embora este capítulo não desenvolverá algoritmos específicos de *ranking and selection*, é importante apresentar a ideia porque ela pertence ao planejamento experimental em simulação. Nem todo experimento busca ajuste de metamodelo; muitos buscam seleção entre alternativas discretas.

14.5.4 Quando o Problema é Comparação e Quando é Exploração de Fatores

Essa distinção é importante para o leitor. Se o estudo envolve poucas alternativas claramente definidas, talvez uma campanha de comparação entre configurações seja mais natural do que um planejamento fatorial clássico. Se, por outro lado, a pergunta central envolve entender a influência de parâmetros e suas interações, então DOE torna-se mais adequado. Na prática, muitos projetos combinam ambas as perspectivas.

14.6 Eficiência Estatística e Custo Experimental

Uma campanha experimental de simulação está sempre sujeita a algum orçamento, ainda que implícito. Esse orçamento pode ser:

- tempo de execução computacional;
- tempo de modelagem e análise;
- custo humano de organizar e interpretar resultados;
- ou simplesmente a quantidade total de corridas viáveis dentro do projeto.

14.6.1 Custo Computacional como Restrição

Em modelos pequenos, executar muitas corridas pode parecer barato. Em modelos maiores, com lógica rica ou horizonte longo, cada corrida pode ser custosa. Além disso, o crescimento do número de tratamentos pode ser exponencial. Por isso, o projeto experimental precisa levar em conta que explorar mais cenários e aumentar o número de replicações competem pelo mesmo orçamento computacional.

14.6.2 Variabilidade de Saída e Precisão

Se a variabilidade entre replicações é alta, mais replicações serão necessárias para estimar com precisão razoável a resposta de um tratamento. Se a resposta é estável, pode ser possível explorar mais tratamentos com o mesmo orçamento. Assim, o planejamento experimental em simulação é também um problema de alocação de esforço entre:

- explorar mais tratamentos;
- replicar mais os tratamentos já escolhidos;
- aumentar horizonte;
- e controlar o transiente.

14.6.3 Introdução à Redução de Variância

Embora técnicas de redução de variância sejam tema mais amplo do que este capítulo pode comportar em profundidade, vale registrar ao menos sua importância conceitual. Métodos como *common random numbers* e variáveis antitéticas procuram aumentar a eficiência estatística do experimento, isto é, obter maior poder analítico por corrida executada.

Em termos práticos, isso significa que planejar bem um experimento não consiste apenas em escolher fatores e níveis, mas também em decidir como usar a aleatoriedade do simulador de forma mais informativa. Essa observação reforça que DOE, embora importante, não esgota a experimentação em simulação.

14.6.4 Experimentos Pobres e Experimentos Informativos

Do ponto de vista metodológico, um experimento pobre é aquele que consome corridas, mas produz pouca informação interpretável. Isso acontece, por exemplo, quando:

- se variam fatores demais sem estrutura;
- não há replicação suficiente;
- as respostas escolhidas não correspondem aos objetivos do estudo;

- a variabilidade estocástica é ignorada;
- ou o número de tratamentos explode sem critério.

Em contraste, um experimento informativo é aquele em que cada corrida contribui para responder a uma pergunta bem definida.

14.7 Da Comparação de Médias à ANOVA

Como muitos alunos já possuem familiaridade com testes de hipótese elementares, é pedagogicamente útil começar a formalização estatística do capítulo por esse ponto, e então mostrar por que essa base é insuficiente quando o número de tratamentos cresce ou quando o interesse passa de há diferença? para quais fatores influenciam, quanto e em interação com quem?.

14.7.1 Revisão Breve: Estimação e Teste de Hipótese

Considere duas configurações de um sistema, com médias populacionais μ_1 e μ_2 para determinada resposta de interesse. Um problema clássico é testar

$$H_0 : \mu_1 = \mu_2 \quad \text{versus} \quad H_1 : \mu_1 \neq \mu_2.$$

Esse formalismo continua útil em simulação. Contudo, ele resolve apenas um problema restrito: comparar duas médias sob uma estrutura estatística relativamente simples.

Se o número de configurações cresce para três, quatro ou mais, repetir testes binários sucessivos deixa de ser boa estratégia. A multiplicidade de comparações aumenta o risco de erro e fragmenta a análise.

14.7.2 Limitações de Comparações Binárias Sucessivas

Suponha que quatro tratamentos T_1, T_2, T_3, T_4 precisem ser comparados. Em princípio, seriam possíveis várias comparações pareadas:

$$(T_1, T_2), (T_1, T_3), (T_1, T_4), (T_2, T_3), (T_2, T_4), (T_3, T_4).$$

Esse procedimento não apenas aumenta rapidamente o número de testes, mas também perde a visão global da estrutura do experimento. É justamente para superar essa limitação que a **análise de variância** surge como instrumento central.

14.7.3 Ideia Central da Análise de Variância

Na forma mais simples, considere um experimento com a tratamentos e n observações por tratamento, descrito por

$$Y_{ij} = \mu + \tau_i + \varepsilon_{ij}, \quad i = 1, \dots, a, \quad j = 1, \dots, n,$$

onde μ é a média global, τ_i representa o efeito do i -ésimo tratamento e ε_{ij} é o erro aleatório.

A ANOVA se baseia na decomposição da soma de quadrados total:

$$SS_T = \sum_{i=1}^a \sum_{j=1}^n (Y_{ij} - \bar{Y}_{..})^2$$

em duas parcelas:

$$SS_T = SS_{Trat} + SS_E,$$

onde

$$SS_{Trat} = n \sum_{i=1}^a (\bar{Y}_{i.} - \bar{Y}_{..})^2$$

e

$$SS_E = \sum_{i=1}^a \sum_{j=1}^n (Y_{ij} - \bar{Y}_{i.})^2.$$

A estatística de teste é construída como

$$F_0 = \frac{MS_{Trat}}{MS_E},$$

com

$$MS_{Trat} = \frac{SS_{Trat}}{a-1} \quad \text{e} \quad MS_E = \frac{SS_E}{a(n-1)}.$$

Em termos conceituais, a ANOVA pergunta se a variabilidade entre médias de tratamentos é grande o suficiente, relativamente à variabilidade residual, para indicar que os tratamentos não são todos equivalentes.

14.7.4 ANOVA como Ponte para DOE

A importância da ANOVA neste capítulo não é apenas permitir comparação de múltiplas médias. Ela também fornece a linguagem estatística pela qual os efeitos de fatores e interações serão interpretados em experimentos planejados. Em outras palavras, DOE não substitui ANOVA; DOE se apoia fortemente nela.

A figura 14.1 resume essa progressão.




Figura 14.1: Progressão conceitual do capítulo: da comparação elementar entre médias para ANOVA e, a partir dela, para o planejamento de experimentos fatoriais.




Figura 14.2: Elementos centrais de uma campanha experimental em simulação: objetivo, fatores, níveis, tratamentos, replicações, warm-up, horizonte, respostas e análise.

14.8 Estrutura Geral do Experimento de Simulação

Antes de entrar nos detalhes de DOE, convém sintetizar a estrutura geral de uma campanha experimental em simulação. A figura 14.2 faz esse resumo.

Essa figura evidencia que DOE é apenas um bloco dentro de uma infraestrutura experimental mais ampla. Os fatores e níveis definem tratamentos; os tratamentos são executados por corridas replicadas; cada corrida pode envolver warm-up, horizonte específico e controle

de sementes; as respostas são registradas e analisadas. Sem essa visão integrada, o experimento tende a se fragmentar.

14.9 Introdução ao Planejamento Fatorial para Simulação

O planejamento fatorial é uma das ferramentas mais importantes da experimentação científica porque permite estudar simultaneamente a influência de múltiplos fatores sobre uma resposta. Em simulação, isso é particularmente valioso, pois os modelos frequentemente possuem vários parâmetros e políticas de interesse, e a alteração isolada de um fator por vez pode ocultar interações relevantes.

14.9.1 Fatores, Níveis, Tratamentos e Respostas

Em DOE, um **fator** é uma variável controlável do experimento. Em simulação, fatores podem ser, por exemplo:

- número de atendentes;
- capacidade de fila;
- política de prioridade;
- taxa média de chegada;
- tempo médio de atendimento;
- tamanho de lote;
- limiar de controle;
- nível de estoque de segurança.

Cada fator assume um conjunto de níveis previamente escolhidos. Quando todos os fatores são combinados sistematicamente, obtêm-se os tratamentos do experimento. A resposta é a variável observada, como tempo médio em fila ou throughput.

14.9.2 Efeito Principal

O **efeito principal** de um fator mede, em essência, a mudança média na resposta quando esse fator passa do nível baixo para o nível alto, mantendo-se a média sobre os níveis dos demais fatores. Se A é um fator binário, seu efeito pode ser estimado por

$$\hat{E}_A = \bar{Y}_{A+} - \bar{Y}_{A-},$$

onde $\bar{Y}_{A+}$ é a média das respostas observadas nos tratamentos com A em nível alto e $\bar{Y}_{A-}$ é a média correspondente ao nível baixo.

14.9.3 Interação entre Fatores

A **interação** entre fatores ocorre quando o efeito de um fator depende do nível de outro. Essa noção é decisiva porque torna metodologicamente pobre a estratégia de alterar um fator por

vez. Se houver interação, a influência isolada de um fator deixa de ser suficiente para descrever o comportamento do sistema.

Por exemplo, o impacto de aumentar o número de atendentes pode ser muito pequeno quando o tempo médio de atendimento já é curto, mas muito grande quando esse tempo é alto. Nesse caso, os fatores número de atendentes e tempo médio de atendimento interagem.

14.9.4 Codificação em -1 e $+1$

Em planejamentos fatoriais 2^k , é extremamente conveniente codificar os níveis dos fatores como -1 e $+1$. Essa codificação simplifica o cálculo dos efeitos e a escrita do modelo linear. Em vez de trabalhar diretamente com valores físicos dos fatores, usa-se:

$$x_i = \begin{cases} -1, & \text{nível baixo do fator } i, \\ +1, & \text{nível alto do fator } i. \end{cases}$$

A relação com os valores físicos reais é recuperada posteriormente quando necessário.

14.10 O Planejamento Fatorial Completo 2^k

O planejamento 2^k é a base conceitual dos planejamentos fatoriais de dois níveis. Nele, k fatores são estudados, cada um em dois níveis, totalizando

$$N = 2^k$$

tratamentos distintos.

14.10.1 Estrutura de 2^k

Se $k = 2$, o experimento possui $2^2 = 4$ tratamentos. Se $k = 3$, possui $2^3 = 8$. Em geral, o número de tratamentos cresce exponencialmente com k . Essa propriedade é, ao mesmo tempo, força e limitação do planejamento completo: ele revela com clareza efeitos e interações, mas se torna rapidamente caro em número de corridas.

14.10.2 O Caso 2^2

Considere um experimento com dois fatores:

- A : número de atendentes, com níveis baixo = 2 e alto = 3;
- B : tempo médio de atendimento, com níveis baixo = 5 min e alto = 8 min.

Suponha que a resposta de interesse seja o tempo médio em fila, e que as médias observadas para os quatro tratamentos sejam:

	$B(-1)$	$B(+1)$
$A(-1)$	12	25
$A(+1)$	7	9

Então:

$$\bar{Y}_{A+} = \frac{7+9}{2} = 8, \quad \bar{Y}_{A-} = \frac{12+25}{2} = 18,5,$$

e o efeito principal de A é

$$\hat{E}_A = 8 - 18,5 = -10,5.$$

Analogamente,

$$\bar{Y}_{B+} = \frac{25+9}{2} = 17, \quad \bar{Y}_{B-} = \frac{12+7}{2} = 9,5,$$

de modo que

$$\hat{E}_B = 17 - 9,5 = 7,5.$$

O efeito de interação AB pode ser calculado por contraste:

$$\hat{E}_{AB} = \frac{(12+9) - (25+7)}{2} = -5,5.$$

A interpretação desse resultado é que os efeitos de A e B não são meramente aditivos.

14.10.3 O Caso 2^3

Quando $k = 3$, o planejamento passa a ter oito tratamentos. A representação geométrica por um cubo é particularmente útil, como mostra a figura 14.3.




Figura 14.3: Representação geométrica de um planejamento fatorial completo 2^3 , com três fatores em dois níveis codificados por -1 e $+1$.

Essa representação é didaticamente valiosa porque mostra que o planejamento cobre sistematicamente todos os vértices do espaço experimental binário. Em 2^3 , podem ser estimados:

- três efeitos principais;
- três interações de segunda ordem;
- uma interação de terceira ordem.

14.10.4 O Caso Geral 2^k

No caso geral, o planejamento completo possui 2^k tratamentos e permite estimar todos os efeitos principais e todas as interações entre fatores. A grande vantagem é a clareza estrutural do experimento. A grande limitação é o crescimento explosivo do número de corridas. Por isso, planejamentos completos são excelentes quando o número de fatores é moderado, mas se tornam onerosos quando k cresce.

14.11 Planejamentos Replicados $(2^k).r$

Em simulação estocástica, não basta muitas vezes executar uma única vez cada tratamento do planejamento fatorial. É necessário replicar as corridas. Isso conduz ao projeto $(2^k).r$, em que cada um dos 2^k tratamentos é executado r vezes de forma estatisticamente independente.

14.11.1 Por que Replicar em DOE para Simulação

A replicação fornece estimativa do erro experimental, separando, ao menos parcialmente, o efeito dos fatores da variabilidade aleatória intrínseca à simulação. Sem replicação, a leitura de efeitos pode ficar excessivamente dependente de uma realização estocástica específica.

14.11.2 Estrutura de $(2^k).r$

Se $k = 3$ e $r = 5$, então o total de corridas será

$$N = 2^3 \cdot 5 = 40.$$

A média de cada tratamento é estimada a partir das r replicações correspondentes. Isso permite aplicar ANOVA com uma noção mais clara de erro residual.

14.11.3 Compromisso entre Explorar e Replicar

Replicar mais aumenta precisão local, mas consome orçamento que poderia ser usado para explorar mais tratamentos ou mais fatores. Essa tensão é central no planejamento experimental em simulação. Não existe escolha universalmente ótima; a decisão depende do objetivo da campanha, do custo por corrida e da variabilidade observada.

14.12 Planejamentos Fracionários 2^{k-p}

Quando o número de fatores cresce, o planejamento completo pode se tornar impraticável. Nesse contexto, surgem os planejamentos fracionários 2^{k-p} , em que apenas uma fração dos 2^k tratamentos é efetivamente executada.

14.12.1 Por que Fracionar

A motivação principal é econômica. Se $k = 7$, um planejamento completo exigiria $2^7 = 128$ tratamentos, antes mesmo de considerar replicações. Em uma fase inicial de triagem, pode ser mais sensato usar uma fração do experimento, sacrificando parte da separabilidade entre efeitos em troca de um custo experimental muito menor.

14.12.2 Geradores e Estrutura de Fração

Em uma fração meia de um planejamento 2^3 , por exemplo, pode-se usar o gerador

$$C = AB,$$

o que conduz à relação definidora

$$I = ABC.$$

Isso significa que o experimento observará apenas metade dos tratamentos do cubo completo, escolhidos de forma estruturada.

14.12.3 Aliasamento e Confundimento

O preço do fracionamento é o **aliasamento**. No exemplo com

$$I = ABC,$$

obtém-se, por multiplicação algébrica, as relações:

$$A = BC, \quad B = AC, \quad C = AB.$$

Isso significa que o efeito principal de A fica confundido com a interação BC , e assim por diante. O experimentador deixa de poder distinguir plenamente certos efeitos com base apenas naquela fração.

14.12.4 Resolução

A **resolução** de um planejamento fracionário fornece uma indicação compacta da qualidade do projeto em termos de confundimento entre efeitos de baixa ordem. Em nível introdutório, basta ao leitor compreender que:

- resoluções mais baixas implicam confundimentos mais severos;
- resoluções mais altas separam melhor efeitos principais e interações de baixa ordem;
- a escolha da resolução depende do objetivo da campanha experimental e do conhecimento prévio sobre o sistema.

A figura 14.4 resume conceitualmente essas ideias.




Figura 14.4: Representação conceitual do compromisso entre economia experimental e confundimento de efeitos em planejamentos fatoriais fracionários.

14.12.5 Cuidados de Interpretação

Planejamentos fracionários exigem disciplina interpretativa. Um efeito estimado como importante pode estar carregando parte da influência de outro efeito confundido. Por isso, a interpretação de frações fatoriais precisa ser apoiada por:

- conhecimento do sistema;
- hierarquia entre efeitos;
- parcimônia;
- eventualmente experimentação complementar posterior.

14.13 Planejamentos Fracionários Replicados $(2^{k-p}).r$

Do ponto de vista conceitual, a forma mais geral tratada neste capítulo é o planejamento $(2^{k-p}).r$. Ele combina duas ideias fundamentais:

- uso de uma fração do experimento completo;
- replicação de cada tratamento executado.

14.13.1 Forma Geral do Projeto

O número total de corridas é

$$N = 2^{k-p} \cdot r.$$

Essa forma é especialmente útil porque engloba os demais casos como particularidades:

- se $p = 0$ e $r = 1$, obtém-se 2^k ;
- se $p = 0$, obtém-se $(2^k).r$;
- se $r = 1$, obtém-se 2^{k-p} .

A figura 14.5 resume essa relação entre os diferentes projetos.




Figura 14.5: Relação entre os principais projetos fatoriais de dois níveis tratados neste capítulo. O caso $(2^{k-p}).r$ é o mais geral dentro da família considerada.

14.13.2 Interpretação Metodológica

O grande interesse de $(2^{k-p}).r$ é oferecer uma estrutura realista para muitos estudos de simulação. Em situações com muitos fatores e saídas ruidosas, é pouco provável que um planejamento completo sem replicações seja a melhor escolha. A forma fracionária replicada permite:

- reduzir o número de tratamentos;
- estimar erro experimental com mais robustez;
- manter a campanha em orçamento computacional viável.

14.13.3 Planejamento Sequencial

Outra vantagem de pensar em $(2^{k-p}).r$ como caso geral é que ele se ajusta bem a estratégias sequenciais. Pode-se começar com uma fração replicada para triagem e, depois, expandir o experimento:

- adicionando tratamentos;
- aumentando replicações;
- introduzindo pontos centrais;
- ou refinando a fração para reduzir aliasamento.

Essa lógica sequencial é particularmente adequada à simulação, pois o custo marginal de novas corridas pode ser controlado ao longo do projeto.

14.13.4 Recomendação Prática

Para o leitor deste livro, o mais importante é compreender que $(2^{k-p}).r$ não é apenas notação sofisticada, mas uma forma de organizar mentalmente a família dos planejamentos fatoriais binários relevantes em simulação. Uma vez entendido esse caso geral, os outros projetos aparecem como variações mais simples dele.

14.14 O Modelo de Regressão Linear Associado ao Experimento

Uma das grandes forças do planejamento fatorial é que ele não se limita a comparar médias de tratamentos. Ele também permite ajustar um **modelo empírico** que relaciona a resposta aos fatores e às interações observadas no experimento.

14.14.1 Forma Geral do Modelo

Em variáveis codificadas, um modelo linear para k fatores pode ser escrito como

$$y = \beta_0 + \sum_{i=1}^k \beta_i x_i + \sum_{i < j} \beta_{ij} x_i x_j + \sum_{i < j < \ell} \beta_{ij\ell} x_i x_j x_\ell + \cdots + \varepsilon,$$

onde:

- y é a resposta;
- β_0 é o intercepto;
- β_i são coeficientes associados a efeitos principais;
- β_{ij} , $\beta_{ij\ell}$ etc. representam interações;
- ε representa erro.

14.14.2 Relação entre Efeitos e Coeficientes

Em planejamentos 2^k balanceados com variáveis codificadas em -1 e $+1$, há uma relação simples entre efeito e coeficiente:

$$\hat{\beta}_i = \frac{\hat{E}_i}{2}, \quad \hat{\beta}_{ij} = \frac{\hat{E}_{ij}}{2},$$

e assim por diante. Isso reforça a conexão entre leitura de contrastes e construção do modelo empírico.

14.14.3 Metamodelo como Instrumento de Entendimento

O modelo linear ajustado ao experimento pode ser visto como um **metamodelo local**. Ele não substitui o modelo de simulação; ele resume empiricamente o comportamento observado do simulador na região experimental estudada. Isso é extremamente útil porque:

- torna os efeitos mais interpretáveis;
- permite prever respostas em combinações próximas;
- ajuda a identificar fatores dominantes;
- sugere regiões promissoras para exploração posterior.

Ainda assim, é importante compreender seus limites. O metamodelo linear não é uma verdade do sistema. Ele é uma aproximação empírica, válida na região e sob o projeto em que foi ajustado.

14.14.4 Relação com ANOVA

Do ponto de vista estatístico, a ANOVA e o modelo de regressão são duas formas complementares de olhar o mesmo experimento. A ANOVA organiza a decomposição da variabilidade em termos de somas de quadrados e testes globais. A regressão organiza a mesma informação em forma de modelo empírico com coeficientes interpretáveis. No contexto didático deste capítulo, ambas devem ser tratadas como linguagens complementares.

14.15 Gráficos de Efeitos e de Interação

A interpretação de experimentos fatoriais é bastante fortalecida por representações gráficas. Embora as fórmulas sejam indispensáveis, os gráficos ajudam a perceber rapidamente padrões que poderiam passar despercebidos em tabelas de coeficientes.

14.15.1 Gráfico de Efeitos Principais

Um gráfico de efeitos principais mostra, para cada fator, como a média da resposta muda entre o nível baixo e o nível alto. A figura 14.6 ilustra um exemplo conceitual correspondente ao caso discutido anteriormente.




Figura 14.6: Exemplo conceitual de gráfico de efeitos principais para dois fatores em um experimento 2^2 .

A leitura básica é simples: quanto maior a inclinação da linha, maior a influência média do fator sobre a resposta. Entretanto, essa leitura deve ser sempre complementada pela análise de interações.

14.15.2 Gráfico de Interação

O gráfico de interação mostra o comportamento da resposta quando dois fatores são analisados simultaneamente. A figura 14.7 apresenta um exemplo correspondente ao caso em que o efeito

do número de atendentes depende do tempo médio de atendimento.




Figura 14.7: Exemplo conceitual de gráfico de interação. Linhas não paralelas indicam que o efeito de um fator depende do nível do outro.

Quando as linhas são aproximadamente paralelas, a interação tende a ser pequena. Quando elas divergem, convergem ou se cruzam, a interação tende a ser relevante. Essa leitura gráfica é particularmente útil em experimentos de simulação porque ajuda a interpretar efeitos de forma operacional.

14.16 Execução Prática das Campanhas Experimentais

Depois de planejado o experimento, é necessário executá-lo de forma organizada. Essa etapa exige tanto cuidado quanto o projeto estatístico propriamente dito. Um projeto excelente, mal executado, produz resultados frágeis.

14.16.1 Construção da Matriz Experimental

A primeira tarefa prática consiste em montar a matriz experimental contendo:

- fatores;
- níveis;
- codificação;
- tratamentos;
- número de replicações;
- warm-up;
- horizonte de corrida;
- respostas a coletar.

A matriz não é apenas uma tabela auxiliar. Ela é o protocolo executivo do experimento.

14.16.2 Protocolo de Execução

A figura 14.8 resume um protocolo genérico de execução das corridas.




Figura 14.8: Sequência recomendada para organizar uma campanha experimental de simulação com controle de fatores, replicações, sementes, warm-up, horizonte e registro das respostas.

Em termos operacionais, esse protocolo deve especificar:

1. a versão do modelo;
2. os tratamentos a executar;
3. as sementes ou regras de geração de sementes;
4. o número de replicações;
5. o período de warm-up, se aplicável;
6. o horizonte de corrida;
7. os arquivos ou variáveis em que as respostas serão registradas.

14.16.3 Execução Prática em Arena

Arena é particularmente conveniente para experimentação porque permite:

- parametrizar elementos do modelo por variáveis e expressões;
- configurar número de replicações;
- definir horizonte de execução;
- definir warm-up;
- coletar estatísticas padronizadas;
- apoiar análise posterior por ferramentas associadas.

Uma boa prática em Arena consiste em construir o modelo de forma parametrizada desde o início. Em vez de criar um novo modelo para cada tratamento, o modelador usa variáveis e parâmetros para representar níveis de fatores. Assim, o mesmo modelo-base pode ser reutilizado ao longo de toda a campanha experimental, o que reduz risco de inconsistência entre tratamentos.

O Process Analyzer e o Output Analyzer podem ser úteis como ferramentas de apoio, respectivamente, à execução de múltiplos cenários e à análise das saídas. Entretanto, do ponto de vista deste livro, o mais importante não é o domínio detalhado da interface, mas a compreensão de que o simulador deve ser subordinado ao protocolo experimental, e não o contrário.

14.16.4 Comentários sobre OpenModelica e Ptolemy II

A lógica do experimento independe do simulador utilizado. Em OpenModelica, por exemplo, a experimentação costuma ser conduzida por parametrização do modelo, sobrescrita de parâmetros, execução em lote e posterior coleta de respostas. Em Ptolemy II, a estrutura do modelo lógico ou híbrido pode ser submetida a campanhas variando limiares, temporizações, ganhos ou políticas modais. O que muda entre ferramentas não é a essência metodológica do experimento, mas a infraestrutura prática de automação e coleta de saídas.

14.17 Além do Escopo Principal: Pontos Centrais, Superfícies de Resposta, Metamodelagem e Simulação-Otimização

Embora o corpo principal deste capítulo tenha se concentrado em experimentação estruturada com foco especial nos planejamentos fatoriais de dois níveis, é importante situar o leitor em relação a extensões relevantes da área.

14.17.1 Pontos Centrais e Curvatura

Quando há suspeita de que a resposta não varie linearmente na região experimental, pode ser útil adicionar **pontos centrais** ao experimento. Esses pontos ajudam a detectar **curvatura** e podem servir como ponte para modelos de segunda ordem.

14.17.2 Superfícies de Resposta

Os métodos de superfície de resposta ampliam a lógica de DOE para construção de modelos empíricos mais ricos, frequentemente quadráticos, capazes de descrever melhor o comportamento local da resposta em torno de regiões de interesse. Esses métodos são extremamente importantes, mas seu desenvolvimento completo extrapola o foco principal deste capítulo. Aqui basta registrar sua existência e seu papel como continuação natural do planejamento experimental.

14.17.3 Metamodelagem em Sentido Ampliado

A regressão linear usada em planejamentos 2^k pode ser vista como a forma mais elementar de **metamodelagem**. Em abordagens mais modernas, metamodelos podem assumir formas mais sofisticadas, servindo para:

- resumir superfícies de resposta complexas;
- acelerar exploração do espaço de fatores;
- reduzir custo computacional;
- e apoiar algoritmos de otimização.

14.17.4 Data Farming e Simulação-Otimização

Em campanhas muito amplas, a experimentação pode assumir caráter de *data farming*, em que um grande número de corridas é produzido sistematicamente para posterior mineração e análise. Em outro extremo, a experimentação pode ser acoplada a algoritmos de busca, formando sistemas de **simulação-otimização**. Ambos os temas são desdobramentos naturais do presente capítulo, mas serão apenas situados aqui, sem aprofundamento.

14.18 Considerações Finais

Este capítulo procurou mostrar que a experimentação em simulação é uma atividade metodologicamente rica, e não uma simples repetição mecânica de corridas do modelo. Planejar experimentos de simulação significa decidir o que medir, que fatores variar, como organizar tratamentos e replicações, como lidar com warm-up e horizonte de corrida, como controlar variabilidade e como estruturar uma campanha experimental que produza informação útil e não apenas volume de saídas.

Também se procurou mostrar que a experimentação em simulação é mais ampla do que o planejamento fatorial clássico, embora este permaneça uma de suas ferramentas centrais. Comparação entre configurações, organização das corridas, eficiência estatística, controle do orçamento computacional e metamodelagem são igualmente partes do problema. Dentro desse quadro mais amplo, os planejamentos 2^k , $(2^k).r$, 2^{k-p} e $(2^{k-p}).r$ ocupam papel especial por oferecerem linguagem estruturada para estudar múltiplos fatores e suas interações.

Por fim, o capítulo reforça que DOE e ANOVA não pertencem apenas à estatística abstrata. Em simulação, eles se tornam instrumentos concretos para investigar comportamento do modelo, identificar fatores relevantes, compreender interações, resumir respostas por meio de metamodelos e organizar campanhas experimentais defensáveis. Com isso, o leitor está preparado para avançar ao próximo capítulo, no qual o foco se deslocará da estrutura do experimento para a análise estatística dos resultados produzidos por essas campanhas experimentais.

14.19 Exercícios Propostos

Exercício 14.1 Explique por que executar várias corridas de simulação sem um planejamento experimental explícito pode ser metodologicamente inadequado, mesmo quando o modelo já foi verificado e validado.

Exercício 14.2 Diferencie, no contexto de simulação:

1. fator;
2. nível;
3. tratamento;
4. corrida;
5. replicação;
6. campanha experimental.

Exercício 14.3 Explique a diferença entre um experimento terminante e um experimento em estado estacionário. Dê um exemplo de cada um.

Exercício 14.4 Discuta por que warm-up pode ser importante em certos experimentos de simulação e irrelevante em outros.

Exercício 14.5 Suponha que um sistema de filas em regime contínuo esteja sendo estudado. Explique por que a escolha do horizonte de corrida influencia a qualidade das estimativas obtidas.

Exercício 14.6 Em um estudo com quatro configurações alternativas de um sistema, explique por que realizar apenas testes binários sucessivos entre pares pode ser metodologicamente insatisfatório.

Exercício 14.7 Considere um experimento com $a = 3$ tratamentos e $n = 4$ observações por tratamento. Escreva as expressões de SS_T , SS_{Trat} , SS_E , MS_{Trat} , MS_E e F_0 .

Exercício 14.8 Em um experimento 2^2 , considere os fatores A e B , com médias observadas:

	$B(-1)$	$B(+1)$
$A(-1)$	10	18
$A(+1)$	6	11

Calcule:

1. o efeito principal de A ;
2. o efeito principal de B ;
3. a interação AB .

Exercício 14.9 Explique, com suas próprias palavras, o significado operacional de uma interação entre fatores em um experimento de simulação.

Exercício 14.10 Mostre por que a codificação em -1 e $+1$ é conveniente em planejamentos fatoriais de dois níveis.

Exercício 14.11 Quantos tratamentos existem em:

1. um planejamento 2^4 ;
2. um planejamento $(2^4)_{.3}$;
3. um planejamento 2^{6-2} ;
4. um planejamento $(2^{6-2})_{.5}$?

Exercício 14.12 Explique a diferença entre um planejamento completo 2^k e um planejamento fracionário 2^{k-p} .

Exercício 14.13 Considere uma meia fração de um experimento 2^3 com gerador $C = AB$. Escreva a relação definidora e mostre as principais relações de aliasamento.

Exercício 14.14 Explique a ideia de resolução em planejamentos fatoriais fracionários e discuta por que ela é importante.

Exercício 14.15 Explique por que o projeto $(2^{k-p})_r$ pode ser visto como o caso mais geral da família de planejamentos fatoriais binários tratados neste capítulo.

Exercício 14.16 Escreva a forma geral do modelo de regressão linear associado a um planejamento fatorial 2^k com variáveis codificadas.

Exercício 14.17 Mostre a relação entre efeito principal e coeficiente de regressão em um planejamento 2^k balanceado com variáveis codificadas em -1 e $+1$.

Exercício 14.18 Explique a diferença entre:

1. usar o modelo de simulação;
2. usar um metamodelo ajustado aos resultados do experimento.

Exercício 14.19 Projete conceitualmente uma campanha experimental para um modelo em Arena com os seguintes fatores:

- número de atendentes;
- tempo médio de atendimento;
- política de prioridade.

Defina:

1. fatores;
2. níveis;
3. resposta principal;
4. número de replicações;
5. necessidade ou não de warm-up;
6. projeto experimental inicial sugerido.

Exercício 14.20 Discuta criticamente a seguinte afirmação: Um bom planejamento experimental em simulação precisa equilibrar profundidade estatística, custo computacional e utilidade prática das respostas observadas.

Base bibliográfica do capítulo. Este capítulo se apoia principalmente em Law [29] como referência central para experimentação com modelos de simulação, incluindo organização de corridas, replicações, tratamento de saídas, comparação entre configurações e relação entre custo computacional e precisão estatística. O tratamento de projetos experimentais fatoriais, análise de variância, efeitos principais, interações, projetos 2^k , 2^{k-p} , projetos replicados e o modelo de regressão linear associado ao experimento se apoia principalmente em Montgomery [34]. A instrumentação prática da execução de campanhas experimentais em modelos discretos utiliza como apoio adicional Kelton, Sadowski e Zupick [24] e o manual do Arena [42]. Para o enquadramento mais amplo e contemporâneo do capítulo, especialmente nas observações sobre metamodelagem, otimização e uso de projetos experimentais com simulação discreta, também servem de base Barton [7], Gjerloev et al. [17] e Miranda et al. [10].