



15. Análise Estatística dos Resultados e Otimização de Modelos

15.1 Introdução

Nos capítulos anteriores, o leitor acompanhou a formulação do problema, a construção do modelo, a escolha do paradigma de modelagem, a preparação dos dados, a verificação, a validação e, por fim, o planejamento e a execução dos experimentos de simulação. Entretanto, a realização das corridas não encerra o trabalho técnico-científico. A simulação produz observações, trajetórias e estatísticas; o que transforma essas saídas em evidência útil é sua análise estatística e sua interpretação à luz dos objetivos do projeto.

Esse ponto é central. Uma média observada em uma ou poucas corridas não equivale automaticamente a uma estimativa confiável do comportamento do sistema modelado. Em modelos estocásticos, a própria saída é aleatória. Em modelos dinâmicos, pode haver transiente inicial, dependência temporal entre observações, variabilidade entre replicações e incerteza residual sobre os parâmetros de entrada. Portanto, sem inferência estatística adequada, sem controle de precisão e sem critérios claros de comparação, a simulação corre o risco de se reduzir a mera geração de números.

Base bibliográfica do capítulo. Este capítulo se apoia principalmente em [29], [34], [24] e [36]. A parte relativa à análise estatística das saídas e comparação entre alternativas utiliza

especialmente a tradição consolidada da análise de resultados em simulação. A parte final, sobre otimização, dialoga com resposta em superfície, metamodelagem e busca por melhores configurações, permanecendo, contudo, em nível introdutório no corpo principal deste livro.

A função deste capítulo, portanto, é dupla. Em primeiro lugar, discutir como estimar, com precisão controlada, medidas de desempenho extraídas de modelos de simulação. Em segundo lugar, mostrar como essas estimativas podem sustentar comparação entre configurações e até orientar a busca de melhores soluções, isto é, a **otimização de modelos**. Com isso, o texto fecha um ciclo metodológico importante do livro: depois de modelar, verificar, validar, planejar e executar, é preciso analisar, interpretar, comparar e decidir.

A figura 15.1 sintetiza essa mudança de foco. Ela mostra que a execução do modelo não é o último passo da investigação, mas apenas a origem dos dados que serão posteriormente estimados, comparados e utilizados em processos de decisão e otimização.




Figura 15.1: Fluxo conceitual que liga corridas de simulação, estimação estatística, comparação entre alternativas, apoio à decisão e otimização.

15.2 Natureza Estatística das Saídas de Simulação

Toda análise de saídas de simulação começa por uma distinção simples, mas decisiva: a diferença entre a *resposta observada* em uma corrida e o **parâmetro de interesse** do sistema modelado. Em uma execução específica, pode-se observar, por exemplo, tempo médio em fila igual a 12,8 minutos, utilização média de um recurso igual a 0,83 ou custo acumulado igual a 4.250 unidades monetárias. Esses valores, contudo, não são normalmente quantidades determinísticas do sistema; são realizações particulares de variáveis aleatórias associadas ao comportamento do modelo.

Se denotarmos por Y uma variável-resposta de interesse, o que geralmente se deseja conhecer não é uma realização específica de Y , mas alguma característica de sua distribuição, como a média $E[Y]$, a variância $\text{Var}(Y)$, um quantil $Q_p(Y)$, uma probabilidade $P(Y \leq c)$ ou a diferença entre médias sob duas configurações. A simulação fornece amostras dessas quanti-

dades, e a análise estatística procura inferir, a partir dessas amostras, valores plausíveis para os parâmetros correspondentes.

15.2.1 Estimadores e Erro de Estimação

Essa distinção entre observação e parâmetro permite compreender por que a linguagem de estimadores é central neste capítulo. Se $Y_1, Y_2, \dots, Y_n$ representam n observações independentes de uma mesma medida-resposta, então a média amostral

$$\bar{Y}(n) = \frac{1}{n} \sum_{i=1}^n Y_i$$

é um estimador natural de $E[Y]$. De modo análogo, a variância amostral

$$S_Y^2(n) = \frac{1}{n-1} \sum_{i=1}^n (Y_i - \bar{Y}(n))^2$$

é usada para estimar a variabilidade entre observações.

Entretanto, uma estimativa pontual isoladamente não basta. É necessário quantificar sua incerteza. É exatamente aqui que entram conceitos como erro padrão, intervalo de confiança e precisão desejada. Sob hipóteses usuais, um intervalo de confiança aproximado de nível $100(1 - \alpha)\%$ para $E[Y]$ pode ser escrito como

$$\bar{Y}(n) \pm t_{1-\alpha/2, n-1} \sqrt{\frac{S_Y^2(n)}{n}},$$

em que $t_{1-\alpha/2, n-1}$ é o quantil apropriado da distribuição t de Student. A metade da largura desse intervalo,

$$h = t_{1-\alpha/2, n-1} \sqrt{\frac{S_Y^2(n)}{n}},$$

é particularmente importante em simulação, pois expressa diretamente a precisão com que o resultado está sendo reportado.

15.2.2 Precisão, Viés e Incerteza

Em um projeto de simulação, a qualidade de uma estimativa não depende apenas de quão próxima ela parece estar do valor real, mas também de quão grande é a incerteza que a acompanha. Em termos práticos, isso significa que uma média estimada deve ser sempre lida conjuntamente com algum indicador de precisão. Sem isso, duas estimativas numericamente próximas podem ter significados completamente diferentes: uma pode ter sido obtida com excelente controle estatístico, enquanto a outra pode estar associada a grande variabilidade.

Também convém distinguir **viés** e **variabilidade**. O viés está associado a erro sistemático, isto é, à diferença entre o valor esperado do estimador e o parâmetro verdadeiro. A variabilidade está associada às flutuações entre diferentes amostras ou replicações. Em muitos problemas de simulação, a maior preocupação prática imediata é a variabilidade estocástica das saídas. Contudo, em simulações de regime permanente ou em estudos com aquecimento inadequado, viés e variabilidade podem coexistir, e essa distinção passa a ser especialmente importante.

15.2.3 Significância Estatística e Relevância Prática

Outra distinção essencial é entre **significância estatística** e **relevância prática**. Uma diferença muito pequena entre duas alternativas pode ser detectável com amostra suficientemente grande e, ainda assim, ser irrelevante do ponto de vista do problema de engenharia ou gestão. Da mesma forma, uma diferença potencialmente importante em termos operacionais pode não ser estatisticamente conclusiva se o número de observações for insuficiente ou se a variabilidade for muito elevada.

Assim, a interpretação dos resultados de simulação não pode ser reduzida a um procedimento mecânico de cálculo de intervalos ou de observação de sobreposição entre médias. O analista precisa sempre recolocar a estimativa no contexto do projeto: o erro máximo admissível é pequeno ou grande? Uma diferença de 2% é desprezível ou decisiva? A resposta a essas perguntas não é dada apenas pela estatística; ela depende do sistema e do objetivo do estudo.

15.3 Análise de Saídas em Simulações Terminantes

Em **simulações terminantes**, existe uma condição natural de término da corrida. Pode ser o fim de um dia de operação, o término de uma jornada, o processamento de um lote, a conclusão de uma missão ou a ocorrência de um evento final bem definido. Nesses casos, a análise estatística é conceitualmente mais simples, pois cada corrida completa pode ser tratada como uma observação de uma variável aleatória associada ao desempenho do sistema naquele horizonte.

A figura 15.2 antecipa a diferença fundamental entre esse caso e a análise em regime permanente. Em simulações terminantes, é natural trabalhar com replicações independentes completas. Em regime permanente, como será discutido adiante, a estrutura temporal das observações exige mais cuidado.

15.3.1 Replicações Independentes

Suponha que se executem n replicações independentes de um mesmo modelo terminante, cada uma produzindo uma observação Y_i da resposta de interesse, como custo total por dia, tempo médio no sistema ao longo do turno ou número total de entidades atendidas. A independência entre replicações decorre de condições iniciais equivalentes e de sequências aleatórias independentes. Então a média amostral $\bar{Y}(n)$ e a variância amostral $S_Y^2(n)$ permitem estimar a média




Figura 15.2: Comparação conceitual entre a análise de saídas em experimentos terminantes e em experimentos voltados ao regime permanente.

verdadeira $E[Y]$ e construir intervalos de confiança da forma apresentada anteriormente.

Esse é o caso mais favorável para análise estatística de saídas, porque a estrutura de dados é naturalmente organizada em replicações. Ainda assim, alguns cuidados permanecem necessários. O primeiro é garantir que as replicações sejam realmente independentes, o que exige atenção ao uso de sementes, fluxos de números aleatórios e reinicialização apropriada do modelo. O segundo é escolher um número de replicações compatível com a precisão desejada. O terceiro é verificar se a variável-resposta escolhida é, de fato, representativa do fenômeno que se pretende analisar.

15.3.2 Intervalos de Confiança e Precisão

Se $Y_1, \dots, Y_n$ são observações independentes da variável de interesse, então o intervalo

$$\bar{Y}(n) \pm t_{1-\alpha/2, n-1} \sqrt{\frac{S_Y^2(n)}{n}}$$

é a principal ferramenta de estimação neste contexto. Em termos práticos, sua interpretação é simples: ele fornece uma faixa plausível para o valor médio da resposta, levando em conta a variabilidade entre replicações e o número de observações disponíveis.

A semi-amplitude

$$h = t_{1-\alpha/2, n-1} \sqrt{\frac{S_Y^2(n)}{n}}$$

mede a largura dessa incerteza em torno da média amostral. Em aplicações de simulação, o controle de h é muito mais útil do que a simples apresentação de $\bar{Y}(n)$, porque permite avaliar se o esforço experimental realizado foi suficiente para sustentar a conclusão desejada.

15.3.3 Determinação do Número de Replicações

Uma forma prática de controlar o número de replicações é utilizar um procedimento sequencial. Executam-se inicialmente algumas corridas independentes, calcula-se a semi-amplitude h do intervalo de confiança e verifica-se se ela atende ao requisito de precisão. Se o objetivo for, por exemplo, obter erro relativo inferior a γ , pode-se exigir

$$h \leq \gamma \bar{Y}(n),$$

desde que a média observada seja estritamente positiva e que o uso de erro relativo faça sentido para a variável em análise.

Caso a condição não seja satisfeita, novas replicações são realizadas até que a precisão desejada seja atingida. Esse procedimento é especialmente adequado em estudos aplicados porque evita tanto o subdimensionamento quanto o excesso de corridas. Planejar um número fixo de replicações antes de qualquer evidência empírica pode ser ineficiente: às vezes é pouco, às vezes é muito mais do que o necessário.

15.3.4 Comentários Práticos

Em modelos implementados em Arena, a lógica anterior aparece de forma bastante natural. Ao definir múltiplas replicações independentes e observar os relatórios do software, o analista pode acessar não apenas médias estimadas das principais medidas de desempenho, mas também semi-amplitudes associadas. Isso permite avaliar imediatamente a precisão do experimento e decidir se novas corridas são necessárias.

Essa prática é muito importante no ensino. Muitos usuários iniciantes de simuladores tendem a se fixar apenas no valor médio apresentado nos relatórios. O hábito correto, no entanto, é sempre ler a média juntamente com sua incerteza. Essa mudança de postura, embora conceitualmente elementar, distingue o uso profissional da simulação da simples inspeção informal de números gerados pelo software.

15.4 Análise de Saídas em Regime Permanente

Em muitos sistemas, o objetivo do estudo não está associado a um horizonte natural de término, mas ao comportamento de longo prazo. É o caso de redes de filas, linhas de produção

contínuas, sistemas de comunicação, sistemas computacionais e diversos processos de atendimento operando continuamente. Nesses contextos, deseja-se estimar medidas de desempenho em **regime permanente**, como número médio em fila, tempo médio no sistema em longo prazo, utilização média de recursos ou taxa média de produção.

A dificuldade estatística aqui é maior. Ao contrário do caso terminante, uma longa trajetória de um sistema em regime permanente não produz observações naturalmente independentes. Pelo contrário, as observações sucessivas de uma variável de saída costumam apresentar **correlação serial**. Se o número de entidades em fila é alto em um certo instante, é bastante plausível que continue relativamente alto em instantes próximos. Essa dependência temporal inviabiliza o uso ingênuo das fórmulas clássicas de intervalo de confiança baseadas em independência amostral.

Há ainda um segundo problema: o **transiente inicial**. Muitos modelos são inicializados em condições artificiais, frequentemente com filas vazias, recursos ociosos e estoques em condições ideais. Essas condições raramente correspondem ao comportamento típico de longo prazo do sistema. Se os dados iniciais forem usados diretamente na estimação, o resultado tende a ser enviesado. Surge então a necessidade de identificar um período inicial de aquecimento, ou *warm-up*, que será descartado da análise.

15.4.1 Replicação com Deleção

Uma estratégia muito utilizada para média em regime permanente é o método de **replicação e deleção**. Nele, realizam-se várias replicações independentes longas; em cada uma, descarta-se um período inicial l e a média é calculada apenas sobre a parte remanescente da corrida. Se denotarmos por Y_{ij} a j -ésima observação da i -ésima replicação e por m o número de observações retidas após a deleção do aquecimento, então a média da i -ésima replicação pode ser escrita como

$$\bar{Y}_i(m) = \frac{1}{m} \sum_{j=1}^m Y_{ij}.$$

As quantidades $\bar{Y}_1(m), \bar{Y}_2(m), \dots, \bar{Y}_n(m)$ passam então a desempenhar o papel de observações aproximadamente independentes, e a análise pode prosseguir de modo análogo ao caso terminante. A principal dificuldade prática está em escolher um período de aquecimento suficientemente longo para reduzir o viés de inicialização, mas não tão longo a ponto de desperdiçar excessivamente a corrida.

15.4.2 Correlação Serial

Mesmo após o descarte do aquecimento, as observações obtidas ao longo de uma trajetória de regime permanente tendem a ser dependentes. Essa **correlação serial** implica que o número de observações registradas não coincide com o número efetivo de observações independentes. Em consequência, métodos que usam diretamente todas as observações como se fossem

independentes subestimam a variância da estimativa e produzem intervalos de confiança artificialmente estreitos.

Em termos intuitivos, o problema é simples. Se duas observações são muito próximas no tempo, elas carregam informação parcialmente redundante sobre o estado do sistema. Portanto, o ganho estatístico de acumular observações altamente correlacionadas é menor do que sugeriria sua simples contagem.


15.4.3 Método de *Batch Means*

Uma alternativa importante para análise em regime permanente é o método de **batch means**. A ideia é executar uma única corrida longa, ou um número pequeno de corridas muito longas, após eventual descarte do aquecimento, e então dividir a trajetória restante em n lotes consecutivos de tamanho k . Se $Y_1, Y_2, \dots, Y_{nk}$ são as observações pós-aquecimento, define-se a média do lote j por

$$\bar{Y}_j^{(k)} = \frac{1}{k} \sum_{i=(j-1)k+1}^{jk} Y_i, \quad j = 1, 2, \dots, n.$$

Se k for suficientemente grande, essas médias de lote tendem a ser menos correlacionadas entre si do que as observações originais. Nesse caso, $\bar{Y}_1^{(k)}, \dots, \bar{Y}_n^{(k)}$ podem ser tratadas aproximadamente como observações independentes para fins de estimação da variância e construção de intervalo de confiança.

A figura 15.3 ilustra essa ideia.



Após o descarte do transiente inicial, a trajetória remanescente é dividida em lotes consecutivos. As médias desses lotes são usadas como observações aproximadamente independentes para fins de estimação.

Figura 15.3: Esquema conceitual do método de *batch means*: após o descarte do aquecimento, uma trajetória longa é dividida em lotes consecutivos, e as médias desses lotes são usadas na estimação estatística.

O principal desafio prático do método é escolher um tamanho de lote grande o bastante para reduzir a autocorrelação entre médias de lote, mas não tão grande a ponto de restarem poucos lotes para estimação da variância. Lotes muito pequenos mantêm dependência excessiva; lotes grandes demais reduzem drasticamente o tamanho efetivo da amostra.

15.4.4 Comentários Práticos

Arena oferece suporte direto a essa lógica para análise em regime permanente. O software pode formar lotes automaticamente e tentar construir intervalos de confiança por *batch means*; além disso, se houver aquecimento especificado, os dados dessa fase inicial não são usados nesse cálculo. Isso mostra de forma bastante concreta como a teoria estatística do capítulo se traduz em operação prática: aquecimento, lotes, precisão e comparação não são apenas ideias abstratas, mas escolhas efetivas no uso da ferramenta.

Do ponto de vista didático, convém registrar uma recomendação prudente. Sempre que a estrutura do problema permitir uma formulação terminante coerente com o objetivo do estudo, esta costuma ser preferível do ponto de vista estatístico. A análise em regime permanente é poderosa e necessária em muitos casos, mas introduz dificuldades adicionais: definição de aquecimento, dependência temporal, escolha de tamanho de lote e maior sensibilidade à duração da corrida.

15.5 Comparação Estatística entre Configurações Simuladas

Depois de estimar adequadamente uma medida de desempenho para uma única configuração, o passo seguinte, em muitos estudos, é comparar alternativas. Pode-se desejar comparar duas políticas de atendimento, dois tamanhos de equipe, duas capacidades de recurso, duas regras de prioridade ou duas arquiteturas de sistema. Em outros casos, há um conjunto maior de configurações candidatas, e o problema deixa de ser apenas estimar para passar a ser selecionar.

A figura 15.4 resume essa progressão conceitual. Primeiro, estimam-se medidas de desempenho para cada configuração. Em seguida, comparam-se as alternativas. Em certos problemas, isso basta para apoiar uma decisão. Em outros, é necessário selecionar explicitamente a melhor alternativa entre várias ou, indo além, buscar sistematicamente configurações superiores por meio de otimização.

15.5.1 Comparação de Duas Configurações

Considere inicialmente duas configurações, A e B , e uma medida de desempenho cujo valor esperado em cada uma delas seja μ_A e μ_B . O interesse pode recair sobre a diferença

$$\delta = \mu_A - \mu_B.$$

Se a variável-resposta for algo a ser minimizado, como tempo médio em fila, então valores negativos de δ favorecem A . Se for algo a ser maximizado, como *throughput*, a interpretação se inverte. Em qualquer caso, o ponto central é que comparar apenas médias observadas $\bar{Y}_A$ e $\bar{Y}_B$ não basta; é preciso quantificar a incerteza da diferença.

Se forem obtidas n observações independentes para cada configuração, a comparação pode ser feita a partir da diferença entre as médias amostrais. Em contexto introdutório, esse é




Figura 15.4: Relação conceitual entre estimação de desempenho, comparação entre alternativas, seleção de configurações e otimização por simulação.

o caso mais simples. Contudo, ele nem sempre é o mais eficiente do ponto de vista estatístico, pois trata as duas séries de saídas como completamente independentes, mesmo quando parte da variabilidade poderia ser controlada.

15.5.2 Comparações Pareadas e *Common Random Numbers*

Quando as observações das duas configurações podem ser organizadas em pares comparáveis, uma estratégia muito eficiente consiste em usar **common random numbers**. Nesse caso, cada par de corridas das alternativas *A* e *B* é executado sob condições aleatórias comparáveis, de modo que parte da variabilidade comum se cancele na diferença. Se $D_i = Y_{Ai} - Y_{Bi}$, então a comparação pode ser feita com base na amostra $D_1, \dots, D_n$, e um intervalo de confiança para δ pode ser construído a partir da média $\bar{D}(n)$ e da variância amostral das diferenças:

$$\bar{D}(n) \pm t_{1-\alpha/2, n-1} \sqrt{\frac{S_D^2(n)}{n}}.$$

O ganho desse procedimento está em que, quando as saídas são positivamente correlacionadas sob o pareamento, a variância de D_i pode ser significativamente menor do que a soma das variâncias individuais. Em linguagem prática, isso significa comparação mais precisa com o mesmo número de corridas. Naturalmente, o método só faz sentido quando o pareamento é metodologicamente justificável; não se trata de simplesmente reutilizar sementes ao acaso, mas de construir pares comparáveis de experimentos.

15.5.3 Comparação de Múltiplas Configurações

Quando há mais de duas alternativas, a situação torna-se mais complexa. Comparações múltiplas por inspeção visual de médias observadas podem ser enganosas, sobretudo quando o número de configurações cresce. Nesses casos, entram em cena estratégias de comparação múltipla, comparação com um padrão e procedimentos de seleção entre alternativas.

Do ponto de vista conceitual, há pelo menos três situações distintas:

1. comparar cada alternativa com uma configuração de referência;
2. comparar todas as alternativas entre si;
3. determinar qual delas é, com evidência estatística suficiente, a melhor.

Essas três situações não são equivalentes. A primeira é comum quando existe uma política operacional atualmente usada e se deseja avaliar se novas propostas a superam. A segunda é útil quando se quer mapear um pequeno conjunto de candidatas. A terceira é metodologicamente mais exigente, pois envolve transformar evidência estatística em decisão de seleção.

15.5.4 Seleção entre Alternativas

O conceito de **ranking and selection** é especialmente relevante quando o objetivo é escolher a melhor entre várias alternativas simuladas. Aqui, o problema não é apenas dizer se duas médias diferem, mas decidir qual configuração deve ser recomendada, controlando o risco de selecionar incorretamente uma alternativa subótima.

Em nível introdutório, basta ao leitor perceber duas ideias. A primeira é que o problema de selecionar a melhor é mais forte do que o problema de detectar diferenças. A segunda é que a confiança nessa seleção depende não apenas da magnitude das diferenças entre alternativas, mas também da variabilidade das saídas e do esforço experimental empregado. Quando várias configurações apresentam desempenhos muito próximos, selecionar a melhor exige mais informação do que quando uma delas domina claramente as demais.

Em aplicações reais, a comparação entre alternativas deve ser sempre acompanhada de duas perguntas adicionais. A primeira é se a diferença observada é estatisticamente sustentada. A segunda é se, mesmo sendo sustentada, ela é relevante em termos de operação, custo, risco ou benefício prático. Uma redução de 0,2% no custo médio pode ser estatisticamente detectável, mas irrelevante diante do esforço de implementação exigido por uma nova política. O inverso também ocorre: uma diferença potencialmente importante pode demandar mais replicações para ser estabelecida com segurança.

15.6 Interpretação dos Resultados e Apoio à Decisão

A análise estatística não se encerra no cálculo de médias, variâncias e intervalos. Em projetos de modelagem e simulação, esses resultados precisam ser interpretados em função do problema original. É neste ponto que o capítulo reencontra, de modo mais explícito, a finalidade aplicada do livro: usar modelos e experimentos computacionais para apoiar decisão técnica, científica ou gerencial.

Uma recomendação importante é que os resultados sejam organizados de maneira comparável e transparente. Em vez de apresentar ao decisor grandes tabelas de saída do simulador, é mais adequado selecionar um conjunto pequeno de medidas realmente relevantes, indicar as estimativas associadas e explicitar sua precisão. Em muitos contextos, uma tabela con-

tendo, para cada alternativa, média estimada, semi-amplitude do intervalo de confiança, custo associado e observações sobre restrições operacionais é mais informativa do que um relatório extenso do software.

Outro aspecto central é a **robustez** da recomendação. Uma alternativa pode ser ligeiramente melhor do que outra nas condições centrais analisadas, mas muito mais sensível a variações de entrada, a hipóteses de modelagem ou a mudanças nas condições de operação. Nesse caso, a melhor média observada não coincide necessariamente com a melhor escolha. A análise de sensibilidade, o exame de cenários e a observação da estabilidade dos resultados sob pequenas perturbações ajudam a distinguir soluções apenas localmente atrativas de soluções robustas.

Em estudos com múltiplas respostas, a interpretação torna-se ainda mais sutil. É comum que uma alternativa melhore um indicador e piore outro. Por exemplo, aumentar agressivamente a utilização de recursos pode elevar *throughput*, mas também aumentar filas e risco de congestionamento. Reduzir estoques pode diminuir custo de capital, mas aumentar vulnerabilidade a atrasos de suprimento. Nessas situações, não há decisão natural sem explicitação de prioridades, pesos, metas ou restrições.

Por isso, o apoio à decisão exige que o modelador vá além do formalismo estatístico e articule, com clareza, critérios técnicos de recomendação. Em termos gerais, esses critérios costumam envolver desempenho médio, variabilidade, custo, risco, facilidade de implementação e aderência a restrições operacionais. Uma boa análise de saídas não termina apenas com números corretos; ela termina com recomendações tecnicamente justificadas, incluindo, quando necessário, ressalvas e limites de confiança.

15.7 Otimização de Modelos de Simulação

A partir do momento em que o analista deixa de apenas comparar algumas alternativas previamente definidas e passa a procurar sistematicamente a melhor configuração possível, o problema assume caráter de **otimização por simulação**. Em termos abstratos, deseja-se escolher um vetor de variáveis de decisão x pertencente a uma região viável $\mathcal{X}$, de modo a otimizar uma ou mais respostas do modelo. Em formulação escalar, isso pode ser escrito como

$$\min_{x \in \mathcal{X}} E[Y(x)]$$

ou

$$\max_{x \in \mathcal{X}} E[Y(x)],$$

dependendo do objetivo. Aqui, $Y(x)$ é uma resposta aleatória produzida pela simulação sob a configuração x .

A figura 15.5 ilustra a ideia geral desse processo. Parte-se de uma configuração candidata, executa-se o modelo, analisam-se estatisticamente as respostas, atualizam-se as decisões e gera-se uma nova configuração a ser avaliada. Em termos conceituais, o laço une modelagem, experimentação, inferência e busca por melhores soluções.




Figura 15.5: Esquema geral de um processo de otimização por simulação, no qual decisões geram novas configurações, o simulador produz respostas e a análise estatística orienta a próxima iteração de busca.

15.7.1 Análise de Sensibilidade, Comparação e Otimização

Do ponto de vista conceitual, é importante distinguir três níveis. O primeiro é a **análise de sensibilidade**, em que se observa como a resposta muda quando parâmetros variam. O segundo é a **comparação entre alternativas**, em que um conjunto finito e previamente definido de configurações é comparado. O terceiro é a **otimização**, em que o objetivo é buscar sistematicamente configurações melhores, possivelmente em um espaço grande ou contínuo de possibilidades. Embora relacionados, esses três níveis não são equivalentes.

Na análise de sensibilidade, o foco recai sobre influência e compreensão do sistema. Na comparação, o foco recai sobre escolher entre candidatas já definidas. Na otimização, o foco recai sobre geração e refinamento sistemático de candidatas em busca de desempenho superior. Em termos metodológicos, a otimização é, portanto, a etapa mais exigente dessas três, pois combina exploração do espaço de decisão, custo computacional e incerteza estatística.

15.7.2 Busca Enumerativa e Busca Guiada

Em problemas pequenos, uma abordagem viável é a enumeração de todas as configurações candidatas. Se houver poucos fatores discretos e poucos níveis, pode ser possível simular cada combinação, estimar seu desempenho e selecionar a melhor. Essa abordagem tem a vantagem da simplicidade e da transparência, mas se torna rapidamente inviável quando o espaço de decisão cresce.

Por isso, muitos problemas exigem algum tipo de busca guiada. Essa busca pode assu-

mir formas bastante diferentes: exploração local, métodos heurísticos, metaheurísticas, busca por regiões promissoras, estratégias adaptativas ou uso de modelos substitutos. O que todas têm em comum é a tentativa de extrair o máximo de informação de um número limitado de avaliações do simulador.

15.7.3 Metamodelagem e Resposta em Superfície

Uma abordagem particularmente útil para problemas de otimização com poucos fatores contínuos é a construção de **metamodelos** ou modelos substitutos. A ideia é usar dados provenientes de um experimento de simulação para ajustar um modelo empírico mais simples, frequentemente de regressão, capaz de aproximar o comportamento da resposta em certa região. É nesse contexto que a metodologia de superfície de resposta reaparece com naturalidade.

Se $x = (x_1, \dots, x_k)$, pode-se ajustar, por exemplo, um modelo de segunda ordem da forma

$$\hat{y}(x) = \beta_0 + \sum_{i=1}^k \beta_i x_i + \sum_{i=1}^k \beta_{ii} x_i^2 + \sum_{i < j} \beta_{ij} x_i x_j.$$

Esse metamodelo não substitui o simulador em termos ontológicos, mas pode servir como aproximação local para orientar busca, detectar curvatura, localizar regiões promissoras ou realizar otimização restrita com custo muito menor do que a avaliação direta do simulador a cada iteração.

Do ponto de vista pedagógico, é importante deixar claro que metamodelagem não é trapaça nem abandono da simulação. Ao contrário, trata-se de um uso inteligente dos resultados simulados para construir uma representação auxiliar da resposta, adequada a tarefas de análise e otimização.

15.7.4 Múltiplas Respostas e Desejabilidade

Quando há múltiplas respostas, o problema de otimização deixa de ser naturalmente unidimensional. Uma solução pode ser melhor em custo e pior em nível de serviço; melhor em produtividade e pior em robustez; melhor em tempo e pior em consumo energético. Nesses casos, surgem formulações de **otimização multiobjetivo**.

Uma estratégia clássica consiste em transformar várias respostas em uma função agregada de desejabilidade. Se $d_i \in [0, 1]$ representa a desejabilidade da i -ésima resposta, pode-se construir uma desejabilidade global por

$$D = \left(\prod_{i=1}^m d_i \right)^{1/m},$$

e então procurar configurações que maximizem D . Essa técnica é conceitualmente simples e frequentemente útil quando as prioridades entre respostas são conhecidas ou podem ser traduzidas em metas aceitáveis.

Contudo, nem todo problema multiobjetivo deve ser reduzido a um único escalar. Em muitos casos, o interesse recai sobre o conjunto de compromissos entre objetivos conflitantes, isto é, sobre uma fronteira de soluções não dominadas. É exatamente nesse contexto que a noção de soluções de Pareto se torna importante.

15.7.5 Otimização Multiobjetivo e Algoritmos Evolucionários

Em contexto contemporâneo, uma das famílias metodológicas mais importantes para problemas multiobjetivo é a de **algoritmos evolucionários multiobjetivo**. Esses métodos, embora não sejam desenvolvidos em profundidade neste capítulo, merecem registro explícito, pois constituem uma das linhas mais conhecidas de otimização inspirada em inteligência artificial e são particularmente adequados quando a função objetivo é ruidosa, cara de avaliar e potencialmente multimodal.

Em termos gerais, esses algoritmos procuram manter e evoluir um conjunto de soluções candidatas, favorecendo simultaneamente qualidade dos objetivos e diversidade ao longo da fronteira de compromisso. Seu interesse, no contexto deste livro, não está em detalhes algorítmicos específicos, mas no fato de que eles mostram como a simulação pode ser integrada a técnicas modernas de busca para tratar problemas em que não existe uma única solução melhor em todos os critérios.

A figura 15.6 resume, em nível panorâmico, essa expansão do uso da simulação para além da análise estatística tradicional.




Figura 15.6: Panorama conceitual que relaciona análise estatística de saídas, meta-modelagem, inteligência artificial e otimização multiobjetivo no uso contemporâneo da simulação.

O uso mais amplo de simulação com inteligência artificial, incluindo metamodelos mais

sofisticados, aprendizado de resposta e estratégias adaptativas de busca, será retomado em um anexo do livro.

15.8 Sessões Práticas de Análise e Otimização

Nesta seção, o objetivo não é construir tutoriais extensos de ferramenta, mas indicar como os conceitos discutidos até aqui aparecem de forma operacional em ambientes de simulação usados ao longo do livro.

15.8.1 Análise de Saídas em Arena

Em modelos terminantes implementados em Arena, a prática usual consiste em definir número suficiente de replicações independentes, executar o experimento e observar, nos relatórios, as médias e semi-amplitudes das medidas de desempenho relevantes. Esse procedimento é adequado para grande parte dos estudos introdutórios e intermediários, desde que as replicações sejam independentes e o horizonte realmente represente o fenômeno de interesse.

Quando o estudo é de regime permanente, Arena permite configurar período de aquecimento e pode tentar calcular intervalos de confiança por *batch means*. Em situações mais exigentes, o modelador pode exportar a trajetória de observações, formar lotes manualmente no *Output Analyzer* e usar essas médias de lote em comparação entre alternativas. Isso mostra, de forma concreta, como a teoria estatística do capítulo se traduz em operação prática: aquecimento, lotes, precisão e comparação não são apenas ideias abstratas, mas escolhas efetivas no uso da ferramenta.

Outra vantagem prática do ecossistema Arena é a possibilidade de articular análise estatística, comparação de cenários e otimização. Em problemas com número moderado de variáveis de decisão, a integração entre modelagem, experimentação, relatórios e mecanismos de busca torna o ambiente especialmente útil para ensino e para estudos aplicados.

15.8.2 Comparação e Exploração Paramétrica em OpenModelica

Em OpenModelica, a lógica é diferente, mas o princípio metodológico é o mesmo. Em vez de módulos gráficos típicos de simulação discreta, trabalha-se com modelos formulados em Modelica, parâmetros de simulação, varreduras e, quando apropriado, recursos de otimização do ambiente. Uma exploração paramétrica simples pode gerar séries de respostas para diferentes configurações, que depois são comparadas estatisticamente.

Em modelos contínuos, híbridos ou orientados a controle, isso é particularmente útil quando o interesse recai sobre erro, energia, estabilidade, tempo de acomodação ou outras métricas de desempenho derivadas das trajetórias simuladas. O ambiente OMOptim, por exemplo, permite definir parâmetros, objetivos e algoritmos de busca para problemas baseados em modelos Modelica. Mesmo quando essas ferramentas não são usadas exaustivamente no livro, sua existência é pedagogicamente importante, pois mostra ao leitor que a passagem da análise

para a otimização é natural em ecossistemas modernos de modelagem.

15.8.3 Comentários sobre Ptolemy II

Em Ptolemy II, a análise costuma assumir a forma de comparação entre arquiteturas de modelo, combinações de parâmetros e configurações híbridas envolvendo diferentes modelos de computação. Em problemas orientados a sistemas ciberfísicos, redes, modelos híbridos ou estruturas orientadas a atores, o experimento frequentemente consiste em variar atrasos, taxas, limiares, períodos ou condições de transição modal, e então comparar saídas temporais e métricas agregadas.

Embora a infraestrutura estatística nem sempre seja tão diretamente encapsulada quanto em um simulador de eventos discretos orientado a relatórios, os mesmos princípios deste capítulo continuam valendo: replicação quando cabível, definição clara da resposta, comparação formal e interpretação cautelosa.

15.9 Limites, Cuidados e Extensões

A análise estatística de saídas de simulação, por mais consolidada que seja, não elimina automaticamente todas as dificuldades de interpretação. Há pelo menos cinco classes de cuidado que devem acompanhar o uso dos métodos apresentados.

A primeira diz respeito à qualidade do próprio modelo. Não existe análise estatística capaz de compensar um modelo mal verificado, mal validado ou inconsistente com os objetivos do estudo. Resultados muito precisos, quando derivados de um modelo inadequado, continuam sendo irrelevantes ou enganosos. A precisão estatística nunca substitui a credibilidade do modelo.

A segunda diz respeito à escolha da variável-resposta. É comum que modeladores iniciantes extraiam do simulador as estatísticas mais facilmente disponíveis, em vez daquelas mais alinhadas à pergunta do projeto. O problema estatístico começa depois da correta formulação da resposta, e não antes.

A terceira diz respeito ao orçamento computacional. Em problemas de otimização ou de comparação entre muitas alternativas, nem sempre é viável avaliar exaustivamente todo o espaço de configurações com alta precisão. Surge então um compromisso entre número de configurações avaliadas e número de replicações por configuração. Esse compromisso não admite solução universal; depende do custo de cada corrida, da variabilidade da saída e do objetivo do estudo.

A quarta diz respeito a múltiplas fontes de incerteza. Neste capítulo, o foco recaiu sobre a variabilidade estocástica das saídas condicionada ao modelo e às distribuições de entrada adotadas. Em prática mais avançada, há também incerteza de entrada, incerteza paramétrica, incerteza estrutural e até incerteza quanto à adequação do metamodelo usado em uma etapa de otimização. Todas elas podem afetar a robustez da conclusão e justificam abordagens mais

sofisticadas em estudos de maior criticidade.

A quinta, por fim, diz respeito à tentação de automatizar prematuramente a decisão. Ferramentas modernas permitem executar centenas ou milhares de corridas, ajustar modelos substitutos, aplicar algoritmos de busca e exibir soluções aparentemente ótimas. Contudo, a decisão final continua exigindo julgamento técnico. Um algoritmo pode localizar um ótimo numérico do modelo sob certas hipóteses; cabe ao analista decidir se esse ótimo é plausível, interpretável, implementável e coerente com as restrições reais do sistema.

15.10 Considerações Finais

Este capítulo procurou mostrar que a análise estatística dos resultados de simulação não é etapa acessória do estudo, mas o elo que converte saídas numéricas em evidência útil. Em simulações terminantes, a estrutura por replicações independentes favorece procedimentos relativamente diretos de estimação e construção de intervalos de confiança. Em regime permanente, por outro lado, surgem dificuldades adicionais, especialmente devido ao transiente inicial e à dependência temporal entre observações, o que exige maior cuidado metodológico e justifica o uso de estratégias como replicação com deleção e *batch means*.

Também se discutiu que comparar configurações simuladas é problema estatístico próprio, e não simples inspeção de médias observadas. A diferença entre significância estatística e relevância prática, a possibilidade de usar pareamento com *common random numbers*, e o papel de procedimentos de seleção entre alternativas mostram que a simulação se insere naturalmente em uma lógica de inferência e apoio à decisão. Em termos práticos, isso significa que o valor de um experimento de simulação não está apenas em produzir números, mas em permitir conclusões tecnicamente justificadas acerca do sistema modelado e das alternativas avaliadas.

Por fim, a introdução à otimização por simulação procurou estabelecer a continuidade entre análise e melhoria de sistemas. Uma vez que o modelo e seus resultados possam ser analisados de forma confiável, torna-se possível usá-los não apenas para compreender o sistema, mas também para procurar configurações mais vantajosas. Nesse contexto, metamodelagem, resposta em superfície, desejabilidade e otimização multiobjetivo aparecem como extensões naturais do repertório analítico. O uso mais amplo de técnicas baseadas em inteligência artificial e algoritmos evolucionários multiobjetivo foi apenas situado, ficando seu aprofundamento para anexo próprio.

Com isso, encerra-se o bloco central da Parte IV dedicado à análise e ao uso dos resultados. O capítulo seguinte deslocará o foco para a dimensão documental e evolutiva do projeto de simulação, mostrando que a utilidade do modelo depende também de registro adequado, comunicação clara e capacidade de revisão contínua ao longo do ciclo de vida do estudo.

15.11 Exercícios Propostos

Exercício 15.1 Explique, com suas próprias palavras, a diferença entre uma resposta observada em uma corrida de simulação e o parâmetro populacional que se deseja estimar.

Exercício 15.2 Explique por que uma média observada em uma única corrida de simulação não deve ser interpretada automaticamente como valor representativo do sistema modelado.

Exercício 15.3 Diferencie significância estatística de relevância prática no contexto de comparação entre alternativas simuladas.

Exercício 15.4 Explique por que a análise de saídas em regime permanente é, em geral, mais difícil do que a análise de saídas em simulações terminantes.

Exercício 15.5 Descreva o papel do período de aquecimento (*warm-up*) na análise de saídas em regime permanente.

Exercício 15.6 Explique a ideia central do método de *batch means* e a razão pela qual o tamanho do lote é uma escolha crítica.

Exercício 15.7 Diferencie análise de sensibilidade, comparação entre alternativas e otimização por simulação.

Exercício 15.8 Explique por que um ótimo numérico encontrado por um algoritmo de busca não deve ser automaticamente aceito como melhor decisão prática.

Exercício 15.9 Uma simulação terminante foi executada $n = 10$ vezes, produzindo uma média amostral $\bar{Y} = 84,2$ e variância amostral $S_Y^2 = 36$. Escreva a expressão do intervalo de confiança bilateral de 95% para $E[Y]$. Não é necessário substituir o valor do quantil t .

Exercício 15.10 Para uma variável-resposta positiva, deseja-se obter erro relativo máximo de 5%. Escreva a condição envolvendo a semi-amplitude h e a média amostral $\bar{Y}$ que expressa esse requisito.

Exercício 15.11 Considere duas configurações simuladas, A e B , comparadas por meio de n observações pareadas $D_i = Y_{Ai} - Y_{Bi}$. Escreva a forma geral do intervalo de confiança de 95% para a diferença média $\delta = \mu_A - \mu_B$.

Exercício 15.12 Em uma análise de regime permanente, o analista dispõe de uma longa sequência de observações pós-aquecimento $Y_1, \dots, Y_{n_k}$. Defina formalmente a média do lote j no método de *batch means*.

Exercício 15.13 Formule matematicamente um problema de otimização por simulação para minimizar o custo esperado de operação de um sistema sujeito a restrições $g_r(x) \leq 0$, $r = 1, \dots, p$.

Exercício 15.14 Suponha que três respostas de um sistema sejam convertidas em desejabilidades d_1, d_2, d_3 . Escreva a expressão da desejabilidade global D baseada na média geométrica.

Exercício 15.15 Considere um modelo de atendimento em Arena já construído em capítulo anterior. Escolha uma medida de desempenho principal e proponha um procedimento para determinar empiricamente o número de replicações necessário para atingir uma precisão relativa de 10%.

Exercício 15.16 Em um modelo de regime permanente implementado em Arena, descreva um procedimento prático para:

1. identificar a necessidade de *warm-up*;
2. obter médias de lote;

3. verificar se o comprimento da corrida parece suficiente.

Exercício 15.17 Proponha duas configurações concorrentes para um sistema de filas simples, por exemplo, uma com um servidor mais rápido e outra com dois servidores mais lentos. Defina:

1. a variável-resposta principal;
2. uma estratégia de comparação estatística;
3. um critério de recomendação final.

Exercício 15.18 Escolha um modelo contínuo ou híbrido em OpenModelica já visto no livro e descreva como você organizaria uma exploração paramétrica para comparar diferentes valores de um parâmetro de projeto. Indique quais saídas observar, como resumir os resultados e como decidir entre configurações.

Exercício 15.19 Descreva um problema de otimização multiobjetivo por simulação em que haja conflito entre custo e desempenho. Explique:

1. quais seriam as variáveis de decisão;
2. quais seriam os objetivos;
3. por que uma única solução ótima pode não existir;
4. por que um algoritmo evolucionário multiobjetivo pode ser uma escolha adequada.

Exercício 15.20 Discuta criticamente a afirmação a seguir: *A utilidade de um estudo de simulação não depende apenas da qualidade do modelo, mas também da qualidade da análise estatística feita sobre suas saídas.*