



B. Geração de Números Aleatórios e de Variáveis Aleatórias

B.1 Introdução

Em praticamente toda simulação estocástica, em algum momento, o computador precisa decidir entre alternativas possíveis segundo alguma lei de probabilidade. Uma chegada pode ou não ocorrer, um tempo de processamento pode ser maior ou menor, um componente pode falhar mais cedo ou mais tarde, uma entidade pode seguir um entre vários caminhos. Em todos esses casos, a modelagem probabilística precisa ser materializada computacionalmente, e isso exige mecanismos de geração de números aleatórios e de variáveis aleatórias.

Do ponto de vista conceitual, convém distinguir imediatamente dois níveis desse problema. O primeiro é a geração de números que se comportem como realizações independentes de uma variável aleatória uniforme no intervalo $[0, 1]$. O segundo é a transformação desses valores uniformes em realizações de distribuições mais específicas, como exponencial, normal, geométrica, Poisson, Weibull ou gama. Em certo sentido, quase toda a infraestrutura probabilística dos simuladores se organiza em torno dessa ideia: primeiro obtém-se uma sequência de valores $U(0, 1)$ com boa qualidade estatística; depois, aplica-se uma transformação apropriada para obter a distribuição desejada.

Essa observação justifica a estrutura deste apêndice. Inicialmente serão revistos apenas

os fundamentos probabilísticos estritamente necessários para o restante do texto, com ênfase em função de probabilidade, densidade e função de distribuição acumulada. Em seguida, serão discutidos os princípios de geração de números pseudoaleatórios uniformes, as propriedades desejáveis de um bom gerador e alguns testes de qualidade. Por fim, serão apresentados métodos para gerar variáveis aleatórias com distribuições específicas a partir dessas sequências uniformes, com destaque para o método da transformação inversa.

A figura B.1 sintetiza essa lógica. Ela deixa claro que a geração computacional de variáveis aleatórias em simuladores não é uma coleção de rotinas desconexas, mas um fluxo conceitual bastante estruturado.




Figura B.1: Fluxo conceitual da geração de variáveis aleatórias em simuladores: um gerador uniforme $U(0, 1)$ alimenta métodos de transformação que produzem distribuições-alvo usadas na modelagem estocástica.

Também é importante esclarecer o papel deste apêndice no contexto do livro. No Capítulo 6, a preocupação central foi a relação entre dados observados, ajuste estatístico e escolha de distribuições para representar fenômenos do sistema. Aqui, a pergunta é outra: uma vez escolhida a distribuição, como o simulador gera, computacionalmente, valores que a sigam? Portanto, o foco desloca-se da análise dos dados de entrada para a infraestrutura probabilística interna da simulação.

B.2 Fundamentos Probabilísticos Necessários

Este apêndice não pretende substituir um curso de estatística ou de probabilidade. Entretanto, para compreender a geração de variáveis aleatórias é necessário retomar alguns conceitos essenciais. Em particular, importa distinguir variáveis discretas e contínuas, compreender a diferença entre função de probabilidade, densidade e distribuição acumulada, e reconhecer o papel dos parâmetros na forma de uma distribuição.

B.2.1 Variáveis Aleatórias Discretas e Contínuas

Uma **variável aleatória discreta** assume valores em um conjunto finito ou enumerável. Seu comportamento probabilístico é descrito por uma função de probabilidade, também chamada de função massa de probabilidade, que associa a cada valor possível x_k a probabilidade $P(X = x_k)$. Em contextos de simulação, distribuições discretas são particularmente úteis para representar contagens, números de tentativas, números de falhas, números de chegadas e outros eventos cuja realização natural já é inteira.

Uma **variável aleatória contínua**, por sua vez, assume valores em intervalos da reta real. Nesse caso, não faz sentido atribuir probabilidade positiva a um valor isolado x , isto é, em distribuições contínuas vale $P(X = x) = 0$. O que se descreve é a densidade de probabilidade $f(x)$, cuja integração sobre um intervalo fornece a probabilidade de a variável cair nesse intervalo. Em simulação, distribuições contínuas são usadas para modelar tempos, distâncias, velocidades, demandas, erros, níveis e grandezas físicas em geral.

Apesar dessa diferença estrutural, tanto no caso discreto quanto no contínuo a função de distribuição acumulada desempenha papel central, pois é ela que viabiliza o método mais geral e didaticamente mais importante deste apêndice: a transformação inversa.

B.2.2 Função de Probabilidade, Densidade e Distribuição Acumulada

Se X é discreta, sua função de probabilidade pode ser escrita como

$$p(x_k) = P(X = x_k).$$

Se X é contínua, sua densidade é denotada por $f(x)$ e satisfaz

$$P(a \leq X \leq b) = \int_a^b f(x) dx.$$

Em ambos os casos, a **função de distribuição acumulada** é definida por

$$F(x) = P(X \leq x).$$

No caso discreto, $F(x)$ é uma função em degraus. No caso contínuo, ela é uma função contínua não decrescente. Essa distinção é importante tanto conceitualmente quanto computacionalmente. Em distribuições discretas, a transformação inversa conduz a uma busca por intervalos de probabilidade acumulada. Em distribuições contínuas, quando a inversa de F é conhecida ou pode ser calculada numericamente, a geração se torna direta.

Também convém observar que a forma da CDF frequentemente é mais didática do que a própria densidade para explicar o mecanismo de geração. Enquanto a densidade ou a massa de probabilidade mostra onde os valores se concentram, a distribuição acumulada indica explicitamente como probabilidades vão sendo acumuladas até alcançar um número uniforme sorteado em $[0, 1]$.

B.2.3 Distribuições Discretas Relevantes em Simulação

As distribuições discretas aparecem naturalmente quando o modelo precisa representar contagens, números de ocorrências, números de tentativas ou quantidades inteiras de eventos em intervalos de tempo ou em sequências de experimentos.

Distribuição de Bernoulli

A distribuição de **Bernoulli** é a mais simples de todas as distribuições discretas. Ela modela um experimento com apenas dois resultados possíveis, tipicamente interpretados como sucesso e fracasso. Se p é a probabilidade de sucesso, então

$$P(X = 1) = p, \quad P(X = 0) = 1 - p.$$


Embora simples, essa distribuição é fundamental, pois está na base de várias outras distribuições discretas, especialmente a binomial e a geométrica.

Distribuição Binomial

A distribuição **binomial** modela o número de sucessos em n tentativas independentes de Bernoulli, cada uma com probabilidade de sucesso p . Sua função de probabilidade é

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}, \quad k = 0, 1, \dots, n.$$

Ela aparece sempre que o interesse recai sobre a contagem de sucessos em um número fixo de experimentos, inspeções, transmissões, testes ou decisões binárias independentes.



(a) Funções de probabilidade

(b) Funções de distribuição acumulada

Figura B.2: Distribuição binomial para diferentes parâmetros.


Distribuição Geométrica

A distribuição **geométrica** modela o número de tentativas necessárias até a ocorrência do primeiro sucesso em ensaios de Bernoulli independentes. Se p é a probabilidade de sucesso,


então

$$P(X = n) = (1 - p)^{n-1} p, \quad n = 1, 2, \dots$$

Ela é particularmente importante porque representa uma forma discreta de tempo até um evento, o que a aproxima conceitualmente da distribuição exponencial no caso contínuo.



(a) Funções de probabilidade



(b) Funções de distribuição acumulada

Figura B.3: Distribuição geométrica para diferentes parâmetros.

Distribuição de Poisson

A distribuição de **Poisson** é usada para modelar o número de ocorrências de eventos em um intervalo quando esses eventos surgem de forma independente e com taxa média constante. Sua função de probabilidade é

$$P(X = k) = \frac{e^{-\lambda} \lambda^k}{k!}, \quad k = 0, 1, 2, \dots$$

em que $\lambda > 0$ representa o número esperado de ocorrências no intervalo considerado.

Essa distribuição é extremamente importante em simulação de chegadas, falhas, chamadas, pacotes, clientes e eventos raros. Além disso, sua conexão com o processo de Poisson faz dela um dos pilares da modelagem estocástica baseada em eventos.


B.2.4 Distribuições Contínuas Relevantes em Simulação

As distribuições contínuas são particularmente importantes para representar tempos, durações, amplitudes e grandezas físicas. Em simulação, elas aparecem com frequência em tempos entre chegadas, tempos de serviço, tempos de falha, demandas contínuas, tempos de reparo e inúmeras outras variáveis de processo.


Distribuição Uniforme

A distribuição **uniforme contínua** no intervalo $[a, b]$ é a mais simples das distribuições contínuas. Sua densidade é

$$f(x; a, b) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b, \\ 0, & \text{caso contrário.} \end{cases}$$



(a) Funções de probabilidade



(b) Funções de distribuição acumulada

Figura B.4: Distribuição de Poisson para diferentes parâmetros.

Sua CDF é

$$F(x; a, b) = \begin{cases} 0, & x < a, \\ \frac{x-a}{b-a}, & a \leq x \leq b, \\ 1, & x > b. \end{cases}$$

No contexto deste apêndice, ela desempenha papel central porque $U(0, 1)$ é a distribuição de partida para praticamente todos os demais métodos de geração.

Distribuição Triangular

A distribuição **triangular** é definida por um mínimo a , um máximo b e uma moda c , com $a < c < b$. Ela é muito útil quando se conhece um intervalo plausível e um valor mais provável, mas não se dispõe de evidência suficiente para justificar uma distribuição mais elaborada. Essa situação é bastante comum em estágios iniciais de projeto ou em contextos de conhecimento especialista.

Sua densidade é dada por

$$f(x; a, b, c) = \begin{cases} \frac{2(x-a)}{(b-a)(c-a)}, & a \leq x < c, \\ \frac{2(b-x)}{(b-a)(b-c)}, & c \leq x \leq b, \\ 0, & \text{caso contrário.} \end{cases}$$




Figura B.5: Distribuição triangular para diferentes parâmetros.

Distribuição Exponencial

A distribuição **exponencial** é uma das mais usadas em simulação. Ela modela o tempo até a ocorrência de um evento quando a taxa de ocorrência é constante. Sua densidade é

$$f(x; \lambda) = \begin{cases} \lambda e^{-\lambda x}, & x \geq 0, \\ 0, & x < 0, \end{cases}$$

e sua CDF é

$$F(x; \lambda) = \begin{cases} 1 - e^{-\lambda x}, & x \geq 0, \\ 0, & x < 0. \end{cases}$$

Sua importância prática decorre não apenas da simplicidade matemática, mas também da propriedade de falta de memória, que a torna natural em muitos modelos de filas, falhas e chegadas.

Distribuição Normal

A distribuição **normal** é provavelmente a mais conhecida da estatística. Parametrizada por média μ e desvio padrão σ , sua densidade é

$$f(x; \mu, \sigma) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right).$$

Sua CDF não possui forma elementar simples e costuma ser escrita por meio da função Φ da normal padrão:

$$F(x; \mu, \sigma) = \Phi\left(\frac{x-\mu}{\sigma}\right).$$

Em simulação, a normal aparece em erros de medição, variações naturais agregadas, ruídos e várias grandezas que resultam da composição de muitos pequenos efeitos.




Figura B.6: Distribuição exponencial para diferentes parâmetros.




Figura B.7: Distribuição normal para diferentes parâmetros.

Distribuição Lognormal

Uma variável aleatória X segue distribuição **lognormal** quando $\ln(X)$ é normalmente distribuída. Sua densidade é

$$f(x; \mu, \sigma) = \frac{1}{x\sigma\sqrt{2\pi}} \exp\left(-\frac{(\ln x - \mu)^2}{2\sigma^2}\right), \quad x > 0.$$

Sua CDF pode ser expressa como

$$F(x; \mu, \sigma) = \Phi\left(\frac{\ln x - \mu}{\sigma}\right), \quad x > 0.$$

Ela é muito utilizada quando a variável modelada é sempre positiva e apresenta assimetria à direita, como tempos, tamanhos, durações ou multiplicadores aleatórios.




Figura B.8: Distribuição lognormal para diferentes parâmetros.

Distribuição Gama

A distribuição **gama** é uma família de distribuições contínuas muito flexível. Uma parametrização comum usa parâmetro de forma $\alpha > 0$ e parâmetro de taxa $\beta > 0$, com densidade

$$f(x; \alpha, \beta) = \frac{\beta^\alpha x^{\alpha-1} e^{-\beta x}}{\Gamma(\alpha)}, \quad x > 0.$$

Sua CDF pode ser expressa por meio da função gama incompleta regularizada. Em simulação, essa distribuição aparece em tempos positivos assimétricos, em modelos de espera e em somas de variáveis exponenciais.

Distribuição Erlang

A distribuição **Erlang** é um caso particular da distribuição gama em que o parâmetro de forma é inteiro positivo. Se $k \in \mathbb{N}$ e $\lambda > 0$, então sua densidade pode ser escrita como

$$f(x; k, \lambda) = \frac{\lambda^k x^{k-1} e^{-\lambda x}}{(k-1)!}, \quad x > 0.$$

Ela é particularmente importante porque pode ser interpretada como a soma de k variáveis exponenciais independentes com mesma taxa. Essa interpretação é muito útil em modelagem de estágios sucessivos de serviço ou de processos compostos por várias fases exponenciais.




Figura B.9: Distribuição gama para diferentes parâmetros.




Figura B.10: Distribuição Erlang para diferentes parâmetros.

Distribuição Beta

A distribuição **beta** é definida no intervalo $[0, 1]$ e parametrizada por $\alpha > 0$ e $\beta > 0$. Sua densidade é

$$f(x; \alpha, \beta) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} x^{\alpha-1} (1-x)^{\beta-1}, \quad 0 < x < 1.$$

Sua importância em simulação decorre da grande flexibilidade de forma, o que a torna adequada para modelar proporções, frações e quantidades naturalmente limitadas entre dois extremos.




Figura B.11: Distribuição beta para diferentes parâmetros.

Distribuição Weibull

A distribuição **Weibull** é largamente usada em confiabilidade, sobrevivência e modelagem de tempos de falha. Em uma parametrização comum, com parâmetro de forma k e parâmetro de escala λ , sua densidade é

$$f(x; k, \lambda) = \frac{k}{\lambda} \left(\frac{x}{\lambda} \right)^{k-1} e^{-(x/\lambda)^k}, \quad x \geq 0,$$

e sua CDF é

$$F(x; k, \lambda) = 1 - e^{-(x/\lambda)^k}, \quad x \geq 0.$$

Sua relevância prática é muito grande porque o parâmetro de forma altera profundamente o comportamento da taxa de falha ao longo do tempo.

B.2.5 Outras Distribuições Úteis em Inferência Estatística

Além das distribuições mais diretamente usadas na geração de entradas de simulação, convém mencionar algumas distribuições muito importantes em inferência estatística e em testes, pois elas aparecem ao longo do livro em procedimentos de análise.

Distribuição t de Student

A distribuição **t de Student** depende do número de graus de liberdade v . Ela é simétrica e se aproxima da normal padrão à medida que v cresce. Seu uso é central em intervalos de confiança e testes de hipótese quando a variância populacional é desconhecida.




Figura B.12: Distribuição Weibull para diferentes parâmetros.




Figura B.13: Distribuição t de Student para diferentes graus de liberdade.

Distribuição F de Fisher-Snedecor

A distribuição **F** surge frequentemente em comparação de variâncias e, sobretudo, em análise de variância. Ela depende de dois números de graus de liberdade, associados tipicamente ao numerador e ao denominador da estatística de teste.




Figura B.14: Distribuição F de Fisher-Snedecor para diferentes parâmetros.

Distribuição Qui-Quadrado

A distribuição **qui-quadrado** depende do número de graus de liberdade k e é obtida como soma de quadrados de variáveis normais padrão independentes. Ela é central em testes de aderência, em inferência sobre variâncias e em vários procedimentos clássicos de análise estatística.




Figura B.15: Distribuição qui-quadrado para diferentes graus de liberdade.

B.3 Geração de Números Aleatórios Uniformes

Uma vez estabelecido que a maioria dos métodos de geração de variáveis aleatórias parte de uma sequência uniforme em $[0, 1]$, torna-se necessário discutir como essa sequência é obtida em um computador. Esse problema é mais sutil do que parece à primeira vista. Um computador digital é, por natureza, uma máquina determinística, finita e baseada em estados discretos.

Portanto, ele não produz aleatoriedade no mesmo sentido físico em que um fenômeno natural verdadeiramente imprevisível poderia produzi-la. O que ele faz, em geral, é executar algoritmos capazes de construir sequências que se comportem suficientemente bem como se fossem aleatórias para os fins da simulação.

É por isso que, em modelagem e simulação, a maior parte dos geradores utilizados é composta por **geradores pseudoaleatórios**. Eles são determinísticos, reproduzíveis e dependentes de um estado interno e de uma semente inicial. Ainda assim, quando bem projetados, conseguem gerar sequências com propriedades estatísticas adequadas para uso em experimentação computacional. Essa combinação entre determinismo interno e aleatoriedade aparente é precisamente o que os torna tão úteis em simulação: embora não sejam aleatórios em sentido forte, são rápidos, reproduzíveis e suficientemente bons para muitas aplicações.

B.3.1 Conceitos Fundamentais

Em termos abstratos, um gerador pseudoaleatório pode ser interpretado como um sistema dinâmico discreto. Ele possui um **estado interno**, uma **função de transição** que atualiza esse estado e uma **função de saída** que converte o estado atual em um número no intervalo desejado. A figura B.16 mostra essa ideia.




Figura B.16: Arquitetura conceitual de um gerador pseudoaleatório: uma semente inicial define o estado interno, que é atualizado iterativamente por uma função determinística de transição, produzindo saídas que são transformadas em valores $U(0, 1)$.

Se denotarmos por s_n o estado interno no passo n , uma representação geral de um PRNG pode ser escrita como

$$s_{n+1} = T(s_n), \quad u_n = G(s_n),$$

em que T é a função de transição de estados e G é a função que extrai do estado interno a saída observável. A sequência $u_1, u_2, \dots$ é então interpretada como aproximação de uma sequência independente e uniformemente distribuída em $[0, 1]$.

A **semente** (*seed*) é simplesmente o valor inicial do estado interno. Em um PRNG, ela é extremamente importante porque determina toda a sequência subsequente. Se a mesma se-

mente for usada novamente, exatamente a mesma sequência será produzida. Em um primeiro olhar, isso pode parecer um defeito. Contudo, em simulação, é justamente uma de suas maiores virtudes, pois permite repetibilidade e rastreabilidade dos experimentos. Se um estudo precisa ser reproduzido, depurado ou comparado sob condições controladas, a possibilidade de regenerar a mesma sequência aleatória é extremamente útil.

Essa característica deve ser entendida corretamente. O fato de um gerador ser reproduzível não significa que sua sequência seja de baixa qualidade. Significa apenas que ele é determinístico. A questão relevante é outra: a sequência produzida tem propriedades estatísticas suficientemente próximas das desejadas para a aplicação em questão?

B.3.2 Período, Estado e Reprodutibilidade

Como todo PRNG é um sistema determinístico finito, a sequência de estados por ele produzida necessariamente acabará se repetindo. Em outras palavras, qualquer gerador pseudoaleatório possui um **período**. Se a partir de certo instante o estado interno volta a assumir um valor já visitado, a sequência subsequente inteira se repetirá a partir dali.

Em termos formais, se existe um inteiro positivo P tal que

$$s_{n+P} = s_n$$

para n suficientemente grande, então P é o período do gerador. Quanto maior esse período, melhor, pois menor a chance de a repetição interferir no experimento. Em aplicações modernas de simulação, especialmente em campanhas extensas com milhões ou bilhões de amostras, períodos muito curtos são simplesmente inaceitáveis.

Entretanto, período longo não basta. Um gerador pode ter período enorme e ainda assim apresentar correlações inadequadas, padrões geométricos indesejáveis ou distribuição marginal ruim. Portanto, o período é apenas uma das propriedades relevantes, e não um critério suficiente de qualidade.

A reprodutibilidade, por sua vez, decorre diretamente da natureza determinística do processo. Se a semente e os parâmetros do gerador forem mantidos, a mesma sequência reaparecerá. Em simulação, isso permite:

- repetir experimentos;
- comparar cenários sob condições controladas;
- depurar modelos;
- reconstruir o histórico de execução;
- e documentar campanhas experimentais de forma rastreável.

Por essa razão, embora em linguagem comum a expressão número aleatório sugira imprevisibilidade absoluta, em simulação computacional o interesse costuma recair sobre pseudoaleatoriedade de boa qualidade estatística, e não sobre aleatoriedade física genuína.

B.3.3 Propriedades Desejáveis em um Bom Gerador

Um bom gerador pseudoaleatório para simulação deve satisfazer um conjunto de propriedades que, embora não garantam perfeição, delimitam um padrão mínimo de utilidade prática. Entre as mais importantes estão:

1. **Uniformidade marginal:** os valores produzidos devem se distribuir aproximadamente como $U(0, 1)$, sem favorecer sistematicamente subintervalos específicos.
2. **Baixa correlação:** valores consecutivos ou quase consecutivos não devem apresentar dependência perceptível que comprometa a interpretação de independência.
3. **Período longo:** a sequência não deve entrar rapidamente em repetição.
4. **Reprodutibilidade:** o uso da mesma semente deve permitir reconstruir a mesma sequência.
5. **Eficiência computacional:** o custo de geração deve ser baixo, especialmente em simulações extensas.
6. **Baixo uso de memória:** o gerador não deve exigir estrutura interna excessivamente cara.
7. **Robustez a sementes:** pequenas escolhas ruins de semente não devem degradar drasticamente o comportamento.

Na prática, essas propriedades entram em tensão. Certos geradores podem ser extremamente rápidos, mas estatisticamente pobres. Outros podem ter excelente qualidade, mas custo maior. A escolha do PRNG, portanto, é parte da infraestrutura do simulador e precisa ser compatível com a criticidade e o porte do experimento.

B.3.4 Geradores Congruentes Lineares

Historicamente, os **geradores congruentes lineares** estão entre os PRNGs mais conhecidos. Sua forma clássica é

$$x_{n+1} = (ax_n + c) \bmod m,$$

em que:

- x_n é o estado atual;
- a é o multiplicador;
- c é o incremento;
- m é o módulo.

A saída uniforme é então construída por

$$u_n = \frac{x_n}{m}.$$

A popularidade histórica desses geradores decorre de sua extrema simplicidade e velocidade. Eles são fáceis de implementar, consomem pouca memória e foram amplamente usados em simuladores clássicos. Contudo, essa simplicidade tem preço. Dependendo da escolha

dos parâmetros a , c e m , o período pode ser curto e a estrutura multidimensional da sequência pode ser muito ruim.

Apesar disso, os geradores congruentes lineares continuam sendo pedagogicamente importantes porque deixam muito claro o funcionamento básico de um PRNG: um estado inteiro é atualizado por regra determinística simples, e a saída observável é uma transformação desse estado.

B.3.5 Registradores de Deslocamento com Realimentação Linear

Outra classe interessante é a dos **registradores de deslocamento com realimentação linear**, ou *Linear Feedback Shift Registers* (LFSR). Esses geradores são especialmente conhecidos em eletrônica digital, telecomunicações e circuitos, mas também possuem relevância conceitual em geração pseudoaleatória.

A figura B.17 mostra a estrutura típica de um LFSR. O estado interno é armazenado em um conjunto de registradores, e a atualização ocorre por deslocamento, com realimentação calculada por combinação linear binária, tipicamente via XOR.




Figura B.17: Exemplo de registrador de deslocamento com realimentação linear (LFSR), em que o próximo estado é obtido por deslocamento e realimentação binária.

O interesse editorial dessa classe de geradores não está em recomendar seu uso geral em simuladores modernos, mas em mostrar outra forma de construir pseudoaleatoriedade computacional. Em vez de uma congruência modular sobre inteiros, aqui a evolução do estado ocorre em estrutura binária. Dependendo dos polinômios de realimentação escolhidos, podem ser obtidos períodos longos e boas propriedades combinatórias.

B.3.6 Autômatos Celulares como Geradores

Autômatos celulares também podem ser utilizados na construção de sequências pseudoaleatórias. Nesse caso, a pseudoaleatoriedade emerge da evolução determinística de uma configuração discreta segundo regras locais. Entre os exemplos mais conhecidos está a Regra 30 de

Wolfram, muitas vezes citada como geradora de comportamento complexo a partir de regra extremamente simples.

O interesse dessa classe de geradores é conceitualmente muito rico. Ele mostra que aleatoriedade aparente pode emergir não apenas de aritmética modular ou circuitos lineares, mas também de dinâmicas discretas locais com comportamento global complexo. Do ponto de vista da teoria da computação e da modelagem, isso é extremamente sugestivo, embora nem todo gerador baseado em autômato celular seja automaticamente adequado para qualquer aplicação de simulação.

B.3.7 Observação sobre Geradores Modernos

Embora os geradores congruentes lineares, LFSRs e autômatos celulares sejam didaticamente muito úteis, a prática contemporânea em simulação frequentemente recorre a geradores mais sofisticados. Entre eles podem ser citados, por exemplo, Mersenne Twister, famílias *xorshift*, *xoroshiro*, PCG e outras variantes modernas.

O objetivo aqui não é desenvolver esses geradores em detalhe, mas apenas registrar que o estado da prática avançou bastante em relação às classes históricas mais simples. Em aplicações exigentes, a escolha do PRNG não deve ser feita apenas por tradição ou simplicidade de implementação. Ela deve considerar qualidade estatística, custo computacional, independência entre fluxos, portabilidade e adequação ao simulador ou biblioteca utilizados.

B.4 Testes de Qualidade em Geradores Pseudoaleatórios

Nenhum PRNG deve ser aceito apenas porque parece funcionar. A qualidade de um gerador precisa ser examinada por critérios estatísticos e estruturais. Em outras palavras, é necessário verificar se a sequência gerada se comporta como deveria sob os aspectos relevantes para a aplicação pretendida.

Essa exigência é especialmente importante em simulação porque defeitos em um gerador podem contaminar todo o experimento. Se houver padrão oculto, correlação residual ou distribuição marginal inadequada, os valores gerados para tempos, falhas, chegadas e decisões probabilísticas poderão carregar esse defeito, propagando-o ao modelo inteiro.

B.4.1 Uniformidade Marginal

O primeiro requisito básico é a uniformidade marginal. Se um gerador pretende aproximar $U(0,1)$, então seus valores devem se distribuir de maneira aproximadamente uniforme sobre o intervalo. Uma forma simples de examinar isso é por histogramas; outra, mais formal, é por testes como qui-quadrado ou Kolmogorov-Smirnov.

Em termos intuitivos, se a sequência favorece certas faixas do intervalo e evita outras, então ela já falha no requisito mais elementar. Contudo, uniformidade marginal sozinha não basta. Um gerador pode produzir um histograma aparentemente perfeito e ainda assim possuir

forte dependência serial ou padrões estruturais relevantes.

B.4.2 Autocorrelação

Um segundo aspecto importante é a dependência entre termos da sequência. Mesmo que a distribuição marginal seja boa, um gerador será problemático se valores próximos exibirem correlação significativa. Em linguagem estatística, isso significa que a sequência deve apresentar autocorrelações pequenas para diferentes defasagens.

Se $u_1, u_2, \dots, u_n$ é a sequência gerada, uma medida natural de autocorrelação amostral para defasagem k é

$$\hat{\rho}_k = \frac{\sum_{i=1}^{n-k} (u_i - \bar{u})(u_{i+k} - \bar{u})}{\sum_{i=1}^n (u_i - \bar{u})^2},$$

em que $\bar{u}$ é a média amostral. Valores persistentemente altos em módulo para certos k sugerem dependência indevida.

É importante notar que, em sequências finitas, autocorrelações pequenas, mas não exatamente nulas, são esperadas. O problema surge quando aparece padrão sistemático ou valor anormalmente elevado em relação ao que seria compatível com flutuação amostral.

B.4.3 Estrutura Multidimensional e Testes Seriais

Mesmo quando histogramas e autocorrelações simples parecem satisfatórios, ainda pode haver estrutura geométrica indesejável em dimensão maior que um. Essa observação é clássica na análise de PRNGs: pares, trios ou vetores de valores consecutivos podem se alinhar em padrões não desejados, revelando defeitos que não aparecem em análise unidimensional.

Uma maneira intuitiva de perceber isso é construir diagramas de dispersão para pares sucessivos (u_i, u_{i+1}) , ou para tuplas maiores. Se a qualidade for boa, espera-se ocupação razoavelmente homogênea do espaço. Quando aparecem linhas, planos ou regiões vazias sistemáticas, o gerador provavelmente possui estrutura interna problemática.

As Figuras B.18a, B.18b e B.18c ilustram exatamente esse tipo de diagnóstico visual.

Do ponto de vista didático, essas figuras são muito importantes porque mostram que aparência aleatória unidimensional não basta. Um gerador razoável para simulação precisa evitar padrões relevantes também em dimensão maior que um.

B.4.4 Custo Computacional e Critério de Uso

A qualidade estatística do gerador é central, mas não é o único critério relevante. Em campanhas de simulação muito grandes, o custo computacional de gerar amostras pode se tornar relevante. Um gerador excelente, mas demasiadamente lento, pode comprometer a viabilidade operacional do estudo. Por outro lado, um gerador extremamente rápido, porém estatisticamente pobre, pode invalidar os resultados.




Figura B.18: Exemplos de diagnóstico visual da estrutura espacial produzida por diferentes geradores pseudoaleatórios.

Por isso, a escolha de um PRNG deve sempre considerar simultaneamente:

- qualidade estatística;
- custo de geração;
- uso de memória;
- capacidade de reprodutibilidade;
- e adequação à escala da simulação.

B.4.5 Interpretação Prática dos Testes

É importante enfatizar que nenhum conjunto finito de testes prova que um gerador seja aleatório em sentido absoluto. O que esses testes fornecem é evidência de adequação ou inadequação sob certos critérios. Passar em um conjunto de testes não significa perfeição; falhar de modo sistemático, por outro lado, é forte sinal de problema.

Também convém distinguir uso em simulação de uso em criptografia. Para simulação, o objetivo principal é reproduzir bem propriedades estatísticas relevantes. Para criptografia, há exigências adicionais de imprevisibilidade e segurança contra ataques. Um gerador bom para simulação não é necessariamente bom para criptografia, e vice-versa.

Do ponto de vista deste apêndice, a mensagem central é simples: antes de transformar sequências $U(0, 1)$ em distribuições mais complexas, é preciso confiar, ao menos razoavelmente, na qualidade do gerador que está produzindo esses valores uniformes.

B.5 Geração de Variáveis Aleatórias com Distribuições Específicas

Uma vez disponível uma sequência de valores com boa aproximação de $U(0, 1)$, o problema seguinte consiste em transformá-la em realizações de distribuições específicas. Essa etapa é central em simulação estocástica, pois a maior parte dos modelos não precisa apenas de valores uniformes, mas de tempos de serviço exponenciais, demandas normais ou lognormais, contagens de Poisson, durações Weibull, probabilidades geométricas e assim por diante.

Do ponto de vista conceitual, os principais métodos de geração de variáveis aleatórias podem ser agrupados em algumas famílias. Entre elas destacam-se:

- **transformação inversa;**
- **aceitação-rejeição;**
- **composição;**
- **convolução;**
- **métodos especializados**, como Box–Muller para a normal ou algoritmos específicos para Poisson, gama e outras distribuições.

Neste apêndice, o foco principal recairá sobre a **transformação inversa**, porque ela é o método mais geral, mais diretamente conectado à função de distribuição acumulada e mais didaticamente revelador. Isso não significa, entretanto, que ela seja sempre o melhor método do ponto de vista computacional. Em várias distribuições de grande interesse prático, a inversa da CDF não possui forma fechada simples, ou sua implementação é numericamente menos eficiente do que métodos alternativos. Ainda assim, como mecanismo conceitual, a transformação inversa ocupa posição central.

B.5.1 Ideia Geral da Transformação Inversa

Seja $U \sim U(0, 1)$. Se F é a função de distribuição acumulada de uma variável aleatória X , então a transformação

$$X = F^{-1}(U)$$

produz uma variável aleatória com distribuição F , desde que F seja invertível no sentido apropriado. Essa proposição é simples e extremamente poderosa, pois mostra que a geração de variáveis aleatórias pode ser entendida geometricamente como o processo de entrar com um valor uniforme no eixo das probabilidades acumuladas e sair no eixo dos valores da variável.

A figura B.19 ilustra essa ideia no caso contínuo. Escolhe-se um valor $u \in [0, 1]$, projeta-se esse valor horizontalmente até a curva da função de distribuição acumulada e, a partir desse ponto, projeta-se verticalmente até o eixo da variável. O valor obtido é exatamente a realização correspondente de X .

No caso discreto, a lógica é muito semelhante, mas a CDF é uma função em degraus. Em vez de uma inversão contínua, o que se faz é localizar o menor valor x_k tal que $F(x_k) \geq u$. A figura B.20 mostra essa ideia.

Em termos formais, quando F não é estritamente invertível no sentido clássico, costuma-se usar a pseudo-inversa generalizada

$$F^{-1}(u) = \inf\{x \in \mathbb{R} : F(x) \geq u\}.$$

Essa definição serve tanto para distribuições contínuas quanto discretas e unifica o procedimento conceitualmente.




Figura B.19: Interpretação geométrica da transformação inversa: um valor uniforme $u \in [0, 1]$ é mapeado, via inversa da CDF, em uma realização da variável aleatória contínua desejada.




Figura B.20: No caso discreto, a transformação inversa consiste em localizar o menor valor x_k cuja probabilidade acumulada já atinge ou ultrapassa o valor uniforme sorteado.

B.5.2 Justificativa Matemática

A razão pela qual esse método funciona é direta. Se $X = F^{-1}(U)$, então, para qualquer x ,

$$P(X \leq x) = P(F^{-1}(U) \leq x).$$

Como F é não decrescente, essa desigualdade equivale a

$$P(U \leq F(x)).$$

Mas como $U \sim U(0, 1)$, segue que

$$P(U \leq F(x)) = F(x).$$

Portanto,

$$P(X \leq x) = F(x),$$

o que mostra que X possui exatamente a distribuição acumulada desejada.

Essa demonstração é importante porque revela que a transformação inversa não é simples artifício gráfico: ela se apoia diretamente na relação entre a distribuição uniforme e a interpretação probabilística da função de distribuição acumulada.

B.5.3 Exemplo: Distribuição Exponencial

A distribuição exponencial é talvez o exemplo mais clássico da transformação inversa, porque sua CDF possui forma simples e sua inversa pode ser obtida analiticamente sem dificuldade. Se

$$F(x) = 1 - e^{-\lambda x}, \quad x \geq 0,$$

então, tomando $u = F(x)$,

$$u = 1 - e^{-\lambda x}.$$

Logo,

$$e^{-\lambda x} = 1 - u,$$

e, tomando logaritmo natural,

$$-\lambda x = \ln(1 - u).$$

Assim,

$$x = -\frac{1}{\lambda} \ln(1 - u).$$

Portanto, se $U \sim U(0, 1)$, então

$$X = -\frac{1}{\lambda} \ln(1 - U)$$

segue distribuição exponencial com parâmetro λ . Como $1 - U$ também é uniformemente distribuído em $(0, 1)$, é comum escrever simplesmente

$$X = -\frac{1}{\lambda} \ln(U).$$

Esse resultado é extremamente útil em simulação, pois permite gerar tempos exponenciais com custo computacional muito baixo. Não por acaso, esse é um dos primeiros exemplos ensinados em praticamente qualquer curso de simulação estocástica.

B.5.4 Exemplo: Distribuição Triangular

A distribuição triangular é um caso interessante porque sua densidade é definida por trechos, e isso se reflete em sua função de distribuição acumulada. Se $a < c < b$, então sua CDF é

$$F(x) = \begin{cases} 0, & x < a, \\ \frac{(x-a)^2}{(b-a)(c-a)}, & a \leq x < c, \\ 1 - \frac{(b-x)^2}{(b-a)(b-c)}, & c \leq x \leq b, \\ 1, & x > b. \end{cases}$$

Para aplicar a transformação inversa, primeiro observa-se o valor da CDF no ponto modal c :

$$F(c) = \frac{c-a}{b-a}.$$

Assim, se $u < F(c)$, a realização sorteada está no ramo crescente à esquerda da moda. Se $u \geq F(c)$, ela está no ramo decrescente à direita.

Resolvendo a inversa por partes, obtém-se:

$$X = \begin{cases} a + \sqrt{u(b-a)(c-a)}, & 0 \leq u < \frac{c-a}{b-a}, \\ b - \sqrt{(1-u)(b-a)(b-c)}, & \frac{c-a}{b-a} \leq u \leq 1. \end{cases}$$

Esse exemplo é importante porque mostra que o método da transformação inversa continua válido mesmo quando a distribuição acumulada exige tratamento por trechos. O preço, do ponto de vista de implementação, é apenas uma estrutura condicional adicional.

B.5.5 Exemplo: Distribuição Weibull

A distribuição Weibull também é muito conveniente para transformação inversa. Sua CDF é

$$F(x) = 1 - e^{-(x/\lambda)^k}, \quad x \geq 0.$$

Tomando $u = F(x)$, temos

$$u = 1 - e^{-(x/\lambda)^k}.$$

Logo,

$$e^{-(x/\lambda)^k} = 1 - u,$$

e, tomando logaritmo,

$$-\left(\frac{x}{\lambda}\right)^k = \ln(1 - u).$$

Assim,

$$\left(\frac{x}{\lambda}\right)^k = -\ln(1 - u),$$

e finalmente

$$x = \lambda [-\ln(1 - u)]^{1/k}.$$

Portanto, se $U \sim U(0, 1)$, então

$$X = \lambda [-\ln(1 - U)]^{1/k}$$

segue distribuição Weibull com parâmetros k e λ . Mais uma vez, pode-se substituir $1 - U$ por U , se desejado, sem alterar a distribuição final.

Esse resultado é muito relevante em confiabilidade e em simulação de falhas, já que a Weibull permite modelar diferentes regimes de taxa de falha conforme o valor do parâmetro de forma k .

B.5.6 Exemplo: Distribuição Geométrica

No caso discreto, a distribuição geométrica fornece um bom exemplo da aplicação da pseudo-inversa da CDF. Se X representa o número de tentativas até o primeiro sucesso, então

$$P(X = n) = (1 - p)^{n-1} p, \quad n = 1, 2, \dots$$

e sua distribuição acumulada pode ser escrita como

$$F(n) = 1 - (1 - p)^n.$$

Dado $u \in (0, 1)$, deseja-se encontrar o menor inteiro n tal que

$$1 - (1 - p)^n \geq u.$$

Isso equivale a

$$(1 - p)^n \leq 1 - u.$$

Tomando logaritmos,

$$n \ln(1 - p) \leq \ln(1 - u).$$

Como $\ln(1 - p) < 0$, a desigualdade precisa ser interpretada com cuidado, resultando na expressão

$$n \geq \frac{\ln(1 - u)}{\ln(1 - p)}.$$

Logo, a geração pode ser feita por

$$X = \left\lceil \frac{\ln(1 - U)}{\ln(1 - p)} \right\rceil.$$

Esse exemplo mostra com clareza o uso da transformação inversa em distribuições discretas. O mecanismo é o mesmo, mas o resultado precisa ser ajustado ao menor inteiro admissível que satisfaça a condição acumulada.

B.5.7 Exemplo Geral para Distribuições Discretas

Em muitas distribuições discretas, a inversa não é expressa por fórmula fechada simples. Ainda assim, o método continua perfeitamente viável. Basta construir a sequência de probabilidades acumuladas

$$F(x_1), F(x_2), F(x_3), \dots$$

e, dado um valor u , localizar o primeiro x_k tal que

$$F(x_k) \geq u.$$

Em termos algorítmicos, isso significa:

1. gerar $u \sim U(0, 1)$;
2. acumular probabilidades da distribuição discreta;
3. retornar o primeiro valor cuja probabilidade acumulada ultrapasse u .

Esse procedimento é bastante geral e se aplica, por exemplo, a distribuições de suporte discreto finito ou enumerável, desde que a soma acumulada possa ser obtida com custo aceitável.

B.5.8 Observação sobre a Distribuição Normal

A distribuição normal merece comentário particular. Conceitualmente, a transformação inversa continua válida: se $U \sim U(0, 1)$, então

$$X = \mu + \sigma \Phi^{-1}(U)$$

segue distribuição normal com média μ e desvio padrão σ , em que Φ^{-1} é a inversa da CDF da normal padrão.

Entretanto, diferentemente dos casos exponencial e Weibull, a função Φ^{-1} não possui forma elementar simples. Em consequência, a geração de normais em simuladores costuma recorrer a métodos específicos, como:

- Box–Muller;
- método polar de Marsaglia;
- algoritmos de rejeição especializados;
- aproximações numéricas para Φ^{-1} .

Editorialmente, esse ponto é importante porque impede a falsa impressão de que a transformação inversa será sempre o método computacionalmente mais prático. Ela é o método conceitual mais geral; a implementação concreta pode, em várias distribuições importantes, recorrer a estratégias mais eficientes.

B.5.9 Observação sobre Outros Métodos

Embora a transformação inversa seja o foco principal deste apêndice, convém registrar brevemente outras famílias de métodos. O método de **aceitação-rejeição**, por exemplo, é especialmente útil quando se conhece uma distribuição envoltória a partir da qual é fácil amostrar. Métodos de **composição** exploram a possibilidade de decompor distribuições em misturas ou combinações de partes mais simples. Métodos de **convolução** são úteis quando a variável desejada pode ser obtida como soma de variáveis mais elementares, como acontece na distribuição Erlang.

Esses métodos são importantes na prática de implementação de simuladores, mas desenvolvê-los em profundidade desviaria o foco central deste apêndice. Aqui interessa sobretudo a compreensão da arquitetura probabilística básica: um bom gerador uniforme e um mecanismo de transformação apropriado.

B.6 Implicações para Modelagem e Simulação

A discussão desenvolvida ao longo deste apêndice possui implicações diretas para o restante do livro. Em primeiro lugar, ela mostra que a escolha de uma distribuição no ajuste de dados de entrada não esgota o problema. É necessário também que o simulador disponha de mecanismo confiável para gerar amostras dessa distribuição a partir de sequências pseudoaleatórias adequadas.

Em segundo lugar, esse material ajuda a compreender por que a qualidade do gerador uniforme importa tanto. Se a base $U(0, 1)$ for ruim, defeitos estatísticos podem ser propagados às distribuições-alvo e, consequentemente, às saídas do modelo. Assim, embora muitas vezes ocultos do usuário do simulador, os mecanismos internos de geração de números e variáveis aleatórias participam diretamente da qualidade científica e técnica do estudo.

Em terceiro lugar, o apêndice esclarece uma distinção metodológica importante. Escolher uma distribuição com base em dados observados é um problema de análise estatística. Gerar valores dessa distribuição no computador é um problema de implementação probabilística. Ambos são indispensáveis, mas pertencem a etapas conceitualmente distintas da construção do experimento de simulação.

Por fim, convém notar que o custo computacional dessas rotinas também pode ser relevante. Em campanhas experimentais muito grandes, a eficiência do método de geração deixa de ser detalhe irrelevante e passa a influenciar o custo total de execução. Isso reforça a ideia de que, em simulação, teoria probabilística e implementação computacional permanecem intimamente ligadas.

B.7 Considerações Finais

Este apêndice procurou mostrar que a geração de números aleatórios e de variáveis aleatórias é uma parte estrutural da simulação estocástica. Partindo dos fundamentos probabilísticos mínimos necessários, foram revistas distribuições relevantes para modelagem e simulação, discutidas as propriedades desejáveis de bons geradores pseudoaleatórios uniformes e apresentados alguns mecanismos clássicos de geração de distribuições específicas, com destaque para a transformação inversa.

Também se procurou enfatizar que o problema não é apenas matemático, mas computacional e metodológico. Um gerador uniforme inadequado pode comprometer a qualidade de todo o estudo. Um método de transformação mal escolhido pode encarecer ou distorcer a geração das entradas do modelo. E a própria escolha entre diferentes distribuições, embora decidida em outra etapa do projeto, só se torna operacional quando há infraestrutura computacional para materializá-la corretamente.

Com isso, fecha-se o papel deste apêndice no livro. Ele não substitui a análise estatística dos dados de entrada, nem a formulação dos modelos estocásticos, mas fornece a base técnica necessária para compreender como essas escolhas são implementadas dentro dos simuladores e bibliotecas de simulação.

B.8 Exercícios Propostos

Exercício B.1 Explique, com suas próprias palavras, a diferença entre um gerador verdadeiramente aleatório e um gerador pseudoaleatório. Discuta por que, em simulação, geradores pseudoaleatórios costumam ser preferidos.

Exercício B.2 Explique o papel da semente (*seed*) em um gerador pseudoaleatório e discuta por que sua reprodutibilidade é vantajosa em estudos de simulação.

Exercício B.3 Defina o conceito de período de um gerador pseudoaleatório e explique por que período longo é desejável, mas não suficiente, para caracterizar a qualidade do gerador.

Exercício B.4 Discuta a diferença entre uniformidade marginal e independência entre observações em uma sequência pseudoaleatória. Explique por que um gerador pode parecer adequado sob um desses critérios e ainda ser inadequado sob o outro.

Exercício B.5 Considere um gerador congruente linear definido por

$$x_{n+1} = (5x_n + 3) \bmod 16.$$

Partindo de $x_0 = 1$, calcule manualmente os cinco primeiros valores de x_n e os correspondentes valores $u_n = x_n/16$.

Exercício B.6 Explique, qualitativamente, o papel dos testes seriais ou espectrais na avaliação de um gerador pseudoaleatório. Por que histogramas unidimensionais não são suficientes?

Exercício B.7 Mostre que, se $U \sim U(0, 1)$, então a variável

$$X = -\frac{1}{\lambda} \ln(U)$$

segue distribuição exponencial com parâmetro λ .

Exercício B.8 A partir da distribuição geométrica com parâmetro p , derive a expressão

$$X = \left\lceil \frac{\ln(1 - U)}{\ln(1 - p)} \right\rceil$$

usando o método da transformação inversa.

Exercício B.9 Explique por que a transformação inversa no caso discreto exige o uso da função inversa generalizada

$$F^{-1}(u) = \inf\{x \in \mathbb{R} : F(x) \geq u\}.$$

Exercício B.10 Derive a expressão da transformação inversa para a distribuição Weibull com parâmetros k e λ .

Exercício B.11 Explique por que a distribuição normal, embora conceitualmente compatível com a transformação inversa, costuma ser gerada por métodos específicos em implementações computacionais.

Exercício B.12 Considere uma distribuição discreta qualquer com suporte finito $\{x_1, \dots, x_n\}$ e probabilidades $\{p_1, \dots, p_n\}$. Descreva um algoritmo geral para gerar amostras dessa distribuição usando a probabilidade acumulada.

Exercício B.13 Discuta a importância da distribuição triangular em modelagem e simulação. Em que tipo de situação prática ela pode ser preferida a distribuições mais sofisticadas?

Exercício B.14 Explique a relação conceitual entre a distribuição geométrica e a distribuição exponencial.

Exercício B.15 Discuta criticamente a afirmação: *Escolher corretamente a distribuição de entrada é suficiente para garantir boa modelagem estocástica em um simulador.*

Base bibliográfica do capítulo. Este apêndice se apoia principalmente em [29], [4], [hammersley1964montecarlo], [knuth1997seminumerical], [devroye1986nonuniform], [fishman1996montecarlo], [gentle2003randomnumbergeneration], [lecuyer2012random] e [press2007numericalrecipes]. A parte relativa às distribuições de probabilidade mantém continuidade com a literatura já utilizada em capítulos anteriores do livro, enquanto a discussão sobre geradores pseudoaleatórios, testes de qualidade e métodos de geração de variáveis aleatórias se apoia mais diretamente na literatura clássica e moderna de Monte Carlo, métodos estocásticos e computação numérica.